

Aula 06 - Prof. Diego Carvalho e Renato da Costa

*SEFAZ-AL (Auditor Fiscal da
Administração Tributária Estadual -
AFTE) Inteligência Artificial e Ciência de
Dados - 2026 (Pós-Edital)*
**Autor:
Diego Carvalho, Emannuelle
Gouveia Rolim, Equipe Informática
e TI, Renato da Costa**

03 de Setembro de 2026

Índice

1) BI e DW - Teoria	3
2) BI e DW - Questões Comentadas - CEBRASPE	28
3) BI e DW - Lista de Questões - CEBRASPE	42



BUSINESS INTELLIGENCE

Conceitos Básicos

INCIDÊNCIA EM PROVA: ALTA

O Business Intelligence (BI) é o conjunto de tecnologias, processos e práticas que permite transformar dados brutos em informações úteis, organizadas e visualmente compreensíveis, com o objetivo de apoiar a tomada de decisões nas empresas. Envolve a coleta de dados de diferentes fontes, sua integração, armazenamento, análise e apresentação por meio de relatórios, dashboards, gráficos e indicadores de desempenho (KPIs).

Em outras palavras, o BI ajuda gestores, analistas e profissionais de negócios a responder perguntas como: "Quais produtos vendem mais?", "Por que as vendas caíram?", "Qual equipe tem melhor desempenho?", "Como prever resultados futuros?". Para isso, utiliza ferramentas como Power BI, Tableau, Qlik Sense, Excel avançado e sistemas de Data Warehouse. O BI não é apenas tecnologia – é uma cultura de decisões baseadas em dados, e não em achismos ou intuição.

Vamos ver na tabela a seguir diversas definições formais bastante comuns em prova – percebam como há algumas palavras-chave em comum em quase todas essas definições.

DEFINIÇÕES

Business Intelligence é o processo de recolhimento e tratamento de informações que apoiarão a gestão de um negócio.

Palavras-chave: processo; tratamento de informações; apoio à gestão de negócio.

Business Intelligence é o processo inteligente de coleta, organização, análise, compartilhamento e monitoração de dados que, depois de processados, geram informações para o suporte e para a tomada de decisões no ambiente de negócios.

Palavras-chave: processo inteligente; coleta, organização, análise, compartilhamento e monitoração de dados; tomada de decisões.

Business Intelligence trata da capacidade de cruzar informações de diferentes bancos de dados, gerando relatórios analíticos diversos.

Palavras-chave: cruzamento de informações; diferentes bancos de dados; relatórios analíticos.

Business Intelligence se refere à aplicação de técnicas analíticas para informações sobre condições de negócio no sentido de melhorá-las, de uma maneira automatizada, mas com a interpretação e respostas humanas, de forma a melhorar a tomada de decisões.

Palavras-chave: técnicas analíticas; automatizada; tomada de decisões;

Business Intelligence trata da descrição de habilidades das organizações para acessar dados e explorar informações, analisando e desenvolvendo percepções e entendimentos a seu respeito.

Palavras-chave: habilidade; explorar informações; análise de percepções e entendimentos.

Business Intelligence são técnicas, métodos e ferramentas de análise de dados para subsidiar processos de decisão de uma empresa.

Palavras-chave: técnicos, métodos e ferramentas; análise de dados; processo de decisão.

Business Intelligence nada mais é que uma série de conceitos e metodologias para auxiliar na tomada de decisões estratégicas nas empresas através principalmente de geração de relatórios gerenciais analíticos.

Palavras-chave: conceitos e metodologias; tomada de decisões estratégicas; geração de relatórios analíticos.



Business Intelligence é um termo utilizado para descrever as habilidades das corporações para coletar dados e explorar informações, analisá-las e desenvolver entendimentos para tomada de melhores decisões.


Palavras-chave: habilidades; coleta, exploração e análise de dados; tomada de decisão.

Agora que nós já sabemos tudo isso, nós podemos criar a nossa própria definição:


Business Intelligence (Inteligência de Negócio) é um termo criado pelo Gartner Group utilizado para representar um conjunto de processos, técnicas, metodologias, habilidades, ferramentas e capacidades utilizadas para acessar, coletar, organizar, tratar, analisar, cruzar, processar, compartilhar e monitorar dados de diversas fontes com o intuito de gerar informações e relatórios analíticos que suportem a gestão corporativa, a definição de estratégias e a tomada de decisão em ambientes de negócio.

BI: DA EVOLUÇÃO À PRÁTICA – TRANSFORMANDO DADOS EM AÇÃO

A EVOLUÇÃO: DOS REGISTROS À INTELIGÊNCIA



BI NA PRÁTICA



Tipos de Análise

INCIDÊNCIA EM PROVA: BAIXA

Em regra, existem quatro tipos de análises: Análise Descritiva (o que aconteceu?), Análise Diagnóstica (por que aconteceu?), Preditiva (o que pode acontecer?) e prescritiva (o que fazer a respeito?). Vejamos:

TIPOS DE ANÁLISE	DESCRIÇÃO
DESCRITIVA	Trata-se do exame de dados ou conteúdos para responder à pergunta: "O que aconteceu?" ou "o que está acontecendo?". É caracterizado pelo Business Intelligence tradicional e visualizações como gráficos de pizza, gráficos de barras, entre outros que servem para que gestores tomem decisões.
DIAGNÓSTICA	Trata-se de uma forma de análise avançada que examina dados ou conteúdos para responder à pergunta: "Por que isso aconteceu?", e é caracterizada por técnicas como detalhamento,



	descoberta de dados, mineração de dados e correlações. Esse é o tipo de análise empregada em investigações de causa-raiz.
PREDITIVA	Trata-se da combinação de técnicas de estatística, mineração de dados e aprendizagem de máquina (Machine Learning) para encontrar significado em grandes quantidades de dados, trabalhando com probabilidades, entre outros para antecipar comportamentos futuros com base em eventos passados. Responde à pergunta: "O que vai acontecer?"
PRESCRITIVA	Trata-se da forma de análise avançada que examina os dados ou os conteúdos para responder à pergunta: "O que deve ser feito?" ou "O que podemos fazer caso algo aconteça?", e é caracterizada por técnicas como análise de gráficos, simulação, redes neurais, mecanismos de recomendação, heurísticas, aprendizado de máquina, entre outros.
EXPLORATÓRIA	Trata-se de uma abordagem mais aprofundada, que envolve a exploração detalhada dos dados para identificar padrões, tendências e relações ocultas. Gráficos, histogramas, Scatter Plots e outras visualizações são frequentemente usados para revelar insights iniciais e formular hipóteses para análises posteriores.
EXPLANATÓRIA	Trata-se de uma abordagem para entender as relações de causa e efeito entre as variáveis. Ela explora como uma variável afeta outras variáveis e tenta explicar por que certos padrões estão ocorrendo nos dados. Modelos estatísticos, como regressão, são frequentemente usados para identificar relações significativas.

Agora um ponto importante: tradicionalmente, Business Intelligence não faz análise prescritiva. O BI clássico se limita às análises descritiva e diagnóstica. Já as análises preditivas e prescritivas pertencem ao domínio de Business Analytics, Data Science ou Analytics Avançado, que vão além do BI tradicional. Ocorre que, com o tempo, o termo "Business Intelligence" foi sendo ampliado pelo mercado. Hoje, muitas ferramentas de BI (Ex: Power BI, Tableau, Qlik Sense) já suportam funções preditivas simples.

Já modelos prescritivos exigem ferramentas ou técnicas, tais como: Machine Learning, Inteligência Artificial, Modelos Matemáticos de Otimização (linear, heurísticas, simulações), entre outros. Essas características são próprias de outros campos de estudo, como Data Science, Decision Intelligence ou Artificial Analytics.

A JORNADA DA ANÁLISE DE DADOS

DO PASSADO AO FUTURO: OS 4 NÍVEIS DA ANÁLISE




ANÁLISES COMPLEMENTARES



Arquitetura de Business Intelligence

INCIDÊNCIA EM PROVA: MÉDIA

De acordo com Turban, o BI tem quatro grandes componentes: Data Warehouse, com seus dados-fonte; Análise de Negócio, uma coleção de ferramentas para manipular e analisar os dados do Data Warehouse, incluindo Data Mining (Mineração de Dados); Business Performance Management (BPM), para monitoria e análise do desempenho; e uma interface de usuário, como um dashboard. Vejamos na imagem seguinte uma arquitetura de alto nível de Business Intelligence:



Data Warehouse

O Data Warehouse é um repositório de dados estruturado e preparado para apoiar processos de tomada de decisão. Ele recebe dados de sistemas transacionais (Ex: CRM, ERP, planilhas, etc), que são integrados, padronizados e armazenados de forma histórica. O DW permite desde consultas simples e relatórios gerenciais até análises complexas e otimizações. Também pode ser subdividido em Data Marts, repositórios menores dedicados a áreas específicas como marketing ou finanças.

Análise de Negócios

A análise de negócios usa ferramentas de software para permitir que usuários criem, sob demanda, relatórios, consultas e análises de dados. Surgiu com o conceito de OLAP (Online Analytical Processing), permitindo visualizar diferentes dimensões dos dados, identificar padrões, tendências e problemas. Assim, os usuários conseguem rapidamente detectar regiões, produtos ou clientes com desempenho fora do esperado, facilitando a tomada de decisões com base em dados.

Business Performance Management (BPM)

O BPM é a etapa final do processo de BI, focado em monitorar e otimizar o desempenho organizacional. Baseia-se em metodologias como Balanced Scorecard, conectando objetivos estratégicos a indicadores



e resultados reais da empresa. Ele utiliza informações de BI para acompanhar metas, gerar relatórios e apoiar decisões dos gestores. Na prática, o BPM permite comparar o desempenho real com o planejado e ajustar ações para melhorar os resultados corporativos.

Interface de Usuário

A interface de BI é composta por dashboards, portais e outras ferramentas que apresentam informações de forma visual, interativa e intuitiva. Os dashboards exibem indicadores-chave de desempenho (KPIs), tendências e alertas, como um painel de controle de carro, permitindo uma visão imediata da saúde do negócio. Outras ferramentas incluem portais corporativos, cockpits digitais e softwares de visualização, que possibilitam explorar gráficos, relatórios e resultados de forma clara e acessível para diferentes perfis de usuários.


COMPONENTES	DESCRIÇÃO
DATA WAREHOUSE	Partindo do lado esquerdo da figura, vemos um fluxo de dados dos sistemas transacionais (Ex: CRM, ERP, etc) até um Data Warehouse, que é um banco ou repositório de dados de interesse dos gestores preparado para dar suporte a aplicações de tomada de decisão. As aplicações variam de simples gerações de relatórios ou consultas a complexas otimizações.
ANÁLISE DE NEGÓCIOS	Trata-se de um conjunto de ferramentas para manipular, minerar e analisar dados, criar relatórios, realizar consultas sob demanda, entre outros. Dessa forma, usuários de negócio são capazes de identificar com rapidez e facilidade as tendências de desempenho (Ex: usuários podem isolar e identificar produtos, clientes ou regiões que apresentam tendências significativas de alta ou de baixa, ou que constituem fontes de problemas).
BPM	Este componente permite otimizar o desempenho geral de uma organização por meio da conexão de métricas (Ex: informações financeiras) com desempenhos reais da organização. Para tal, utiliza-se da análise, geração de relatórios e consultas para comparar o desempenho de negócios às metas estabelecidas - além de oferecer uma plataforma para compartilhar metas de desempenho e resultados da empresa.
INTERFACE DE USUÁRIO	Esse componente permite uma visão rápida dos dados por meio de ferramentas de visualização, como dashboards, painéis, portais, gráficos, cockpits, entre outros. Os dashboards fornecem uma visão abrangente das medidas, tendências e exceções do desempenho corporativo provenientes de múltiplas áreas do negócio, propiciando uma visão imediata da saúde da organização.

Processo de Business Intelligence

INCIDÊNCIA EM PROVA: MÉDIA

O processo de Business Intelligence (BI) é o conjunto de etapas que transforma dados brutos em informações e insights relevantes para apoiar a tomada de decisões estratégicas nas organizações. Dito isso, nós já vimos nas páginas anteriores componentes suficientes para finalmente entender como funciona o processo de BI. Vejam a figura abaixo:





Vamos por partes: à esquerda, temos os Data Sources (Fontes de Dados). É o ecossistema operacional onde os dados nascem. Cada sistema tem formatos, cadências e qualidades distintas (Ex: ERP com vendas e faturamento; CRM com funil e contatos; planilhas departamentais; APIs externas com câmbio, demografia, etc). Aqui ainda vale a lógica OLTP: muitos registros pequenos, atualizações frequentes, foco em operação. Na tabela, podemos ver uma descrição das principais fontes de dados:

FONTES DE DADOS	DESCRIÇÃO
CRM/ERP	Sistemas de CRM (Customer Relationship Management) e ERP (Enterprise Resource Planning) que fornecem dados transacionais e operacionais.
SISTEMAS LEGADOS	Sistemas mais antigos que ainda estão em uso por uma organização e que ainda fornecem serviços essenciais (muitas vezes, desenvolvidos com tecnologias ultrapassadas).
BANCOS DE DADOS	Bancos de dados estruturados que armazenam informações essenciais.
DADOS WEB (XML/JSON)	Dados extraídos da web em formatos como XML ou JSON. Esses formatos são representações de dados utilizados na troca de dados entre aplicações.
PLANILHAS ELETRÔNICAS	Dados armazenados em planilhas eletrônicas, frequentemente usados para relatórios manuais e análises ad hoc.
DADOS EXTERNOS	Informações obtidas de fontes externas à organização que podem vir de diversas fontes diferentes.

A imagem quer mostrar que diversas fontes de dados servem de entrada para um Enterprise Data Warehouse (EDW). No entanto, notem que - antes de serem carregados - eles devem passar pelo processo de ETL (Extract, Transform, Load). Essas são as principais etapas, mas é possível dividi-la também em Seleção, Extração, Transformação, Integração e Carga, conforme apresentamos a seguir:

ETAPAS	DESCRIÇÃO
SELEÇÃO	Define o quê traremos (tabelas, colunas, filtros de período) e sob quais critérios de negócios/privacidade.



EXTRAÇÃO	Coleta os dados das fontes (completa, incremental, CDC, em lote, quase em tempo real, entre outros).
TRANSFORMAÇÃO	Limpeza, padronização (Ex: "SP" vs "São Paulo"), deduplicação, enriquecimento (Ex: faixas etárias), cálculos e conformidade de chaves.
INTEGRAÇÃO	Consolida dados de múltiplas origens num modelo comum (conformação de dimensões, códigos e calendários).
CARGA	Grava os dados já transformados e consolidados no DW ou no ODS. A Staging Area serve como zona de trabalho técnica/temporária durante as etapas de extração e transformação.

Os dados podem passar por uma área intermediária chamada ODS/Staging antes de serem carregados no Data Warehouse. Esta área serve para armazenar temporariamente os dados durante o Processo ETL. Nós não vamos detalhar o Processo de ETL agora porque será visto mais à frente. O Data Warehouse – como já sabemos – é um repositório central onde os dados integrados e transformados são armazenados, sendo que ele contém:

- **Metadados:** informações sobre os dados armazenados no DW, como estruturas e atributos de tabelas, especificações do modelo de dados, rotinas de acesso, log de extrações, entre outros;
- **Replicação:** mecanismos para copiar e sincronizar dados entre diferentes sistemas e o Data Warehouse. Isso garante a continuidade de negócio e reduz latência para filiais/regiões.

Como sabemos, Data Warehouses podem ser divididos em Data Marts, cada um focado em uma área específica da empresa (Ex: Marketing, Finanças, RH). Usuários e aplicações não acessam os dados diretamente – eles usam middlewares e APIs, que fazem a ponte entre os sistemas e o DW, garantindo acesso eficiente. A última etapa envolve a visualização dos dados para apoiar decisões. Finalmente, os dados são acessados e analisados para descobrir informações relevantes para a organização através de diversas ferramentas e métodos de visualização, incluindo:

FERRAMENTAS	DESCRIÇÃO
DATA MINING	Processo de descoberta de padrões significativos em grandes conjuntos de dados, usando métodos estatísticos e algoritmos para encontrar insights ocultos.
TEXT MINING	Análise de textos para extrair informações úteis, identificar tendências / padrões, frequentemente utilizada para processar dados não estruturados.
APLICAÇÕES WEB	Interfaces de software acessíveis via navegador que permitem usuários interagir e visualizar dados do DW em tempo real, com foco em usabilidade e acessibilidade.
APLICAÇÕES DE NEGÓCIO	Softwares específicos de negócio que utilizam dados do DW para otimizar operações empresariais, melhorar processos e suporte a decisões estratégicas.
DIAGRAMAS	Representações visuais de dados em formas gráficas, como fluxogramas ou organogramas, que ajudam a entender e comunicar informações complexas.
GRÁFICOS	Visualizações de dados que utilizam elementos gráficos como barras, linhas ou setores para representar e comparar informações numéricas de forma intuitiva.
FERRAMENTAS OLAP	Ferramentas de Processamento Analítico Online que permitem análise multidimensional dos dados, oferecendo capacidades de slicing, dicing e drill-down para explorar insights.
DASHBOARDS INTERATIVOS	Painéis visuais que agregam e mostram métricas e KPIs importantes, permitindo aos usuários interagir com os dados para análises detalhadas e insights rápidos.
PLANILHAS ELETRÔNICAS	Ferramentas como Excel ou Google Sheets que permitem organização, análise e visualização de dados em tabelas, com funcionalidades de cálculo e gráfico.
ANÁLISE EXPLORATÓRIA	Processo de investigar dados para encontrar padrões, detectar anomalias, testar hipóteses e validar suposições com ajuda de visualizações interativas.
MACHINE LEARNING	Aplicação de algoritmos que permitem que sistemas aprendam e façam previsões ou decisões baseadas em dados históricos, melhorando com o tempo e experiência.
ANÁLISE PREDITIVA	Uso de técnicas estatísticas e algoritmos de machine learning para prever tendências futuras e comportamentos, baseando-se em dados históricos e padrões identificados.



SISTEMAS OPERACIONAIS

Integração de dados do DW com sistemas transacionais para otimizar funções e processos internos da empresa, como ERP e CRM.


RELATÓRIOS GERENCIAIS

Documentos que compilam dados e análises para informar gestores sobre o desempenho e estado de diferentes aspectos do negócio, auxiliando na tomada de decisão.

FLUXO DE DADOS: ORIGEM, PROCESSAMENTO E ANÁLISE

1. Origem e Coleta dos Dados

Fontes de Dados Operacionais
(CRMs, ERPs e planilhas, dados do dia a dia)



2. Processamento e Armazenamento Centralizado

Processo ETL:
Extrair,
Transformar
e Carregar.
(Extração, limpeza,
padronização,
validação)

Data Warehouse:
O Repositório Central.
(Armazenamento integrado,
seguro e pronto para análise.)

3. Análise e Visualização

Ferramentas para Geração
de Insights



ARMAZENAMENTO DE DADOS

Conceitos Básicos

INCIDÊNCIA EM PROVA: BAIXÍSSIMA

Ao longo da evolução dos sistemas de análise corporativa, os repositórios de dados passaram por transformações guiadas pela capacidade tecnológica, pelo volume dos dados e pela necessidade de análise mais sofisticada. No início, não havia estruturas complexas: as organizações armazenavam informações em arquivos simples, como CSV, XML, texto ou formatos proprietários.

Esses arquivos eram baratos e fáceis de manipular, mas extremamente frágeis para consistência, integridade e escalabilidade. Por isso, com o aumento do volume de informações transacionais, surgiram os Sistemas Gerenciadores de Banco de Dados (SGBDs), que trouxeram controle de concorrência, integridade, normalização e linguagem padronizada (SQL). Essa fase permitiu operações mais confiáveis, mas os bancos tradicionais não eram eficientes para análises históricas e agregações pesadas.

Foi desse cenário que emergiu o conceito de Data Warehouse, concebido por Bill Inmon e fortalecido por práticas como ETL, modelagem em estrela e histórico de longo prazo. O Data Warehouse consolidava dados de diversas fontes, reconciliando diferenças semânticas e garantindo consistência para relatórios corporativos. Ele marcou uma ruptura: o foco deixou de ser apenas “armazenar”, e passou a ser “analisar com qualidade”.

Com o tempo, percebeu-se que áreas de negócio tinham necessidades específicas e mais ágeis; assim surgiram os Data Marts, subconjuntos especializados do Data Warehouse com escopos temáticos, frequentemente modelados segundo a abordagem de Kimball. Essa fase consolidou o BI clássico (BI 1.0), baseado em consulta estruturada e relatórios confiáveis.

No entanto, a explosão de dados não estruturados – logs, mídias, redes sociais, IoT – expôs a rigidez do Data Warehouse. Foi então que surgiram os Data Lakes, repositórios capazes de armazenar dados brutos em qualquer formato, sem necessidade de pré-modelagem. A filosofia “schema-on-read”, a adoção de Hadoop e o processamento distribuído permitiram uma democratização do armazenamento massivo, mas ao custo de criar ambientes que, se mal governados, tornavam-se Data Swamps.

Para resolver essa dicotomia entre a governança rígida do Data Warehouse e a flexibilidade caótica do Data Lake, surgiram os Data Lakehouses, que combinaram o melhor dos dois mundos: estrutura transacional (ACID), catálogos unificados, versionamento e capacidade de servir tanto workloads analíticos quanto de machine learning no mesmo repositório.

A etapa mais recente da evolução enfatiza não apenas tecnologia, mas organização, culminando no Data Mesh. Essa abordagem descentraliza o armazenamento e o processamento, distribuindo a responsabilidade dos dados para domínios de negócio que passam a tratá-los como “produtos”. Em vez de um único repositório centralizado, existem múltiplos “Data Products” governados por padrões comuns e consumidos de forma federada. O Data Mesh não elimina Data Warehouses, Lakes ou Lakehouses; ele redefine a forma como esses repositórios são criados, mantidos e disponibilizados, colocando ênfase em autonomia, descentralização e escalabilidade organizacional.

Em síntese, a evolução dos repositórios de dados reflete a busca contínua por equilíbrio entre governança, flexibilidade e escalabilidade. Arquivos simples deram lugar aos bancos relacionais; Data Warehouses estruturaram a análise histórica; Data Marts especializaram as necessidades departamentais; Data Lakes ampliaram o escopo para dados brutos e massivos; Lakehouses unificaram governança e



flexibilidade; e o Data Mesh trouxe uma perspectiva organizacional distribuída para lidar com ecossistemas complexos. Cada etapa não substitui a anterior – elas coexistem, compondo um ecossistema híbrido que responde à maturidade e às necessidades específicas de cada organização.

PERÍODO	REPOSITÓRIO/ARQUITETURA	CARACTERÍSTICAS	OBJETIVO PRINCIPAL
1960-1980	Arquivos	Dados armazenados de forma simples, sem padronização, pouca governança e difícil integração.	Registro operacional, armazenamento básico.
1970-1990	SGBDR	Modelo relacional, SQL, ACID, alta integridade; sistemas como Oracle, DB2, Informix.	Processamento transacional (OLTP) e consultas estruturadas.
1990-2005	Data Warehouse	Repositório corporativo central; integração via ETL; dados limpos, consolidados e historizados.	BI corporativo, consistência e análises estratégicas.
1995-2005	Data Marts	Subconjuntos temáticos do DW, geralmente dimensionais (Kimball); entregas mais rápidas.	Análises departamentais, desempenho analítico.
2000-2010	ODS	Repositório intermediário com dados mais recentes e pouca história; integração operacional.	Visão integrada e quase em tempo real para operações.
2010-2018	Data Lake	Armazena dados brutos (estruturados e não estruturados) em grande escala; Hadoop, HDFS, Spark; schema-on-read.	Flexibilidade, Big Data, ciência de dados e ML.
2018+	Data Lakehouse	Combina governança de DW com flexibilidade de Data Lake; tabelas ACID, catálogos, versionamento; ex.: Delta Lake, Iceberg.	BI + ML no mesmo repositório, unificação de workloads.
2019+	Data Mesh	Arquitetura descentralizada; dados como produtos; domínios responsáveis; consumo federado.	Escalabilidade organizacional e autonomia dos domínios.

Data Warehouse e Data Mart

INCIDÊNCIA EM PROVA: ALTÍSSIMA

O termo Data Warehouse pode ser traduzido como "Armazém de Dados". Contudo, é importante esclarecer que um Data Warehouse não é simplesmente um banco de dados maior, mas sim um tipo especializado de banco de dados, projetado para análise de informações e suporte à tomada de decisão. Ele se diferencia dos bancos de dados tradicionais, também conhecidos como sistemas OLTP (Online Transaction Processing), que são otimizados para operações transacionais do dia a dia, como inserção de registros, consultas, atualizações ou exclusões.

Vamos relembrar um pouquinho a história do Estratégia Concursos: quatro servidores públicos fundam uma empresa de cursos preparatórios para concursos. Inicialmente, com poucos funcionários e um volume reduzido de vendas, um pequeno banco de dados transacional é suficiente para registrar as operações por meio de um sistema. Com o tempo, a empresa obtém grande sucesso, atraindo alunos de todo o país e aumentando significativamente o volume de vendas e, conseqüentemente, a quantidade de dados armazenados.

Com o crescimento, os sócios, sobrecarregados, contratam funcionários para diversas áreas, como financeira, comercial, recursos humanos, pedagógica e coaching. Esses novos colaboradores também utilizam o mesmo sistema e o mesmo banco de dados transacional. Aqui, é importante destacar que os



bancos de dados OLTP são altamente eficientes para operações transacionais, ou seja, para realizar leituras, inclusões, alterações ou exclusões de dados.

O que é uma transação? Uma transação refere-se a um conjunto de operações que buscam manipular dados. Uma transação é um conjunto de operações que precisam ser executadas de forma completa e consistente – ou tudo ocorre com sucesso, ou nada é aplicado, assegurando integridade e confiabilidade dos dados. Os exemplos mais clássicos de operações de uma transação são:

- **Inclusão:** registrar uma nova aula no sistema quando chega a data prevista no cronograma.
- **Leitura:** acessar uma aula pelo site, consultando o banco de dados.
- **Alteração:** corrigir uma aula inserida incorretamente.
- **Exclusão:** remover uma aula do banco de dados, caso necessário.




Os bancos de dados OLTP são ideais para essas operações, sendo amplamente utilizados por professores e alunos que interagem diretamente com os dados transacionais. Com o crescimento da empresa, as áreas administrativa e gerencial (financeira, comercial, recursos humanos, pedagógica, entre outras) passam a demandar relatórios e consultas gerenciais, em vez de manipular dados individualmente. Exemplos incluem:

- **Área Pedagógica:** relatório identificando professores com maior índice de atrasos de aulas.
- **Área Financeira:** relatório de remuneração mensal dos professores.
- **Área Comercial:** relatório de volume de vendas e comissões mensais.
- **Área de Recursos Humanos:** relatório de cálculos trabalhistas.


Esses relatórios consolidados são essenciais para embasar decisões estratégicas dos gestores. Contudo, gerá-los exige alto poder de processamento, já que envolvem a análise de grandes quantidades de dados. Embora os bancos de dados OLTP sejam capazes de processar tais relatórios, eles não foram projetados para tarefas analíticas complexas, conhecidas como OLAP (Online Analytical Processing).

Com o contínuo crescimento da empresa, que passa a atender milhões de alunos, o banco de dados transacional atinge proporções significativas, com mais de um bilhão de linhas e dezenas de tabelas altamente relacionadas. Quando relatórios gerenciais são processados, o desempenho do banco de dados é comprometido, impactando todos os usuários: alunos enfrentam lentidão no download de aulas; professores encontram dificuldades no upload de conteúdos; ou funcionários são responsabilizados pela sobrecarga gerada pelo processamento dos relatórios.


Fica evidente que bancos de dados transacionais não são ideais para processar relatórios analíticos complexos, especialmente em larga escala. Uma solução seria investir em um servidor de banco de dados transacional mais robusto, conforme é apresentado na imagem a seguir. No entanto, essa opção é custosa e pode não ser suficiente caso a empresa continue crescendo.



Outra alternativa seria adquirir um segundo servidor, replicando os dados do banco transacional e dedicando-o exclusivamente ao processamento de relatórios, conforme é apresentado na imagem a seguir. Embora mais acessível, essa abordagem ainda demandaria processar relatórios sob demanda, o que pode ser lento e ineficiente.



A melhor solução é implementar um Data Warehouse (DW), um banco de dados projetado especificamente para análises. Diferentemente de um banco transacional, o Data Warehouse organiza os dados em estruturas analíticas, como tabelas fato e tabelas dimensão, que são otimizadas para consultas complexas e geração de relatórios. Ele não armazena relatórios prontos, mas sim dados tratados, agregados e estruturados para facilitar análises.



Os dados do Data Warehouse são alimentados por meio de um processo chamado ETL (Extract, Transform, Load), que envolve três etapas:



- **Extract (Extração):** coleta dados do banco de dados transacional ou de outras fontes.
- **Transform (Transformação):** limpa, organiza e estrutura os dados no formato adequado para análise.
- **Load (Carregamento):** insere os dados processados no Data Warehouse.

Essa abordagem oferece diversas vantagens: alta performance, porque separa as operações transacionais (alunos e professores) das analíticas (gestores e funcionários), evitando conflitos de uso; facilidade de análise, porque os dados já estão organizados e otimizados para consultas complexas; e eficiência, porque relatórios não precisam ser processados repetidamente, pois os dados no DW são atualizados pelo ETL. Apesar dos benefícios, há desafios a considerar:

- **Complexidade do ETL:** captar e transformar dados de fontes diversas pode ser tecnicamente desafiador e custoso.
- **Infraestrutura Adicional:** ferramentas e servidores específicos são necessários para manter as operações.
- **Defasagem de Dados:** dependendo da periodicidade do ETL, os dados podem não estar atualizados em tempo real.
- **Integração de Dados Não Estruturados:** dados pouco estruturados podem ser difíceis de incorporar ao DW.

Com o sucesso contínuo, a empresa evolui para uma holding, composta por diversas unidades de negócio, como cursos para concursos, pós-graduação, certificações, vestibulares e um site de questões. O número de usuários do Data Warehouse aumenta exponencialmente, sobrecarregando o sistema e causando lentidão. Para resolver esse problema, pode-se adotar a mesma estratégia de replicação de servidores, mas uma solução mais eficiente é criar Data Marts. Trata-se de subconjuntos temáticos do Data Warehouse, segmentados por critérios específicos, como:

- **Assuntos:** concursos, coaching, pós-graduação, certificações, vestibulares, questões.
- **Níveis de Agregação:** anual, semestral, trimestral, mensal, semanal.
- **Localização Geográfica:** regiões como Nordeste, Norte, Centro-Oeste, Sudeste e Sul.

Os Data Marts são estruturas menores e especializadas, projetadas para atender às necessidades específicas de cada área ou unidade de negócio, garantindo maior desempenho e escalabilidade.



O uso de um Data Warehouse, complementado por Data Marts quando necessário, é uma estratégia robusta para empresas que lidam com grandes volumes de dados e demandam análises complexas para embasar decisões estratégicas. Apesar dos desafios, como a complexidade do ETL e os custos de infraestrutura, essa abordagem oferece alta performance e flexibilidade, sendo essencial para organizações em crescimento.

CARACTERÍSTICA

DADOS OPERACIONAIS (OLTP)

DADOS INFORMACIONAIS (OLAP)



FINALIDADE	Suporte a operações do dia a dia (transações)	Suporte à análise, tomada de decisão e relatórios
CONTEÚDO DOS DADOS	Valores atuais/detalhados (registro a registro)	Dados sumarizados, históricos, integrados de várias fontes
ORGANIZAÇÃO DOS DADOS	Por aplicação ou processo (sistema de vendas, RH, etc)	Por assunto/tema de negócio (Vendas, Clientes, Finanças, etc)
NATUREZA DOS DADOS	Dinâmica (mudam constantemente)	Estática ou historizada (mudam apenas em ciclos de carga - ETL)
MODELO DE DADOS	Modelo relacional, normalizado (3FN)	Modelo dimensional (fatos e dimensões), desnormalizado
ATUALIZAÇÃO	CRUD (inclusão, alteração, exclusão) frequente	Carregamento em lote (ETL/ELT), sem UPDATE direto na maior parte dos casos
ACESSO AOS DADOS	Transações curtas, consultas simples e repetitivas	Consultas complexas, agregações, cruzamentos históricos
TEMPO DE RESPOSTA	Milissegundos a < 1 segundo	Segundos a minutos (dependendo da complexidade)
VOLUME DE DADOS	Alto volume de transações pequenas	Grande volume de dados históricos e agregados
USUÁRIOS TÍPICOS	Operadores, sistemas de cadastro, aplicações	Gestores, analistas, BI, cientistas de dados

Banco de Dados Transacional (OLTP)

Data Warehouse (ambiente OLAP)

Foco em Operações do Dia a Dia

Otimizado para registrar transações rápidas como vendas, matrículas e cadastros.

Dados Atuais e Detalhados (Granulares)

Registra o que está acontecendo agora, com informações granulares e atualizadas constantemente.



Usuários Operacionais (Frente de Loja)




Ideal para sistemas de frente de loja, aplicativos e funcionários que inserem dados.

Foco em Análise e Decisão Estratégica

Projetado para responder perguntas complexas e suportar relatórios gerenciais.

Dados Históricos e Consolidados (Agregados)

Centraliza e armazena grandes volumes de dados de várias fontes para análises.



Comparação

Característica	Dados Operacionais (OLTP)	Dados Informacionais (OLAP)
Organização	Por aplicação (vendas, RH)	Por assunto de negócio (clientes, produtos)
Tempo de Resposta	Milissegundos	Segundos a minutos
Tipo de Acesso	Transações curtas e simples	Consultas complexas e agregadas

Usuários Gerenciais e Analistas (BI, Cientistas)



Usado por gestores, analistas de BI e cientistas de dados para encontrar padrões.

Definições Básicas

INCIDÊNCIA EM PROVA: ALTÍSSIMA

Nós fizemos uma contextualização prática sobre Data Warehouse. Agora, é importante entendermos como a literatura acadêmica e as bancas de concurso definem esse conceito. Vejamos:

AUTOR

DEFINIÇÕES ACADÊMICAS



RALPH KIMBALL	Conjunto de ferramentas e técnicas de projeto ¹ que – quando aplicadas às necessidades específicas dos usuários e aos bancos de dados específicos – permitirá que planejem e construam um Data Warehouse.
BILL INMON	Coleção de dados ² orientados por assunto, integrados, variáveis com o tempo e não-voláteis, para dar suporte ao processo de tomada de decisão.
ARUN SEN	Banco de dados construídos no interesse de suporte à decisão de negócios e contêm dados históricos sumarizados e consolidados provenientes de registros individuais de bancos de dados operacionais.
KENNETH LAUDON	Banco de dados – com ferramentas de consulta e relatório – que armazena dados atuais e históricos extraídos de vários sistemas/ambientes operacionais e consolidados para fins de análises e relatórios administrativos.

Note que esses autores convergem para os mesmos pilares conceituais. As palavras-chave mais cobradas em prova são:

PALAVRA-CHAVE	SIGNIFICADO
COLEÇÃO DE DADOS	Um repositório de dados estruturados para análise.
ORIENTADO POR ASSUNTO (SUBJECT-ORIENTED)	Organizado por temas de negócio: Vendas, Clientes, Finanças, etc.
INTEGRADO (INTEGRATED)	Dados provenientes de várias fontes são padronizados, tratados e consolidados.
VARIÁVEL COM O TEMPO (TIME-VARIANT)	Armazena dados históricos, com perspectiva temporal (ano, mês, dia), permitindo análises comparativas.
NÃO-VOLÁTIL (NON-VOLATILE)	Após carregados (via ETL), os dados não são alterados ou excluídos, apenas consultados e atualizados em ciclos específicos.
SUPOORTE À TOMADA DE DECISÃO	Finalidade principal é fornecer informações estratégicas para gestores.
DADOS HISTÓRICOS, SUMARIZADOS E CONSOLIDADOS	Analisa tendências, padrões, desempenho – ao contrário dos dados detalhados de transações do dia a dia (OLTP).
FERRAMENTAS DE CONSULTA E RELATÓRIO	Camada de BI e OLAP que permite visualizar, cruzar e interpretar os dados.

As principais palavras-chave que definem um Data Warehouse são: coleção de dados; orientado por assunto; integrado; variável no tempo; não volátil; dados históricos e sumarizados; suporte à decisão; modelagem dimensional ou corporativa; uso de ferramentas de consulta e relatório (OLAP/BI). Esses termos refletem exatamente o que estudamos: o DW não é um banco de dados comum, mas sim um ambiente projetado para armazenar dados históricos organizados para análises estratégicas, com alta performance e suporte à tomada de decisão.

Características Essenciais

INCIDÊNCIA EM PROVA: ALTA

Nós vimos um contexto geral e um conjunto de definições básicas. No entanto, nós passamos direto por vários termos importantes que veremos a seguir:

¹ Note que Ralph Kimball apresenta uma definição bastante abrangente em que trata o Data Warehouse como um conjunto de ferramentas e técnicas de projeto.

² Esses dados podem ser estruturados ou não-estruturados. No entanto, Data Warehouses geralmente são pouco eficientes ao lidar com dados não-estruturados.





Orientado por Assunto

Data Warehouses são considerados orientados por assunto porque organizam os dados de acordo com temas estratégicos do negócio, e não por processos operacionais ou sistemas específicos. Em um banco de dados transacional, as informações são estruturadas por funcionalidades do sistema, como "cadastro de alunos", "financeiro" ou "estoque", com foco em registrar operações do dia a dia.

Já num Data Warehouse, os dados são reorganizados por grandes áreas de análise – como Vendas, Clientes, Desempenho de Professores, Receita por Produto, Recursos Humanos – permitindo que gestores analisem informações de forma consolidada e estratégica. Isso facilita responder perguntas como "qual curso mais vendeu no último mês?", "qual região do país mais compra nossos produtos?" ou "qual professor atrasa mais aulas?".

Por exemplo, imagine uma instituição de ensino. No banco de dados operacional, as tabelas estão divididas por funcionalidades: alunos, matrículas, cursos, pagamentos, entre outros. Já no Data Warehouse, os dados são reorganizados por assunto. Assim, podemos ter um Data Mart de Vendas, com tabelas como Fato_Vendas, Dim_Tempo, Dim_Curso, Dim_Professor, Dim_Aluno. Outro exemplo seria um Data Mart de Recursos Humanos, com Fato_FolhaPagamento, Dim_Funcionario, Dim_Departamento.

Essa nova estrutura temática facilita a análise, porque agrupa todos os dados relevantes de um mesmo assunto, mesmo que originalmente viessem de sistemas diferentes.

Não-volátil

Data Warehouses são considerados não-voláteis porque, diferentemente dos bancos de dados transacionais (OLTP), eles não sofrem alterações constantes nos dados. Isso significa que, depois que as informações são carregadas no DW por meio de processos como o ETL (Extract, Transform, Load), elas não são atualizadas ou apagadas individualmente. Não existe o uso comum de comandos como UPDATE ou DELETE linha a linha. Em vez disso, os dados permanecem estáveis e são atualizados apenas em ciclos



específicos (diários, semanais, mensais etc.). Essa característica garante confiabilidade histórica, permitindo que análises feitas hoje possam ser reproduzidas no futuro com os mesmos resultados.

Por exemplo: imagine que em 1º de janeiro de 2024 foram registradas 5.000 vendas de cursos em uma empresa. Esse dado é extraído do banco transacional e carregado no Data Warehouse. Mesmo que uma venda seja cancelada depois ou que o valor do curso seja alterado no sistema operacional, o dado armazenado no DW permanece igual (a não ser que uma nova carga completa substitua o histórico). Isso garante que os gestores possam comparar os dados de janeiro/2024 com janeiro/2025, mantendo a coerência das informações. Logo, o DW registra "o que aconteceu", enquanto o banco transacional registra "o que está acontecendo agora".

Integrado

Data Warehouses são considerados integrados porque reúnem dados provenientes de diversas fontes diferentes – sistemas transacionais, ERPs, CRMs, planilhas, APIs, entre outros – e os padronizam em um único repositório coerente. No ambiente operacional, cada sistema costuma ter seu próprio formato de dados, convenções de nomenclatura, unidades de medida e códigos. Por exemplo, um sistema pode registrar "M" e "F" para gênero, outro pode usar "Masculino" e "Feminino", e um terceiro pode usar 1 e 0. No Data Warehouse, antes de armazenar, esses dados são tratados, limpos, padronizados e unificados, garantindo consistência e permitindo comparações confiáveis entre diferentes áreas da empresa. Essa integração é uma das bases do processo de ETL (Extract, Transform, Load).

Por exemplo: imagine que uma empresa tenha três sistemas diferentes – um para vendas online, outro para vendas em lojas físicas e outro para atendimento ao cliente. No sistema de lojas físicas, o estado do cliente é "SP"; no e-commerce, está escrito "São Paulo"; e no sistema de suporte, aparece como código "35". Quando os dados são levados para o Data Warehouse, todos esses valores são transformados para um padrão único, como "SP". Assim, relatórios como "vendas por estado" passam a ser confiáveis e comparáveis. Essa integração garante que o DW seja uma fonte única da verdade (Single Source of Truth) para toda a organização, eliminando divergências entre sistemas.

Histórico

Data Warehouses são considerados históricos porque armazenam dados ao longo do tempo, preservando informações de diferentes períodos para permitir análises de tendências, comparações e evolução dos indicadores do negócio. Enquanto os bancos de dados transacionais (OLTP) se preocupam principalmente com o estado atual dos dados – por exemplo, o saldo atual de um cliente ou a matrícula ativa de um aluno – o Data Warehouse registra também como essas informações eram no passado. Isso significa que ele mantém dados de meses, anos ou até décadas, possibilitando estudos de comportamento, previsões e relatórios comparativos entre períodos.

Por exemplo: imagine uma escola de cursos preparatórios. No banco transacional, a tabela de alunos pode guardar apenas o valor atual da mensalidade ou o curso em que o aluno está matriculado hoje. Já no DW, são armazenados dados históricos de todas as mensalidades pagas, cursos concluídos e mudanças de status. Assim, é possível responder perguntas como: "Como evoluiu o faturamento nos últimos 5 anos?", "Qual foi o crescimento de matrículas por região?", ou "Quais foram os meses com maior evasão de alunos?". Essa capacidade de olhar para trás e comparar diferentes momentos é uma das principais razões pelas quais o Data Warehouse é tão valioso para gestores e analistas.



O Data Warehouse: Análise e Decisão Estratégica – Quatro Pilares Essenciais

Foco no Negócio: Organização e Unificação

1. Orientado por Assunto



2. Integrado



A Perspectiva do Tempo: Estabilidade e Evolução

3. Histórico



4. Não-volátil



Combinação Chave: Histórico + Não-volátil



Tipos de Data Warehouse

INCIDÊNCIA EM PROVA: MÉDIA

Existem basicamente três componentes no ecossistema de Data Warehouse: Enterprise Data Warehouse (EDW), Operational Data Store (ODS) e Data Mart (DM)!

Enterprise Data Warehouse (EDW)

O Enterprise Data Warehouse (EDW) é um repositório corporativo centralizado de dados, que integra informações de todas as áreas da organização – como vendas, finanças, marketing, RH e operações – com o objetivo de fornecer uma visão única, consistente e histórica do negócio para suporte estratégico à tomada de decisões.

Ele armazena dados consolidados, orientados por assunto, integrados, não-voláteis e variáveis no tempo, permitindo análises em larga escala, geração de relatórios gerenciais, dashboards e aplicações de Business Intelligence. Diferente de Data Marts, que atendem áreas específicas, o EDW possui abrangência corporativa e serve como a “fonte única da verdade” (single source of truth) dentro da empresa.

Operational Data Store (ODS)

O Operational Data Store (ODS) é um repositório de dados intermediário entre os sistemas transacionais (OLTP) e o Data Warehouse. Ele armazena dados integrados de diversas fontes operacionais com atualização mais frequente e em tempo quase real, permitindo consultas e análises de curto prazo, voltadas para o suporte a decisões operacionais e táticas do dia a dia.


Diferente do Data Warehouse, o ODS não armazena longos históricos de dados e pode permitir, em alguns casos, atualizações diretas (inserções, alterações e exclusões), o que o torna mais dinâmico. Sua principal função é fornecer uma visão consolidada e atualizada do negócio, sem sobrecarregar os sistemas OLTP nem depender de cargas periódicas como no DW.



Data Mart (DM)

O Data Mart é um subconjunto de um Data Warehouse, projetado para atender às necessidades de uma área específica da organização, como Vendas, Marketing, Recursos Humanos ou Finanças. Ele armazena dados orientados por um tema ou departamento, facilitando o acesso rápido e direto às informações relevantes para aquele grupo de usuários. Por ser mais focado, o Data Mart é mais simples de implementar, exige menor volume de dados e proporciona consultas e relatórios mais ágeis do que um Data Warehouse corporativo completo (EDW).


Embora alguns autores (como C. J. Date) mencionem que Data Marts são mais "voláteis", isso não significa que seus dados mudam como em bancos transacionais. Na verdade, o termo reflete a flexibilidade estrutural – ou seja, Data Marts podem ser mais facilmente ajustados, expandidos ou reestruturados de acordo com as necessidades do departamento. Na prática, eles continuam mantendo as características essenciais de um ambiente analítico: orientação por assunto, integração, histórico e não-volatilidade dos dados operacionais inseridos após o ETL.



TIPO DE DATA MART	DEFINIÇÃO	VANTAGENS	DESVANTAGENS	ABORDAGEM RELACIONADA
DEPENDENTE	Criado a partir de um Data Warehouse corporativo (EDW). Os dados são extraídos do DW, não diretamente dos sistemas transacionais.	- Dados já vêm integrados, limpos e padronizados. - Mantém consistência com a visão corporativa. - Maior governança e controle.	- Depende que o EDW exista primeiro. - Implementação mais lenta e custosa. - Menos flexível para mudanças rápidas.	Top-Down (Bill Inmon)
INDEPENDENTE	Construído diretamente a partir dos sistemas transacionais (OLTP), sem depender de um Data Warehouse central.	- Implementação rápida e econômica. - Atende diretamente a uma área de negócio. - Útil quando o DW ainda não existe.	- Falta de integração entre áreas da empresa. - Pode gerar dados inconsistentes entre setores. - Risco de "ilhas de informação" (data silos).	Bottom-Up (Ralph Kimball)




HÍBRIDO	Combina os dois modelos: pode receber dados tanto do DW quanto de fontes operacionais. Permite integração parcial e agilidade ao mesmo tempo.	- Mais flexível que o dependente. - Mais consistente que o independente. - Possibilita evolução gradual para um EDW.	- Maior complexidade de integração. - Risco de duplicidade de dados. - Demanda governança forte.	Modelo intermediário / Arquiteturas modernas (como Data Lake + DW)
----------------	---	--	--	--



Ecosistema de Data Warehouse

Composto por diferentes repositórios de dados, cada um com um propósito específico para fornecer análises estratégicas, táticas e operacionais.



Tipos de Arquitetura de Data Mart

Tipo	Fonte dos Dados	Principal Vantagem	Principal Desvantagem
DEPENDENTE	Alimentado a partir do Data Warehouse corporativo.	Dados consistentes e integrados; fonte única da verdade.	Exige o DW pronto antes; maior custo e prazo iniciais.
INDEPENDENTE	Extraído diretamente dos sistemas transacionais, sem passar pelo DW.	Implantação rápida e barata para um único setor.	Gera ilhas de dados e inconsistência entre departamentos.
HÍBRIDO	Combina dados do DW corporativo com fontes externas ou operacionais.	Flexibilidade: une consistência e agilidade.	Maior complexidade de manutenção e governança.


ETL e ELT

INCIDÊNCIA EM PROVA: ALTÍSSIMA

Imagine que você precisa carregar seu Data Warehouse regularmente para que ele cumpra sua função: facilitar a análise de negócios e apoiar a tomada de decisões. Para isso, os dados de um ou mais sistemas transacionais precisam ser extraídos, padronizados e carregados no DW. O desafio está justamente em integrar, limpar e consolidar grandes volumes de dados vindos de diferentes sistemas, formatos e tecnologias. É assim que nasce uma base única, confiável e integrada de informações para análise.



Esse processo é conhecido como ETL (Extract, Transform, Load). E atenção: embora a sigla pareça indicar apenas três etapas, ETL é um processo bem mais amplo, que inclui atividades como validação, limpeza, padronização, integração, auditoria, controle de qualidade, agendamento e monitoramento. Em outras palavras, a sigla é simplificada – mas o processo é complexo! Mesmo assim, o termo ETL é consagrado e utilizado mundialmente.



O ETL é considerado uma das partes mais críticas, trabalhosas e demoradas de todo o projeto de Data Warehouse. Muitas literaturas estimam que cerca de 70% a 80% do esforço total de construção de um DW está nessa fase. Isso ocorre porque é necessário extrair dados de fontes diferentes (e muitas vezes bagunçadas), transformá-los, corrigir inconsistências e só então carregá-los no DW com qualidade. E se esses dados forem carregados de forma incorreta, o Data Warehouse produzirá relatórios errados – e decisões estratégicas poderão ser tomadas com base em informações equivocadas.


Outro dado famoso: costuma-se dizer que aproximadamente 60% do esforço do ETL está apenas na extração dos dados. Isso porque os dados podem estar distribuídos em inúmeros sistemas, planilhas, APIs, bancos legados ou até arquivos textos. Cada fonte exige uma forma diferente de captura, conversão e tratamento. Depois da extração, vem a transformação e, por fim, a carga dos dados para o DW.

Mas surge a dúvida: para onde vão os dados após serem extraídos e antes de serem carregados no Data Warehouse? Eles vão para um local chamado Staging Area (ou Stage Area). Essa área funciona como uma "área de transferência de dados", semelhante à área de transferência do computador: é um espaço temporário, usado para armazenar os dados brutos antes de serem transformados e limpos. Importante: ela não é acessada por usuários finais – serve apenas como ambiente técnico para preparar os dados.

É na Staging Area que ocorrem processos como: limpeza de dados, padronização de formatos (Ex: "SP", "São Paulo", "S. Paulo"), tratamento de caracteres inválidos, remoção de duplicidades, verificação de integridade, identificação de erros e preparação para carga no DW. Só depois disso os dados são enviados ao Data Warehouse, já no formato ideal para análise.

Depois da carga inicial (que insere todo o histórico disponível), o mais comum é utilizar a carga incremental – ou seja, carregar apenas os novos dados ou dados modificados desde a última atualização. Isso torna o processo mais rápido e eficiente. Técnicas como timestamp, logs de transação ou Change Data Capture (CDC) podem ser usadas para identificar apenas o que mudou.

Por muito tempo as bancas cobravam apenas ETL nas provas. Mas as coisas mudaram... agora estão cobrando também o ELT! Professor, você errou a sigla? Não! O ELT existe mesmo – e é basicamente uma inversão da ordem tradicional: em vez de Extrair → Transformar → Carregar (ETL), fazemos Extrair → Carregar → Transformar (ELT).



Nos dois casos, o objetivo é o mesmo – levar dados de sistemas transacionais para um ambiente analítico – mas o caminho é diferente. No ETL, os dados são transformados antes de entrar no Data Warehouse. No ELT, os dados são carregados primeiro no repositório de destino (DW, Data Lake ou Lakehouse) e só depois são transformados dentro dele.

Por que isso virou tendência? Quando o ETL surgiu, armazenar e processar dados era caro e lento. Poucas empresas conseguiam manter grandes volumes de dados em servidores. Por isso, fazia-se a limpeza e transformação antes do carregamento, para economizar espaço e evitar retrabalho. Com o avanço da computação em nuvem, tudo mudou: armazenamento ficou barato; processamento ficou extremamente rápido; e as empresas passaram a trabalhar com grandes volumes de dados (Big Data). Resultado? Surgiu o ELT: carrega-se tudo primeiro (dados brutos) e transforma depois, no próprio repositório.

Dentre as principais vantagens do ELT, temos: reduz o tempo entre extração e disponibilidade dos dados; permite que analistas e cientistas de dados transformem os dados diretamente no DW/Data Lake, usando SQL ou ferramentas de BI; engenheiros de dados focam no que é crítico: extração, governança, segurança e orquestração; favorece colaboração entre área técnica e área de negócio, com mais autonomia para quem analisa os dados; e melhor desempenho em ambientes modernos de nuvem com processamento paralelo em massa.

Por outro lado, ele só funciona bem se o repositório de destino for robusto, escalável e com alto poder de processamento. Pode gerar o famoso "data swamp" (lago de dados sujo) se não houver governança, catálogo e transformação bem planejada. ETL ainda é muito utilizado em dados críticos, sistemas legados e ambientes com infraestrutura limitada. Na prática, muitas empresas usam arquiteturas híbridas: ETL para dados operacionais sensíveis e ELT/Lakehouse para dados massivos.

CRITÉRIOS	ETL	ELT
TEMPO DE CARGA	A transformação ocorre antes da carga → o processo pode ser mais lento.	A carga é imediata → dados vão direto para o repositório e podem ser usados mais rapidamente.
TEMPO DE TRANSFORMAÇÃO	A transformação é feita fora do DW, podendo ser mais lenta para grandes volumes.	A transformação é feita dentro do DW/Data Lake com alto poder de processamento em nuvem (MPP), geralmente mais rápida e escalável.



CUSTO DE MANUTENÇÃO	Maior dependência de engenheiros de dados, pipelines mais rígidos e manutenções mais complexas.	Menor custo de armazenamento e maior automação. Ainda exige engenheiros de dados, mas analistas ganham autonomia para transformar dados.
COMPLEXIDADE DE IMPLEMENTAÇÃO	Complexo em relação ao design de fluxo, regras de transformação e staging.	Complexo em termos de arquitetura de nuvem, governança, controle de custos e segurança dos dados brutos.
LIMITAÇÃO DE DADOS	É necessário escolher previamente quais dados serão extraídos e transformados. Dados não escolhidos são descartados.	Dados brutos são armazenados primeiro; só depois são transformados. Isso permite guardar tudo (schema-on-read).
SUPOORTE A BANCOS DE DADOS	Projetado originalmente para bancos relacionais e sistemas legados.	Projetado para grandes volumes de dados em nuvem, estruturados e não estruturados. Integra com Data Lakes, APIs, streaming, etc.
USABILIDADE	Estrutura fixa. Consultas dependem de modelos pré-definidos e profissionais técnicos.	Mais flexível. Permite análise ad hoc, self-service BI e participação de analistas de negócio.
CUSTO/BENEFÍCIO	Mais caro e menos escalável para grandes volumes. Mais viável em ambientes controlados ou sistemas corporativos legados.	Mais econômico em escala, com baixo custo de armazenamento e elasticidade de processamento em nuvem. Ideal para Big Data e Analytics.
DADOS SENSÍVEIS	Mais seguro: permite anonimizar, mascarar e transformar dados sensíveis antes do carregamento.	Exige cuidado: como carrega dados brutos, pode armazenar informações sensíveis sem tratamento inicial.
REPOSITÓRIO DE DESTINO	Comumente usado em Data Warehouses (modelados e estruturados).	Usado em Data Lakes ou Lakehouse, onde os dados podem estar brutos e ser transformados sob demanda.

Data Lake

INCIDÊNCIA EM PROVA: MÉDIA

Um Data Lake é um repositório de dados que permite armazenar grandes volumes de informações em seu formato original, sem a necessidade de estruturação prévia. Diferentemente de um Data Warehouse, que exige organização e modelagem dos dados antes do armazenamento (chamado de schema-on-write), o Data Lake adota a filosofia schema-on-read, isto é, os dados são guardados de forma bruta e só são organizados ou estruturados quando alguém precisa utilizá-los. Ele pode armazenar dados estruturados (como tabelas e planilhas), semiestruturados (JSON, XML, CSV) e não estruturados (imagens, vídeos, áudios, logs, documentos, mensagens de redes sociais e até dados de sensores IoT).

Esse tipo de repositório surgiu como resposta ao crescimento massivo do volume de dados nas empresas e à necessidade de armazená-los com baixo custo e alta escalabilidade, especialmente em ambientes de computação em nuvem. A arquitetura de um Data Lake é altamente flexível e permite que diferentes áreas de uma organização alimentem esse "Lago de Dados" continuamente, sem se preocupar com o formato ou destino imediato dessas informações. Ele funciona como uma fonte central que pode ser usada posteriormente para análises, relatórios, inteligência artificial e machine learning.



Uma das principais vantagens do Data Lake é a flexibilidade analítica. Como todos os dados são armazenados no formato original, cientistas de dados, engenheiros de dados e analistas podem aplicar técnicas avançadas de exploração, mineração, modelagem estatística e treinamento de modelos preditivos. Isso o torna ideal para iniciativas de Big Data, Inteligência Artificial e Machine Learning, que dependem de grandes volumes de dados variados para gerar insights mais precisos. Além disso, o Data Lake permite reaproveitar dados que, em soluções tradicionais, seriam descartados por não estarem no formato certo.

No entanto, essa flexibilidade também traz desafios. Se não houver organização, governança e controle, o Data Lake pode se transformar em um “Data Swamp” (Pântano de Dados), isto é, um repositório confuso, com arquivos duplicados, dados desatualizados, sem metadados, sem segurança e sem utilidade prática. Por isso, boas práticas de governança são essenciais: catalogação de dados, controle de acesso, versionamento, políticas de retenção e definição de zonas.

Outra característica importante é a separação entre armazenamento e processamento. No Data Lake, o armazenamento geralmente é barato e escalável, enquanto o processamento é feito sob demanda por motores diversos. Isso permite que múltiplos usuários e ferramentas consumam os mesmos dados de formas diferentes, seja por consulta SQL, Python, R, dashboards ou algoritmos de aprendizado de máquina.

Além disso, o Data Lake não substitui o Data Warehouse, mas sim o complementa. Enquanto o Data Warehouse é ideal para relatórios gerenciais, dados históricos organizados e indicadores de desempenho, o Data Lake é ideal para armazenar dados diversos, massivos e ainda não estruturados. Muitas organizações utilizam os dois em conjunto – modelo conhecido como Data Lakehouse ou Arquitetura Lambda – onde o Data Lake serve como base bruta e o Data Warehouse como camada refinada para consumo gerencial.

Podemos dizer, portanto, que o Data Lake é como um grande lago onde todos os dados da organização são despejados, independentemente do formato e da origem. Cabe à empresa aplicar governança, segurança e ferramentas de processamento para transformar esse lago em fonte de conhecimento, e não em um pântano caótico. É uma solução poderosa, moderna e essencial para empresas que desejam adotar estratégias orientadas por dados, inteligência artificial e inovação.

CRITÉRIO	DATA WAREHOUSE	DATA LAKE
TRATAMENTO DOS DADOS	Dados são extraídos, transformados e só então carregados (ETL). Armazenamento de dados limpos, integrados e organizados.	Dados são carregados em formato bruto (raw data) e podem ser transformados depois (ELT).
TIPO DE DADOS	Principalmente dados estruturados (tabelas, colunas).	Estruturados, semiestruturados (JSON, XML, CSV) e não estruturados (imagem, áudio, log, vídeo).
USUÁRIOS PRINCIPAIS	Analistas de BI, gestores, área de negócios, tomada de decisão estratégica.	Cientistas de dados, engenheiros de dados, analistas avançados, IA/ML.
CUSTO E DESEMPENHO	Armazenamento e processamento mais caros; otimizado para consultas complexas e rápidas.	Armazenamento barato e escalável; processamento sob demanda (Spark, Hive, Presto, etc).
DEFINIÇÃO DE ESQUEMA	Schema-on-write: o esquema é definido antes de armazenar os dados.	Schema-on-read: o esquema é aplicado apenas na leitura/análise.
VOLUME DE DADOS	Armazena grandes volumes de dados históricos relevantes para decisão.	Armazena volumes massivos (Big Data), incluindo dados raramente usados.





OBJETIVO PRINCIPAL

Suporte a decisões estratégicas, relatórios, dashboards, indicadores (KPI).

Exploração de dados, Machine Learning, descoberta de padrões, Big Data, experimentação.


DATA LAKE



Schema-on-Read (Esquema na Leitura)

A estrutura dos dados só é definida no momento da análise, garantindo flexibilidade.

DATA WAREHOUSE



O ALERTA: EVITE O PÂNTANO DE DADOS!



DATA SWAMP

Sem governança, o lago vira um pântano.

Um repositório caótico, com dados desatualizados e sem valor, é chamado de "Data Swamp".



Governança é a solução.

Catalogar dados, controlar acessos e documentar origens mantém o Data Lake útil.

QUESTÕES COMENTADAS

1. (CEBRASPE / Petrobras - 2022) Quanto aos conceitos relativos à arquitetura de dados, julgue o item a seguir.

Data lakes são grandes armazenadores de informações, vindas de diversas fontes, na qual diversos usuários podem ter acesso para fazer a análise e coletar insights importantes para o negócio.

Comentários:

Data lakes são repositórios que armazenam grandes volumes de dados em seu formato bruto, permitindo que diferentes usuários acessem e analisem informações de diversas fontes para gerar insights valiosos para o negócio.

Gabarito: Correto

2. (CEBRASPE / EMBRAPA - 2025) Considerando as ideias do texto precedente, julgue o próximo item.

Os data lakes proporcionam a possibilidade de se investigar relações de causa e efeito entre variáveis, utilizando-se técnicas de análise de dados observacionais, como técnicas de redes bayesianas e modelos de equações estruturais. Esse grupo de técnicas de análise de dados propicia resultados de análises sem intervenção no sistema, para não ocorrer alterações nos resultados.

Comentários:

Embora os data lakes permitam a análise de grandes volumes de dados, as técnicas mencionadas, como redes bayesianas e modelos de equações estruturais, podem exigir intervenções ou suposições que não garantem resultados sem viés.

Gabarito: Errado

3. (CEBRASPE / TRT - 10ª REGIÃO (DF e TO) - 2025) Julgue o próximo item, relativo à normalização de dados, à linguagem de definição de dados (DDL), a sistema gerenciador de banco de dados (SGBD) Oracle 21C e a data lake.

A principal característica de um data lake é sua capacidade de armazenar diferentes tipos de dados (estruturados, semiestruturados e não estruturados) sem a necessidade de um esquema antecipadamente definido.

Comentários:

A principal característica de um data lake é a flexibilidade no armazenamento de dados em diversos formatos, permitindo que dados estruturados, semiestruturados e não estruturados sejam armazenados sem a necessidade de um esquema pré-definido, o que facilita a ingestão e análise de grandes volumes de dados.

Gabarito: Correto

4. (CEBRASPE / TSE - 2024) Acerca de bancos de dados NoSQL, de banco de dados em memória e de data lake, julgue o item subsequente.

Um data lake funciona como uma arquitetura de armazenamento que requer que todos os dados sejam estruturados e limpos antes de serem armazenados.

Comentários:

Um data lake permite o armazenamento de dados em seu formato bruto, sem a necessidade de estruturação ou limpeza prévia. Isso possibilita a ingestão de grandes volumes de dados variados, facilitando análises futuras.

Gabarito: Errado

5. (CEBRASPE / TJ-PA - 2025) Julgue o item a seguir, que versam acerca da administração do SGBD Oracle, da modelagem de dados multidimensional e do conceito de data lake.

O conceito de data lake baseia-se na estruturação rígida dos dados no momento da ingestão (schema-on-write), o que garante integridade imediata e desempenho otimizado em consultas transacionais.

Comentários:

O conceito de data lake é baseado na ingestão de dados de forma não estruturada (schema-on-read), permitindo flexibilidade e armazenamento de dados em seu formato original, ao contrário da rigidez mencionada.

Gabarito: Errado

6. (CEBRASPE / TCE-AC - 2024) A respeito de Big Data, julgue o próximo item.

Aplicações que usam data lake devem ser abrigadas em plataformas diferentes, em função de armazenarem dados estruturados e não estruturados.

Comentários:

Aplicações que utilizam data lake podem coexistir na mesma plataforma, pois um data lake é projetado para armazenar tanto dados estruturados quanto não estruturados, permitindo flexibilidade e escalabilidade no armazenamento e processamento de dados.

Gabarito: Errado

7. (CEBRASPE / TCE-AC - 2024) A respeito de arquitetura e política de armazenamento de dados e engenharia de dados, julgue o item subsequente.

Os lagos de dados armazenam dados de forma não estruturada e sem catalogação, permitindo que todos os dados sejam armazenados livremente, independentemente de sua análise ou utilidade.

Comentários:

Correto. Os lagos de dados (data lakes) são projetados para armazenar grandes volumes de dados em sua forma bruta, sem a necessidade de estruturação ou catalogação prévia, o que permite flexibilidade na ingestão de dados variados.

Gabarito: Correto

8. (CEBRASPE / MC - 2022) Julgue o próximo item, a respeito de ETL, ELT e data lake.

Data lake é um tipo de repositório que armazena grandes volumes de dados, sob um esquema de banco de dados comum, unificado, visando responder perguntas específicas do negócio; esse sistema de armazenamento também oferece uma visão multidimensional dos dados atômicos e resumidos.

Comentários:

Data lake é um repositório que armazena grandes volumes de dados em seu formato bruto, sem um esquema unificado, permitindo a análise de dados estruturados e não estruturados. Não visa responder perguntas específicas, mas sim armazenar dados para futuras análises.

Gabarito: Errado

9. (CEBRASPE / ANATEL - 2024) A respeito de Big Data, julgue o próximo item.

Em um data lake, os dados são depositados em estado bruto, sem terem passado por qualquer análise e mesmo sem terem uma governança.

Comentários:

Em um data lake, os dados são armazenados em seu estado original, sem processamento prévio, permitindo a inclusão de grandes volumes de dados variados. A falta de governança é uma característica comum, pois a estrutura é flexível e adaptável.

Gabarito: Correto

10.(CEBRASPE / SEBRAE-NACIONAL - 2024) Data lake é um repositório em que é permitido

I processar e proteger grandes quantidades de dados estruturados.

II armazenar dados sem a necessidade de primeiro estruturá-los para que possam ser executados diferentes tipos de análises neles.

III armazenar dados semiestruturados ou dados em formato nativo.

Assinale a opção correta.

- a) Apenas o item I está certo.
- b) Apenas o item II está certo.
- c) Apenas o item III está certo.
- d) Todos os itens estão certos.

Comentários:

(I) Correto. Um data lake é capaz de processar e proteger grandes volumes de dados, inclusive dados estruturados, utilizando tecnologias escaláveis e seguras para armazenamento e análise;

(II) Correto. O data lake é projetado para armazenar dados em seu formato bruto, permitindo análises sem a necessidade de estruturação prévia, o que é uma de suas principais características.

(III) Correto. O data lake aceita dados semiestruturados e em formato nativo, permitindo flexibilidade na análise de diferentes tipos de dados, o que é fundamental para a sua funcionalidade.

Gabarito: Letra D

11.(CEBRASPE / BNB - 2022) Julgue o item a seguir, a respeito do conceito de data lake.

O termo data lake é usado para se referir a uma arquitetura em que os dados são armazenados em vários sistemas de armazenamento de dados e em diferentes formatos, inclusive em sistemas de arquivos, mas podem ser consultados em um único sistema.

Comentários:

O conceito de data lake refere-se a uma arquitetura que permite armazenar dados em diversos formatos e sistemas, mantendo a flexibilidade para consultas em um único ponto. Isso facilita a análise de grandes volumes de dados não estruturados.

Gabarito: Correto

12.(CEBRASPE / EMPREL - 2023) No projeto de arquitetura de um data lake, a primeira etapa que deve estar prevista é a

- a) criação de um ambiente virtual de captura de dados.
- b) concessão de acesso ao banco de dados (somente leitura) aos cientistas de dados, para estes realizarem experimentos e testes.
- c) integração dos dados do data lake aos data warehouses da empresa.
- d) atualização dos dados dos repositórios de dados da empresa a partir dos dados já consolidados disponíveis no data lake.
- e) visualização de dados e otimização das principais consultas.

Comentários:

(a) Correto. A criação de um ambiente virtual de captura de dados é fundamental para um data lake, pois é a etapa inicial que permite a ingestão de dados de diversas fontes, garantindo que a arquitetura esteja pronta para armazenar e processar informações.

(b) Errado. Conceder acesso aos cientistas de dados é uma etapa posterior, pois primeiro é necessário ter um ambiente de dados configurado e os dados capturados para que possam ser analisados.

(c) Errado. A integração dos dados do data lake aos data warehouses ocorre após a captura e organização dos dados, não é a primeira etapa do projeto.

(d) Errado. A atualização dos dados nos repositórios é uma atividade contínua que deve ocorrer após a implementação inicial do data lake, não na fase de planejamento inicial.

(e) Errado. A visualização de dados e otimização de consultas são etapas que dependem da existência de dados já capturados e organizados, portanto, não são prioritárias na fase inicial do projeto.

Gabarito: Letra A

13.(CEBRASPE / DATAPREV - 2023) No que se refere a conceitos de business intelligence, data lake, inteligência artificial e machine learning, julgue o item a seguir.

Um data lake é um excelente recurso para solucionar problemas e encontrar alternativas no momento da tomada de decisão.

Comentários:

Um data lake armazena grandes volumes de dados brutos, mas não fornece diretamente soluções para problemas ou alternativas na tomada de decisão. Para isso, é necessário aplicar técnicas de análise e processamento de dados.

Gabarito: Errado

14.(CEBRASPE / TC-DF - 2023) No que se refere a Big Data, data lake, business intelligence e data warehousing, julgue o item seguinte.

Data lake é um repositório onde os dados podem ser armazenados em vários formatos, incluindo-se registros estruturados e formatos de arquivo não estruturados.

Comentários:

Data lake é um repositório que permite armazenar dados em diversos formatos, tanto estruturados quanto não estruturados, facilitando a análise e o processamento de grandes volumes de dados de forma flexível.

Gabarito: Correto

15.(CEBRASPE / DATAPREV - 2023) No que se refere a conceitos de business intelligence, data lake, inteligência artificial e machine learning, julgue o item a seguir.

Dados em um data lake estão em estado bruto, ou seja, sem verificações, processamentos ou análises.

Comentários:

Dados em um data lake são armazenados em seu formato original, sem transformações ou análises prévias. Isso permite que diferentes tipos de dados sejam mantidos juntos, prontos para processamento posterior.

Gabarito: Correto

16.(CEBRASPE / DATAPREV - 2023) No que se refere a banco de dados NoSQL e data lake, julgue o próximo item.

Considere-se que uma empresa de comércio eletrônico deseje armazenar todos os dados relacionados às interações dos clientes em seu site – registros de visitas, cliques, compras, avaliações, comentários, entre outros. Nessa situação, se a empresa decidir não estruturar e organizar esses dados antecipadamente, será melhor armazenar esses dados em uma solução data lake do que em um banco relacional.

Comentários:

O data lake permite armazenar grandes volumes de dados não estruturados e semi-estruturados, como interações de clientes, sem a necessidade de uma estrutura rígida. Isso é ideal para a flexibilidade e análise posterior dos dados.

Gabarito: Correto

17.(CEBRASPE / TRF - 6ª REGIÃO - 2025) A respeito de Big Data, julgue o item a seguir.

Os data lakes, por armazenarem dados em seus formatos originais, eliminam completamente a necessidade de data warehouses em ambientes de Big Data.

Comentários:

Embora os data lakes armazenem dados em formatos brutos, eles não eliminam a necessidade de data warehouses, que são essenciais para análises estruturadas e relatórios, oferecendo desempenho otimizado e organização dos dados.

Gabarito: Errado

18.(CEBRASPE / SEFIN de Fortaleza - CE - 2023) Julgue o próximo item, relativos a NoSQL, data lake, ETL e governança de dados.

A arquitetura de um data lake pode variar de organização para organização, uma vez que muitas tecnologias podem ser usadas e combinadas de diferentes formas.

Comentários:

A arquitetura de um data lake é flexível e pode ser adaptada conforme as necessidades específicas de cada organização, permitindo a utilização de diversas tecnologias e combinações para atender a diferentes cenários de armazenamento e análise de dados.

Gabarito: Correto

19.(CEBRASPE / SERPRO - 2023) Acerca de armazenamento e processamento de dados, julgue o item a seguir.

Uma das características do data lake é armazenar um grande volume de dados brutos e heterogêneos, oriundos de diversas fontes distintas.

Comentários:

O data lake é projetado para armazenar grandes volumes de dados em seu formato original, permitindo a inclusão de dados estruturados e não estruturados de diversas fontes, o que facilita a análise posterior.

Gabarito: Correto

20.(CEBRASPE / MPE-CE - 2025) Julgue o seguinte item, relativo a técnicas de visualização de dados em business intelligence, a data lakes e a regras de associação em mineração de dados.

Embora os data lakes possam armazenar dados estruturados, como tabelas de bancos relacionais, eles não oferecem suporte para dados semiestruturados e não estruturados, tais como arquivos JSON, XML, imagens e vídeos.

Comentários:

Data lakes são projetados para armazenar grandes volumes de dados em diversos formatos, incluindo dados estruturados, semiestruturados e não estruturados, como JSON, XML, imagens e vídeos. Portanto, a afirmação é incorreta.

Gabarito: Errado

21.(CEBRASPE / BNB - 2022) A respeito de business intelligence, julgue o próximo item.

Data lake é um sistema que permite o armazenamento em uma base de dados os quais tenham sido refinados em processos anteriores.

Comentários:

Data lake é um repositório que armazena dados brutos em seu formato original, sem a necessidade de refinamento prévio. Isso permite que os dados sejam processados e analisados posteriormente, ao contrário de sistemas que exigem dados refinados.

Gabarito: Errado

22.(CEBRASPE / ANM - 2025) Em relação a BI (business intelligence) e à modelagem de dados, julgue o item que se segue.

Bancos de dados utilizados em data warehouses empregam uma modelagem específica e otimizada, denominada modelagem multidimensional.

Comentários:

A modelagem multidimensional é uma abordagem utilizada em data warehouses que organiza dados em dimensões e fatos, facilitando a análise e a geração de relatórios. Essa estrutura otimiza consultas e melhora o desempenho em BI.

Gabarito: Correto

23.(CEBRASPE / CTI - 2024) Com base em obtenção, limpeza e pré-processamento de dados, julgue o próximo item.

A análise descritiva tem como objetivo responder à pergunta 'o que aconteceu?', ao passo que a análise diagnóstica visa responder à questão 'por que isso aconteceu?'.

Comentários:

A análise descritiva foca em resumir e descrever dados, respondendo ao que ocorreu em um determinado contexto. Já a análise diagnóstica busca entender as causas por trás dos eventos, respondendo ao porquê das ocorrências.

Gabarito: Correto

24.(CEBRASPE / CNPQ - 2024) Julgue o item subsecutivo, com base em análise de dados e informações e em mapeamento de fonte de dados.

A análise descritiva envolve a utilização de técnicas estatísticas e algoritmos para fazer previsões ou estimativas sobre eventos futuros com base em dados históricos.

Comentários:

A análise descritiva se concentra em resumir e descrever características dos dados, sem fazer previsões. As previsões são parte da análise preditiva, que utiliza modelos estatísticos e algoritmos para estimar eventos futuros com base em dados históricos.

Gabarito: Errado

25.(CEBRASPE / FUNPRES-P-EXE - 2022) Com base nas informações apresentadas, julgue o item seguinte.

A área representada pela coluna 2 é alimentada com dados obtidos da coluna 1; ela é uma área acessível aos usuários para efetuarem suas consultas.

Comentários:

A descrição sugere que a coluna 2 é uma área de consulta, mas se é alimentada pela coluna 1, isso indica que a coluna 2 pode ser um repositório de dados, não necessariamente acessível para consultas diretas pelos usuários.

Gabarito: Errado

26.(CEBRASPE / FUB - 2025) No que se refere aos sistemas de apoio à decisão e ao benchmarking, julgue o próximo item.

O sistema BI permite análises de cenários, o que contribui para a tomada de decisão empresarial.

Comentários:

O sistema de Business Intelligence (BI) é projetado para coletar, processar e analisar dados, permitindo a criação de cenários que ajudam na tomada de decisões estratégicas nas empresas. Essa capacidade de análise é fundamental para a gestão eficaz.

Gabarito: Correto

27.(CEBRASPE / Telebras - 2022) A coleta de dados visa obter informações estratégicas e pode ser realizada de diferentes formas.

Nesse sentido: métodos de coleta de dados quantitativos são os menos indicados para previsões de longo prazo, pois são subjetivos; métodos de coleta de dados qualitativos são objetivos, pois se baseiam em experiência, julgamento, intuição, conjecturas, emoções etc.

Comentários:

Métodos de coleta de dados quantitativos são, na verdade, mais indicados para previsões de longo prazo, pois são baseados em dados numéricos e análises estatísticas, enquanto os qualitativos são subjetivos, focando em experiências e percepções.

Gabarito: Errado

28.(CEBRASPE / EMBRAPA - 2025) Julgue o próximo item, a respeito de computação e de programação.

As ferramentas de business intelligence, como o Tableau e o Power BI, são utilizadas para criação de dashboards e não possuem funcionalidades para análise de dados ou integração com bancos de dados.

Comentários:

As ferramentas de business intelligence, como Tableau e Power BI, são projetadas para análise de dados e integração com bancos de dados, além de permitir a criação de dashboards interativos e relatórios analíticos.

Gabarito: Errado

29.(CEBRASPE / BDMG - 2025) Julgue o próximo item, relativos a visualização de dados, banco de dados e BI (business intelligence).

Relatórios gerados em ferramentas de BI são sempre estáticos e não podem ser atualizados com novos dados.

Comentários:

Relatórios gerados em ferramentas de BI podem ser dinâmicos e atualizados com novos dados em tempo real, permitindo análises mais precisas e decisões informadas. Essa flexibilidade é uma das principais vantagens das ferramentas de BI.

Gabarito: Errado

30.(CEBRASPE / ANM - 2025) Em relação a BI (business intelligence) e à modelagem de dados, julgue o item que se segue.

Em BI, a informação é o resultado da organização dos dados, ao passo que o conhecimento é a geração de valor com a informação.

Comentários:

Perfeito! A afirmação descreve corretamente a relação entre dados, informação e conhecimento em BI. Dados são organizados para formar informações, e o conhecimento é gerado a partir da análise e interpretação dessas informações, criando valor para a tomada de decisões.

Gabarito: Correto

31.(CEBRASPE / FUNPRES-EXE - 2025) Julgue o próximo item, relativo a data analytics e ferramentas de análise de dados.

Data analytics está associada à camada quantitativa, visto que os dados são o principal insumo no processo de tomada de decisão, principalmente no âmbito empresarial.

Comentários:

Perfeito! A afirmação destaca que data analytics utiliza dados quantitativos para fundamentar decisões empresariais, o que é essencial para análises precisas e embasadas, refletindo a importância dos dados no processo decisório.

Gabarito: Correto

32.(CEBRASPE / DATAPREV - 2023) A respeito da construção de relatórios e dashboards interativos em ferramentas de BI, julgue o seguinte item.

A característica mais distintiva de um dashboard são suas três camadas de informação: monitoramento, análise e gerenciamento.

Comentários:

Os dashboards são projetados para fornecer informações em três camadas: monitoramento (visualização de dados em tempo real), análise (exploração de dados para insights) e gerenciamento (tomada de decisões). Essa estrutura é fundamental para a eficácia das ferramentas de BI.

Gabarito: Correto

33.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Acerca de business intelligence, ETL e OLAP, julgue o item que se segue.

A análise preditiva utiliza algoritmos estatísticos e modelos de machine learning para identificar padrões históricos nos dados e projetar tendências futuras, de forma a guiar decisões proativas e permitir a antecipação de cenários críticos para o negócio.

Comentários:

A análise preditiva realmente utiliza algoritmos estatísticos e modelos de machine learning para identificar padrões em dados históricos, permitindo a projeção de tendências futuras e a tomada de decisões informadas, o que é essencial para a antecipação de cenários críticos nos negócios.

Gabarito: Correto

34.(CEBRASPE / DATAPREV - 2023) A respeito da construção de relatórios e dashboards interativos em ferramentas de BI, julgue o seguinte item.

Um dashboard bem projetado possui como característica a exigência de numerosa codificação customizada para ser implementado, utilizado e mantido.

Comentários:

Um dashboard bem projetado deve ser intuitivo e de fácil manutenção, utilizando ferramentas de BI que oferecem recursos prontos e personalizáveis, minimizando a necessidade de codificação complexa.

Gabarito: Errado

35.(CEBRASPE / DATAPREV - 2023) A respeito da construção de relatórios e dashboards interativos em ferramentas de BI, julgue o seguinte item.

Os dashboards oferecem exibições textuais de informações ad hoc e exibidas em múltiplas mensagens.

Comentários:

Dashboards em ferramentas de BI são projetados para apresentar visualizações gráficas e interativas de dados, não apenas exibições textuais. Eles permitem a análise rápida e intuitiva das informações, facilitando a tomada de decisões.

Gabarito: Errado

36.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Julgue o item seguinte, relativo a Business Intelligence 3.

0 e data warehouse. O conceito de BI 3.0 (Business Intelligence 3.0) é caracterizado pela introdução de soluções de inteligência artificial para tomada de decisões automatizadas em tempo real.

Comentários:

O Business Intelligence 3.0 realmente integra soluções de inteligência artificial, permitindo a automação na análise de dados e a tomada de decisões em tempo real, o que representa uma evolução significativa em relação às versões anteriores.

Gabarito: Correto

37.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Quanto aos conceitos de Big Data e Analytics, julgue o item a seguir.

Em uma abordagem de Analytics, a análise descritiva permite que eventos futuros sejam previstos com base em dados históricos e algoritmos de machine learning.

Comentários:

A análise descritiva tem como foco a interpretação de dados históricos para entender o que aconteceu, mas não prevê eventos futuros. A previsão de eventos é uma função da análise preditiva, que utiliza algoritmos de machine learning.

Gabarito: Errado

38.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Em relação a BI (business intelligence), julgue o item seguinte.

O BI pode ser descrito como um termo abrangente que contempla ferramentas, metodologias, arquiteturas e bancos de dados com o objetivo de fornecer suporte às decisões gerenciais.

Comentários:

O Business Intelligence (BI) realmente abrange um conjunto de ferramentas, metodologias e arquiteturas que, juntamente com bancos de dados, visam facilitar a análise de dados e o suporte à tomada de decisões gerenciais.

Gabarito: Correto

39.(CEBRASPE / STJ - 2024) As estatísticas relacionadas a BI devem ser geradas com base nas fontes transacionais, sem que haja acréscimo de informações diretamente da base de BI.

Comentários:

As estatísticas de Business Intelligence (BI) devem ser geradas a partir de fontes transacionais, pois essas fontes contêm dados operacionais essenciais. A inclusão de informações da base de BI poderia distorcer a análise, comprometendo a integridade dos dados.

Gabarito: Correto

LISTA DE QUESTÕES

- 1. (CEBRASPE / Petrobras - 2022) Quanto aos conceitos relativos à arquitetura de dados, julgue o item a seguir.**

Data lakes são grandes armazenadores de informações, vindas de diversas fontes, na qual diversos usuários podem ter acesso para fazer a análise e coletar insights importantes para o negócio.

- 2. (CEBRASPE / EMBRAPA - 2025) Considerando as ideias do texto precedente, julgue o próximo item.**

Os data lakes proporcionam a possibilidade de se investigar relações de causa e efeito entre variáveis, utilizando-se técnicas de análise de dados observacionais, como técnicas de redes bayesianas e modelos de equações estruturais. Esse grupo de técnicas de análise de dados propicia resultados de análises sem intervenção no sistema, para não ocorrer alterações nos resultados.

- 3. (CEBRASPE / TRT - 10ª REGIÃO (DF e TO) - 2025) Julgue o próximo item, relativo à normalização de dados, à linguagem de definição de dados (DDL), a sistema gerenciador de banco de dados (SGBD) Oracle 21C e a data lake.**

A principal característica de um data lake é sua capacidade de armazenar diferentes tipos de dados (estruturados, semiestruturados e não estruturados) sem a necessidade de um esquema antecipadamente definido.

- 4. (CEBRASPE / TSE - 2024) Acerca de bancos de dados NoSQL, de banco de dados em memória e de data lake, julgue o item subsequente.**

Um data lake funciona como uma arquitetura de armazenamento que requer que todos os dados sejam estruturados e limpos antes de serem armazenados.

- 5. (CEBRASPE / TJ-PA - 2025) Julgue o item a seguir, que versam acerca da administração do SGBD Oracle, da modelagem de dados multidimensional e do conceito de data lake.**

O conceito de data lake baseia-se na estruturação rígida dos dados no momento da ingestão (schema-on-write), o que garante integridade imediata e desempenho otimizado em consultas transacionais.

- 6. (CEBRASPE / TCE-AC - 2024) A respeito de Big Data, julgue o próximo item.**

Aplicações que usam data lake devem ser abrigadas em plataformas diferentes, em função de armazenarem dados estruturados e não estruturados.

7. (CEBRASPE / TCE-AC - 2024) A respeito de arquitetura e política de armazenamento de dados e engenharia de dados, julgue o item subsequente.

Os lagos de dados armazenam dados de forma não estruturada e sem catalogação, permitindo que todos os dados sejam armazenados livremente, independentemente de sua análise ou utilidade.

8. (CEBRASPE / MC - 2022) Julgue o próximo item, a respeito de ETL, ELT e data lake.

Data lake é um tipo de repositório que armazena grandes volumes de dados, sob um esquema de banco de dados comum, unificado, visando responder perguntas específicas do negócio; esse sistema de armazenamento também oferece uma visão multidimensional dos dados atômicos e resumidos.

9. (CEBRASPE / ANATEL - 2024) A respeito de Big Data, julgue o próximo item.

Em um data lake, os dados são depositados em estado bruto, sem terem passado por qualquer análise e mesmo sem terem uma governança.

10.(CEBRASPE / SEBRAE-NACIONAL - 2024) Data lake é um repositório em que é permitido

I processar e proteger grandes quantidades de dados estruturados.

II armazenar dados sem a necessidade de primeiro estruturá-los para que possam ser executados diferentes tipos de análises neles.

III armazenar dados semiestruturados ou dados em formato nativo.

Assinale a opção correta.

- a) Apenas o item I está certo.
- b) Apenas o item II está certo.
- c) Apenas o item III está certo.
- d) Todos os itens estão certos.

11.(CEBRASPE / BNB - 2022) Julgue o item a seguir, a respeito do conceito de data lake.

O termo data lake é usado para se referir a uma arquitetura em que os dados são armazenados em vários sistemas de armazenamento de dados e em diferentes formatos, inclusive em sistemas de arquivos, mas podem ser consultados em um único sistema.

12.(CEBRASPE / EMPREL - 2023) No projeto de arquitetura de um data lake, a primeira etapa que deve estar prevista é a

- a) criação de um ambiente virtual de captura de dados.

- b) concessão de acesso ao banco de dados (somente leitura) aos cientistas de dados, para estes realizarem experimentos e testes.
- c) integração dos dados do data lake aos data warehouses da empresa.
- d) atualização dos dados dos repositórios de dados da empresa a partir dos dados já consolidados disponíveis no data lake.
- e) visualização de dados e otimização das principais consultas.

13.(CEBRASPE / DATAPREV - 2023) No que se refere a conceitos de business intelligence, data lake, inteligência artificial e machine learning, julgue o item a seguir.

Um data lake é um excelente recurso para solucionar problemas e encontrar alternativas no momento da tomada de decisão.

14.(CEBRASPE / TC-DF - 2023) No que se refere a Big Data, data lake, business intelligence e data warehousing, julgue o item seguinte.

Data lake é um repositório onde os dados podem ser armazenados em vários formatos, incluindo-se registros estruturados e formatos de arquivo não estruturados.

15.(CEBRASPE / DATAPREV - 2023) No que se refere a conceitos de business intelligence, data lake, inteligência artificial e machine learning, julgue o item a seguir.

Dados em um data lake estão em estado bruto, ou seja, sem verificações, processamentos ou análises.

16.(CEBRASPE / DATAPREV - 2023) No que se refere a banco de dados NoSQL e data lake, julgue o próximo item.

17.(CEBRASPE / TRF - 6ª REGIÃO - 2025) A respeito de Big Data, julgue o item a seguir.

Os data lakes, por armazenarem dados em seus formatos originais, eliminam completamente a necessidade de data warehouses em ambientes de Big Data.

18.(CEBRASPE / SEFIN de Fortaleza - CE - 2023) Julgue o próximo item, relativos a NoSQL, data lake, ETL e governança de dados.

A arquitetura de um data lake pode variar de organização para organização, uma vez que muitas tecnologias podem ser usadas e combinadas de diferentes formas.

19.(CEBRASPE / SERPRO - 2023) Acerca de armazenamento e processamento de dados, julgue o item a seguir.

Uma das características do data lake é armazenar um grande volume de dados brutos e heterogêneos, oriundos de diversas fontes distintas.

20.(CEBRASPE / MPE-CE - 2025) Julgue o seguinte item, relativo a técnicas de visualização de dados em business intelligence, a data lakes e a regras de associação em mineração de dados.

Embora os data lakes possam armazenar dados estruturados, como tabelas de bancos relacionais, eles não oferecem suporte para dados semiestruturados e não estruturados, tais como arquivos JSON, XML, imagens e vídeos.

21.(CEBRASPE / BNB - 2022) A respeito de business intelligence, julgue o próximo item.

Data lake é um sistema que permite o armazenamento em uma base de dados os quais tenham sido refinados em processos anteriores.

22.(CEBRASPE / ANM - 2025) Em relação a BI (business intelligence) e à modelagem de dados, julgue o item que se segue.

Bancos de dados utilizados em data warehouses empregam uma modelagem específica e otimizada, denominada modelagem multidimensional.

23.(CEBRASPE / CTI - 2024) Com base em obtenção, limpeza e pré-processamento de dados, julgue o próximo item.

A análise descritiva tem como objetivo responder à pergunta 'o que aconteceu?', ao passo que a análise diagnóstica visa responder à questão 'por que isso aconteceu?'.

24.(CEBRASPE / CNPQ - 2024) Julgue o item subsecutivo, com base em análise de dados e informações e em mapeamento de fonte de dados.

A análise descritiva envolve a utilização de técnicas estatísticas e algoritmos para fazer previsões ou estimativas sobre eventos futuros com base em dados históricos.

25.(CEBRASPE / FUNPRES-P-2022) Com base nas informações apresentadas, julgue o item seguinte.

A área representada pela coluna 2 é alimentada com dados obtidos da coluna 1; ela é uma área acessível aos usuários para efetuarem suas consultas.

26.(CEBRASPE / FUB - 2025) No que se refere aos sistemas de apoio à decisão e ao benchmarking, julgue o próximo item.

O sistema BI permite análises de cenários, o que contribui para a tomada de decisão empresarial.

27.(CEBRASPE / Telebras - 2022) A coleta de dados visa obter informações estratégicas e pode ser realizada de diferentes formas.

Nesse sentido: métodos de coleta de dados quantitativos são os menos indicados para previsões de longo prazo, pois são subjetivos; métodos de coleta de dados qualitativos são objetivos, pois se baseiam em experiência, julgamento, intuição, conjecturas, emoções etc.

28.(CEBRASPE / EMBRAPA - 2025) Julgue o próximo item, a respeito de computação e de programação.

As ferramentas de business intelligence, como o Tableau e o Power BI, são utilizadas para criação de dashboards e não possuem funcionalidades para análise de dados ou integração com bancos de dados.

29.(CEBRASPE / BDMG - 2025) Julgue o próximo item, relativos a visualização de dados, banco de dados e BI (business intelligence).

Relatórios gerados em ferramentas de BI são sempre estáticos e não podem ser atualizados com novos dados.

30.(CEBRASPE / ANM - 2025) Em relação a BI (business intelligence) e à modelagem de dados, julgue o item que se segue.

Em BI, a informação é o resultado da organização dos dados, ao passo que o conhecimento é a geração de valor com a informação.

31.(CEBRASPE / FUNPRES-EXE - 2025) Julgue o próximo item, relativo a data analytics e ferramentas de análise de dados.

Data analytics está associada à camada quantitativa, visto que os dados são o principal insumo no processo de tomada de decisão, principalmente no âmbito empresarial.

32.(CEBRASPE / DATAPREV - 2023) A respeito da construção de relatórios e dashboards interativos em ferramentas de BI, julgue o seguinte item.

A característica mais distintiva de um dashboard são suas três camadas de informação: monitoramento, análise e gerenciamento.

33.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Acerca de business intelligence, ETL e OLAP, julgue o item que se segue.

A análise preditiva utiliza algoritmos estatísticos e modelos de machine learning para identificar padrões históricos nos dados e projetar tendências futuras, de forma a guiar decisões proativas e permitir a antecipação de cenários críticos para o negócio.

34.(CEBRASPE / DATAPREV - 2023) A respeito da construção de relatórios e dashboards interativos em ferramentas de BI, julgue o seguinte item.

Um dashboard bem projetado possui como característica a exigência de numerosa codificação customizada para ser implementado, utilizado e mantido.

35.(CEBRASPE / DATAPREV - 2023) A respeito da construção de relatórios e dashboards interativos em ferramentas de BI, julgue o seguinte item.

Os dashboards oferecem exibições textuais de informações ad hoc e exibidas em múltiplas mensagens.

36.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Julgue o item seguinte, relativo a Business Intelligence 3.

O data warehouse. O conceito de BI 3.0 (Business Intelligence 3.0) é caracterizado pela introdução de soluções de inteligência artificial para tomada de decisões automatizadas em tempo real.

37.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Quanto aos conceitos de Big Data e Analytics, julgue o item a seguir.

Em uma abordagem de Analytics, a análise descritiva permite que eventos futuros sejam previstos com base em dados históricos e algoritmos de machine learning.

38.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Em relação a BI (business intelligence), julgue o item seguinte.

O BI pode ser descrito como um termo abrangente que contempla ferramentas, metodologias, arquiteturas e bancos de dados com o objetivo de fornecer suporte às decisões gerenciais.

39.(CEBRASPE / STJ - 2024) As estatísticas relacionadas a BI devem ser geradas com base nas fontes transacionais, sem que haja acréscimo de informações diretamente da base de BI.

GABARITO

- | | | | | | |
|-----|---------|-----|---------|-----|---------|
| 1. | CORRETO | 14. | CORRETO | 27. | ERRADO |
| 2. | ERRADO | 15. | CORRETO | 28. | ERRADO |
| 3. | CORRETO | 16. | CORRETO | 29. | ERRADO |
| 4. | ERRADO | 17. | ERRADO | 30. | CORRETO |
| 5. | ERRADO | 18. | CORRETO | 31. | CORRETO |
| 6. | ERRADO | 19. | CORRETO | 32. | CORRETO |
| 7. | CORRETO | 20. | ERRADO | 33. | CORRETO |
| 8. | ERRADO | 21. | ERRADO | 34. | ERRADO |
| 9. | CORRETO | 22. | CORRETO | 35. | ERRADO |
| 10. | LETRA D | 23. | CORRETO | 36. | CORRETO |
| 11. | CORRETO | 24. | ERRADO | 37. | ERRADO |
| 12. | LETRA A | 25. | ERRADO | 38. | CORRETO |
| 13. | ERRADO | 26. | CORRETO | 39. | CORRETO |

ESSA LEI TODO MUNDO CONHECE: PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.



1 Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.



2 Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).



3 Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).



4 Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).



5 Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).



6 Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).



7 Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.



8 O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.