

Aula 09 - Prof. Diego Carvalho e Renato da Costa

*SEFAZ-AL (Auditor Fiscal da
Administração Tributária Estadual -
AFTE) Inteligência Artificial e Ciência de
Dados - 2026 (Pós-Edital)*
**Autor:
Diego Carvalho, Emannuelle
Gouveia Rolim, Equipe Informática
e TI, Renato da Costa**

03 de Setembro de 2026

Índice

1) Mineração de Dados - Teoria	3
2) Mineração de Dados - Questões Comentadas - CEBRASPE	28
3) Mineração de Dados - Lista de Questões Comentadas - CEBRASPE	39



APRESENTAÇÃO

Prezados,


Para dominar Mineração de Dados, foque primeiro nos Conceitos Básicos e no modelo CRISP-DM, ambos com altíssima incidência em prova. Essas matérias são fáceis e exigem compreender o ciclo iterativo do CRISP-DM, estruturado em seis fases. O ponto crucial aqui é memorizar que a fase de preparação de dados consome de 50% a 70% do tempo e que a fase de avaliação valida os modelos frente aos objetivos de negócio. Por ser um assunto essencialmente teórico, possui um excelente custo-benefício.

Para quem estuda em pré-edital com tempo, o ideal é construir uma base sólida. Estude a teoria de KDD (baixa incidência, mas dá visão geral), os tipos de análise e todas as tarefas de mineração. Estude os algoritmos supervisionados, como árvores de decisão e regressão para prever valores contínuos, e não supervisionados, como regras de associação (suporte e confiança) e clustering, focando em K-Means e coeficiente Silhouette. Detecção de anomalias pode ser deixada para o final.

No pós-edital, com tempo escasso, foque no que mais cai e descarte o resto. Estude só os conceitos básicos de Data Mining, as fases do CRISP-DM e diferencie o aprendizado supervisionado (classificação e regressão) do não supervisionado (agrupamento e associação) - isso é muito importante. Você pode descartar as etapas detalhadas de KDD e a detecção de anomalias. Gaste seu tempo resolvendo dezenas de questões para fixar qual algoritmo pertence a qual tarefa, pois as principais bancas cobram essa correlação direta de forma rápida e conceitual.

A matéria une decoreba teórica com conceitos abstratos. O CRISP-DM e o KDD exigem decorar suas fases e tarefas específicas. Por outro lado, o estudo de algoritmos de mineração como K-Means, Apriori e árvores de decisão exige compreensão lógica e intuitiva. Embora existam cálculos de suporte e confiança em associação, a cobrança é simples, intuitiva e muito prática por meio de exercícios de prova. Fazer muitas questões ajuda a solidificar o entendimento de cada algoritmo e garante pontos valiosos nas provas.

Prof. Diego Carvalho



MINERAÇÃO DE DADOS

Conceitos Básicos

INCIDÊNCIA EM PROVA: ALTÍSSIMA

MINERAÇÃO DADOS

Conjunto de processos, métodos, teorias, ferramentas e tecnologias utilizadas para explorar, organizar e analisar de forma automática ou semi-automática uma grande quantidade de dados brutos com o intuito de identificar, descobrir, extrair, classificar e agrupar informações implícitas desconhecidas, além de avaliar correlações, tendências e padrões consistentes de comportamento potencialmente úteis – como regras de associação ou sequências temporais – de forma não-trivial por meio de técnicas estatísticas e matemáticas, como redes neurais, algoritmos genéticos, inteligência artificial, lógica nebulosa, análise de conglomerados (clusters), entre outros.

Mineração de dados (Data Mining) é o processo de analisar grandes volumes de dados em busca de padrões consistentes e relevantes para apoiar a tomada de decisões. Utiliza estatística avançada, algoritmos e alto poder computacional para identificar relações não perceptíveis de forma intuitiva.

Um exemplo marcante foi o caso da Cambridge Analytica, que obteve, sem consentimento, dados de mais de 80 milhões de usuários do Facebook. Com essas informações, a empresa criou perfis psicológicos e desenvolveu campanhas publicitárias e políticas altamente direcionadas, com o objetivo de influenciar eleitores, especialmente nas eleições norte-americanas de 2016. O episódio gerou repercussão internacional e levou o CEO do Facebook a prestar esclarecimentos sobre falhas na proteção de dados.

Atualmente, empresas como Google, Amazon, Twitter e Spotify utilizam a mineração de dados de forma contínua. Seu objetivo é compreender o comportamento dos usuários para oferecer recomendações personalizadas, otimizar serviços e antecipar demandas. As aplicações incluem previsão de ausência em voos, identificação de gravidez por padrões de consumo, suporte a diagnósticos médicos e até prevenção de ataques terroristas por meio da análise de deslocamentos geográficos.

O processo consiste em identificar padrões que, muitas vezes, não possuem uma explicação lógica imediata, mas se mostram estatisticamente relevantes. A lógica é semelhante à da meteorologia, que se baseia em dados históricos para prever o clima, sem depender de interpretações subjetivas.

No contexto musical, por exemplo, o Spotify aplica mineração de dados para traçar perfis de usuários e recomendar novas bandas ou estilos semelhantes, mesmo que não haja uma explicação clara para as associações encontradas. Em síntese, trata-se de descrever e prever comportamentos a partir de dados reais, com base em correlações objetivas e não em suposições.

Um exemplo clássico e frequentemente citado sobre correlação de dados é a “lenda” das fraldas e cervejas, surgida nos anos 1990. A história relata que, ao posicionar fraldas próximas a cervejas em supermercados, houve aumento nas vendas combinadas. A lógica seria simples: homens enviados ao mercado para comprar fraldas aproveitavam para adquirir cerveja. Embora essa relação não tenha sido identificada por algoritmos de mineração de dados, mas sim por intuição de um funcionário, o princípio permanece válido e ilustra bem o tipo de padrão que a mineração de dados pode revelar.

Além disso, algumas correlações observadas em bases de dados desafiam explicações claras. Por exemplo, uma rede varejista identificou que a venda de colírios aumentava na véspera de feriados, sem motivo evidente. Mesmo sem compreender a causa, a empresa passou a preparar estoques e promoções com base nesse padrão, utilizando a informação de forma estratégica.



Casos mais robustos também demonstram o impacto da mineração de dados. A empresa de telefonia Sprint, nos Estados Unidos, desenvolveu um modelo preditivo com 61% de acurácia para identificar clientes propensos a cancelar seus contratos. Com campanhas direcionadas, evitou a perda de 120 mil clientes e economizou cerca de 35 milhões de dólares.

No Brasil, a Secretaria de Fazenda do Amazonas (SEFAZ-AM) utilizou técnicas de mineração de dados e descobriu que aproximadamente 80% dos servidores com os maiores salários estavam divorciados, índice muito superior ao de outros órgãos, como a Secretaria de Educação. A análise revelou um padrão, mas a interpretação ficou em aberto, sendo atribuída a fatores como independência financeira ou maior exposição a relacionamentos extraconjugais.

Esses exemplos evidenciam o potencial da mineração de dados para revelar padrões não evidentes e orientar decisões estratégicas. Embora o termo seja usado de forma ampla, ele pode englobar desde análises estatísticas até técnicas avançadas de aprendizado de máquina e otimização. Não há uma separação rígida entre essas disciplinas – todas buscam extrair valor de grandes volumes de dados.

A mineração de dados é comumente associada ao uso de Data Warehouses, que são repositórios centralizados de dados integrados de múltiplas fontes, estruturados para análises e suporte à decisão. Armazenam dados históricos e atuais, permitindo visualizações a partir de diferentes perspectivas. No entanto, a mineração de dados não se limita a esses ambientes.

Com as tecnologias atuais, é possível aplicar mineração de dados em diversas fontes: bancos de dados transacionais, arquivos como CSV, TXT e JSON, Data Lakes, e até dados semiestruturados (como XML) ou não estruturados, incluindo textos, imagens, vídeos e postagens em redes sociais. Nesses casos, os dados exigem pré-processamento – limpeza, padronização e extração de características –, mas continuam sendo fontes viáveis para análise.

Os bancos de dados NoSQL também são amplamente utilizados em mineração de dados. Projetados para lidar com grandes volumes de dados variados e distribuídos, são comuns em aplicações de Big Data, sistemas web e ambientes em tempo real. Eles oferecem flexibilidade para armazenar e consultar dados heterogêneos, o que os torna fontes importantes no cenário atual.

Portanto, a mineração de dados não depende de um único tipo de estrutura de armazenamento. Ela pode integrar informações de bancos relacionais e NoSQL, ampliando o alcance e a profundidade das análises realizadas. Vamos só relembrar rapidamente os tipos de dados:

TIPOS DE DADOS	DESCRIÇÃO
DADOS ESTRUTURADOS	São aqueles que residem em campos fixos de um arquivo (Ex: tabela, planilha ou banco de dados) e que dependem da criação de um modelo de dados, isto é, uma descrição dos objetos juntamente com as suas propriedades e relações.
DADOS SEMI-ESTRUTURADOS	São aqueles que não possuem uma estrutura completa de um modelo de dados, mas também não é totalmente desestruturado. Em geral, são utilizados marcadores (<i>tags</i>) para identificar certos elementos dos dados, mas a estrutura não é rígida.
DADOS NÃO ESTRUTURADOS	São aqueles que não possuem um modelo de dados, que não está organizado de uma maneira predefinida ou que não reside em locais definidos. Eles costumam ser de difícil indexação, acesso e análise (Ex: imagens, vídeos, sons, textos livres, etc).

O mercado atual oferece diversas ferramentas de mineração de dados, muitas baseadas na arquitetura cliente-servidor, em que o processamento ocorre no servidor e o usuário interage por meio de interfaces gráficas intuitivas. Soluções mais recentes são web-based, o que facilita o acesso remoto, uso via dispositivos móveis e colaboração em tempo real, favorecendo organizações descentralizadas e aumentando a escalabilidade.



A análise de dados não estruturados tem ganhado destaque. Esse tipo de dado inclui textos livres, imagens, áudios, vídeos, logs e interações em redes sociais. Para que esses dados possam ser minerados, é necessário um pré-processamento mais complexo, com etapas como transcrição de voz, vetorização textual, reconhecimento de padrões visuais, entre outras. Após essa preparação, é possível aplicar algoritmos como classificadores, agrupadores e modelos preditivos.

A acessibilidade às ferramentas também evoluiu. Muitas plataformas oferecem interfaces de tipo drag and drop, permitindo a construção de fluxos de análise sem necessidade de programação. Isso torna a mineração de dados acessível a profissionais de diferentes áreas. No entanto, conhecimentos técnicos aprofundados permitem maior personalização, integração de fontes diversas, criação de scripts e otimização de modelos.

Destaque também para a Mineração de Processos (Process Mining), que se diferencia da mineração de dados tradicional ao focar na análise de processos de negócios. Utiliza registros de eventos (logs) de sistemas como ERPs e workflows para reconstruir o fluxo real de atividades. Essa abordagem permite identificar gargalos, desvios, ineficiências e oportunidades de melhoria, contribuindo com a gestão de processos baseada em dados concretos.

Mineração de Dados: Descobrindo Padrões Ocultos

Mineração de Dados é o processo de analisar automaticamente grandes volumes de informação para encontrar padrões, tendências e correlações que não são óbvias. Essas descobertas ajudam empresas e organizações a tomar decisões mais inteligentes.

O Que é e Como Funciona?

É o processo de "garimpar" grandes volumes de dados. Busca por padrões, tendências e correlações valiosas que estavam ocultas.



Funciona como a previsão do tempo

Analisa dados históricos para entender o presente e prever cenários futuros.



PASSADO
(Dados Históricos)



FUTURO
(Cenários Previstos)

Não se limita a bancos de dados tradicionais

Pode analisar textos, imagens, vídeos e posts de redes sociais.



TIPOS DE DADOS ANALISADOS

Estruturado	Semi-estruturado	Não Estruturado
Organizado em campos fixos, como tabelas e planilhas.	Não tem estrutura rígida, mas usa marcadores (tags) para organizar.	Sem organização pré-definida, como textos, imagens, áudios e vídeos.



O Poder em Ação: Exemplos Reais


Prevenindo Perdas Milionárias

A Sprint usou dados para prever o cancelamento de clientes e economizou US\$ 35 milhões.



Influenciando o Comportamento Humano

O caso Cambridge Analytica usou dados do Facebook para influenciar a opinião de eleitores.




Tipos de Análise

INCIDÊNCIA EM PROVA: MÉDIA

No contexto de mineração de dados, os tipos de análise representam níveis crescentes de sofisticação analítica, indo da simples compreensão do passado até o apoio direto à tomada de decisão automática. Embora nem todos sejam, estritamente, "mineração" no sentido algorítmico, todos aparecem associados ao ciclo analítico e são recorrentes em provas. Vejamos...



TIPO DE ANÁLISE	PERGUNTA QUE RESPONDE	OBJETIVO PRINCIPAL	FOCO TEMPORAL	EXEMPLOS DE TÉCNICAS
DESCRITIVA	O que aconteceu?	Descrever e resumir dados históricos	Passado	Estatística descritiva, relatórios, dashboards, OLAP
DIAGNÓSTICA	Por que aconteceu?	Identificar causas, relações e padrões	Passado (com investigação)	Correlação, regras de associação, análise de outliers, segmentação
PREDITIVA	O que vai acontecer?	Prever eventos ou comportamentos futuros	Futuro	Classificação, regressão, séries temporais, redes neurais
PRESCRITIVA	O que deve ser feito?	Recomendar ações e apoiar decisões	Futuro (ação)	Otimização, simulação, sistemas de recomendação, regras de decisão



Processo de Descoberta de Conhecimento

INCIDÊNCIA EM PROVA: BAIXA


PROCESSO DE DESCOBERTA DE CONHECIMENTO

Processo sistemático de extrair conhecimento útil, válido e compreensível a partir de grandes volumes de dados. Ele envolve várias etapas organizadas, que vão desde a seleção e pré-processamento dos dados até a aplicação de técnicas de mineração propriamente ditas e a interpretação dos resultados. Seu objetivo é transformar dados brutos em informações relevantes e acionáveis, capazes de apoiar a tomada de decisões e gerar insights estratégicos em diversos contextos, como negócios, saúde, finanças e ciência.

A Mineração de Dados faz parte de um processo muito maior de descoberta de conhecimento chamada KDD (Knowledge Discovery in Databases). Esse processo de descoberta de conhecimento em banco de dados compreende cinco fases: (1) Seleção; (2) Pré-processamento; (3) Transformação; (4) Data Mining;



(5) Interpretação e Avaliação - alguns autores possuem uma classificação um pouco diferente como veremos adiante.




FASE DO KDD	DESCRIÇÃO
SELEÇÃO	Consiste em escolher, entre as fontes disponíveis, os dados relevantes para a análise. Nessa etapa, define-se o subconjunto de dados que será trabalhado, levando em conta os objetivos do negócio e os critérios de interesse.
PRÉ-PROCESSAMENTO	Visa melhorar a qualidade dos dados, corrigindo erros, tratando valores ausentes, eliminando duplicações e padronizando formatos. Essa etapa garante que os dados estejam consistentes e confiáveis para o restante do processo.
TRANSFORMAÇÃO	Adapta os dados para os algoritmos de mineração, convertendo-os em formatos adequados. Envolve normalização, agregações, codificação de variáveis e criação de atributos, facilitando a análise e aumentando a eficácia dos modelos.
MINERAÇÃO DE DADOS	É a etapa central, onde são aplicadas técnicas e algoritmos para extrair padrões, correlações e modelos úteis a partir dos dados transformados. Pode envolver classificação, regressão, agrupamento, associação, entre outros.
INTERPRETAÇÃO/ AVALIAÇÃO	Consiste em analisar, interpretar e validar os padrões extraídos, verificando sua utilidade e consistência com os objetivos do negócio. Envolve também a apresentação dos resultados de forma compreensível para tomada de decisão.


Elmasri e Navathe - renomados autores de bancos de dados - consideram que o Processo de Descoberta de Conhecimento de Banco de Dados contempla, na verdade, seis etapas. Como exemplo, considere um banco de dados de transação mantido por um revendedor de bens de consumo especializados. Suponha que os dados do cliente incluam um nome de cliente, CEP, número de telefone, data de compra, código do item, preço, quantidade e valor total. Vejamos:



PROCESSO DE MINERAÇÃO DE DADOS



ETAPAS	DESCRIÇÃO
SELEÇÃO DE DADOS	Nessa etapa, dados sobre itens específicos ou categorias de itens, ou de lojas em uma região ou área específica do país, podem ser selecionados.
LIMPEZA DE DADOS	O processo de limpeza de dados, então, pode corrigir códigos postais inválidos ou eliminar registros com prefixos de telefone incorretos.
ENRIQUECIMENTO DE DADOS	O enriquecimento normalmente melhora os dados com fontes de informação adicionais. Por exemplo, dados os nomes de cliente e números de telefone, a loja pode adquirir outros dados sobre idade, renda e avaliação de crédito e anexá-los a cada registro.
TRANSFORMAÇÃO OU CODIFICAÇÃO	A transformação de dados e a codificação podem ser feitas para reduzir a quantidade de dados. Por exemplo, os códigos de item podem ser agrupados em relação a categorias de produtos e códigos postais podem ser agregados em regiões geográficas.
MINERAÇÃO DE DADOS	Nessa etapa, as técnicas de mineração de dados são usadas para extrair diferentes regras e padrões. O resultado da mineração pode ser descobrir regras de associação, padrões sequenciais ou árvores de classificação.
RELATÓRIO E EXIBIÇÃO	Os resultados da mineração de dados podem ser informados em diversos formatos, como listagens, saídas gráficas, tabelas de resumo ou visualizações.



Mineração de Texto (Text Mining)

INCIDÊNCIA EM PROVA: BAIXÍSSIMA

MINERAÇÃO DE TEXTO (TEXT MINING)

Processo de extração automática de informações relevantes, padrões ou conhecimentos ocultos a partir de grandes volumes de dados textuais não estruturados, como notícias, e-mails, postagens em redes sociais, documentos corporativos, entre outros. Utiliza técnicas de Processamento de Linguagem Natural (PLN), aprendizado de máquina e estatística para converter o texto bruto em dados estruturados, permitindo tarefas como classificação de documentos, análise de sentimentos, extração de tópicos, resumo automático e reconhecimento de entidades. Seu objetivo é transformar textos em insights úteis para tomada de decisão e apoio estratégico.

A Mineração de Texto (Text Mining) é uma subárea da mineração de dados que analisa textos não estruturados para extrair conhecimento relevante. Trabalha com linguagem natural, o que envolve desafios como ambiguidade, informalidade e variações regionais. O processo começa com a coleta de dados de fontes como e-mails, redes sociais, sites, fóruns e artigos. Em seguida, realiza-se o pré-processamento, com técnicas como remoção de stopwords, tokenização, radicalização e padronização, para preparar o texto para análise.

A representação numérica dos textos é feita por métodos como Bag of Words e TF-IDF, que quantificam a frequência de termos, permitindo o uso de algoritmos estatísticos. Com os dados vetorizados, aplicam-se algoritmos para classificação, agrupamento, análise de sentimentos e detecção de tópicos. Um exemplo comum é a identificação automática de opiniões positivas ou negativas em comentários de clientes.

Análise de sentimentos e detecção de tópicos são aplicações recorrentes, úteis para avaliar percepções, organizar grandes volumes de texto e monitorar tendências. Setores como jurídico, médico e científico utilizam a técnica para análise de documentos técnicos, promovendo automação e eficiência. Apesar do potencial, desafios como ambiguidade semântica, ironia e questões éticas sobre privacidade de dados permanecem.




Diante do crescimento exponencial de conteúdo textual, a Mineração de Texto tornou-se essencial para transformar informação dispersa em conhecimento estratégico e apoiar decisões baseadas em dados.

TÉCNICAS DE MINERAÇÃO DE TEXTO	DESCRIÇÃO
REMOÇÃO DE STOPWORDS	Técnica que elimina palavras muito frequentes e com baixo valor semântico, como artigos, preposições e pronomes, reduzindo ruído no texto e destacando termos mais relevantes para a análise.
STEMMING	Processo que reduz palavras ao seu radical por meio de regras heurísticas, removendo sufixos e prefixos, sem garantir forma linguística correta, com foco em simplificação e ganho computacional.
LEMMATIZAÇÃO	Técnica que converte palavras para sua forma canônica ou lema, considerando o contexto linguístico e a classe gramatical, produzindo resultados semanticamente mais corretos que o stemming.
TOKENIZAÇÃO	Etapa que divide o texto em unidades menores chamadas tokens, como palavras ou termos, permitindo que o conteúdo textual seja representado e processado por algoritmos de mineração e NLP.
REMOÇÃO DE PONTUAÇÃO	Técnica que elimina sinais de pontuação do texto, evitando que caracteres como vírgulas, pontos ou aspas sejam tratados como tokens distintos e interfiram na análise textual.
REMOÇÃO DE CARACTERES ESPECIAIS	Processo que remove símbolos não alfanuméricos, como @, #, %, ou emojis, reduzindo ruídos e padronizando o texto para facilitar a extração de padrões relevantes.
LOWERCASING	Técnica que converte todas as letras do texto para minúsculas, evitando distinções artificiais entre palavras iguais escritas com capitalização diferente e garantindo consistência nos tokens.
REMOÇÃO DE NÚMEROS	Etapa que elimina valores numéricos do texto quando eles não agregam significado semântico à análise, reduzindo dimensionalidade e evitando ruídos em modelos baseados em termos.
CORREÇÃO ORTOGRÁFICA	Técnica que identifica e corrige erros de grafia no texto, melhorando a qualidade dos dados e evitando que variações incorretas de palavras sejam tratadas como termos distintos.




O Processo da Mineração de Texto em 4 Passos



Técnicas e Tarefas

Vamos começar entendendo o que são técnicas e tarefas de mineração de dados. Embora sejam utilizados de forma intercambiável em provas, há uma diferença: tarefas referem-se ao objetivo do processo de mineração (Ex: classificação, regressão, entre outros); já técnicas são os métodos ou algoritmos usados para realizar as tarefas (Ex: árvore de decisão, redes neurais, entre outros). Em outras palavras, uma mesma tarefa pode ser realizada por diversas técnicas diferentes. Conforme é apresentado na imagem a seguir, podemos dividi-las em duas categorias: Preditivas e Descritivas. Vejamos:



As tarefas de análise de dados são geralmente classificadas em dois grandes grupos: preditivas e descritivas. Embora relacionadas, elas possuem finalidades distintas. Tarefas preditivas utilizam dados históricos para estimar eventos futuros. O objetivo é identificar padrões passados e projetar tendências, auxiliando na antecipação de comportamentos. Um exemplo típico é prever a probabilidade de um cliente cancelar um serviço com base em seu histórico de consumo.

Tarefas descritivas, por sua vez, focam na compreensão do presente ou do passado recente. Elas resumem grandes volumes de dados e identificam padrões ou relações entre variáveis, sem



necessariamente fazer previsões. Exemplos incluem segmentação de clientes com características semelhantes ou análise de produtos frequentemente adquiridos em conjunto.

Em síntese, tarefas preditivas respondem à pergunta “o que vai acontecer?”, enquanto as descritivas buscam entender “o que está acontecendo ou o que aconteceu?”. Ambas são essenciais para embasar decisões estratégicas e operacionais com base em dados concretos.

Antes da gente mergulhar nas tarefas em si, vale a pena dar uma passada rápida por três conceitos que são fundamentais quando falamos em inteligência artificial: aprendizado supervisionado, aprendizado não supervisionado e aprendizado por reforço¹. Calma, nada muito complicado – a lógica por trás deles é até bem intuitiva.

No aprendizado supervisionado, os algoritmos são treinados a partir de dados rotulados, nos quais cada instância possui uma entrada e uma saída conhecida, permitindo que o modelo aprenda a mapear atributos para classes ou valores, como ocorre em problemas de classificação e regressão. No aprendizado não supervisionado, não há rótulos disponíveis, e o objetivo é identificar padrões, estruturas ou agrupamentos intrínsecos nos dados, sendo comum em tarefas como clustering e descoberta de associações. Já o aprendizado por reforço baseia-se na interação contínua de um agente com um ambiente, no qual ações são tomadas e avaliadas por meio de recompensas ou punições, permitindo que o agente aprenda, por tentativa e erro, políticas que maximizem o retorno acumulado ao longo do tempo.




TIPO	COM SUPERVISÃO?	ENTRADA	SAÍDA	EXEMPLOS
------	-----------------	---------	-------	----------

¹ Em tese, existe também o aprendizado semi-supervisionado em que parte dos dados são rotulados e parte não são rotulados (isso ajudar a reduzir custos do processo supervisionado).

SUPERVISIONADO	Sim	Dados rotulados	Previsões ou classificações	Spam, previsão de preço, diagnóstico médico
NÃO SUPERVISIONADO	Não	Dados não rotulados	Padrões, clusters, regras	Segmentação de clientes, análise de mercado
APRENDIZADO POR REFORÇO	Feedback	Ações e recompensas	Maximizar recompensa	Jogos, robôs, sistemas de recomendação

As tarefas de Classificação e Regressão são consideradas de aprendizado supervisionado; já as tarefas de Associação, Agrupamento são de aprendizado não-supervisionado².



Detecção de Anomalia

INCIDÊNCIA EM PROVA: BAIXA

DETECÇÃO DE ANOMALIAS

Também conhecida como Anomaly Detection ou Outlier Detection, é uma tarefa da mineração de dados voltada à identificação de padrões ou instâncias que se desviam significativamente do comportamento esperado dos dados. Essas anomalias podem representar eventos raros, erros, fraudes ou comportamentos incomuns que merecem atenção especial. Essa tarefa é particularmente útil em áreas como segurança, saúde, finanças e monitoramento de sistemas.

Antes de abordar as principais tarefas de mineração de dados, é importante destacar a Detecção de Anomalias, uma tarefa auxiliar com grande utilidade prática. Ela consiste em identificar registros que se desviam significativamente do padrão geral dos dados – os chamados “pontos fora da curva”. Essa detecção é essencial para evitar que exceções ou erros prejudiquem análises e modelos preditivos.

Frequentemente aplicada com técnicas de aprendizado não supervisionado, a detecção de anomalias busca padrões incomuns sem a necessidade de rótulos prévios. Esses desvios podem ter origens diversas: naturais (como casos extremos de altura ou variações de patrimônio), erros humanos (como digitação incorreta) ou falhas técnicas (como sensores defeituosos).

Na prática, a detecção pode ser feita por meio de análise de outliers, com o uso de representações gráficas simples, como box-plots e scatter-plots, ou por meio de métricas estatísticas que integram rotinas analíticas. Ressalta-se que uma anomalia não é necessariamente um erro – pode representar um caso raro, porém válido, que não se encaixa nos padrões mais comuns.

Bases de dados reais frequentemente contêm anomalias, que podem indicar fraudes, falhas operacionais, mudanças comportamentais, erros de registro ou alterações no ambiente. Por isso, detectar essas

² Dica: começou com A é uma técnica de aprendizado não supervisionado (Associação, Agrupamento).



ocorrências é fundamental em aplicações como detecção de fraudes, análise de crédito, segurança de redes, diagnóstico de falhas, análise de imagens e vídeos, séries temporais e textos.


Em termos técnicos, o desafio pode ser tratado como um problema de classificação binária, no qual se determina se cada instância é "normal" ou "anômala". Trata-se, portanto, de uma tarefa crítica para garantir a confiabilidade e robustez das análises baseadas em dados.

Detecção de Anomalias: Encontrando o Ponto Fora da Curva

O Que é uma Anomalia?

A busca por dados que fogem do padrão

Identifica eventos raros, erros ou fraudes que merecem atenção especial.



Por que detectar é crucial?



Para evitar que exceções ou falhas distorçam as análises e gerem conclusões erradas.

Origens e Aplicações


De onde surgem as anomalias?



Atividades maliciosas



Erros humanos




Falhas técnicas



Mudanças no ambiente

Como são detectadas?



Onde a técnica é mais usada?




Detecção de fraudes



Análise de crédito



Segurança de redes



Diagnóstico de falhas

Classificação

INCIDÊNCIA EM PROVA: ALTÍSSIMA

CLASSIFICAÇÃO

Consiste em atribuir categorias predefinidas a novos registros com base em um conjunto de dados rotulado. É um processo supervisionado, pois utiliza exemplos já classificados para treinar um modelo que será capaz de prever a classe de novos dados. Por exemplo, em um sistema de crédito, a classificação pode ser usada para categorizar clientes como "adimplente" ou "inadimplente" com base em características como renda, histórico de pagamento e idade. O objetivo é construir um modelo preciso que generalize bem e consiga prever corretamente a classe de entradas futuras.

Classificação é uma das tarefas centrais da mineração de dados. Seu objetivo é categorizar instâncias com base em atributos previamente observados. Trata-se de um problema de aprendizado supervisionado, no qual os dados utilizados no treinamento já estão rotulados, permitindo ao algoritmo aprender padrões e aplicá-los a novos dados.

Um exemplo real e amplamente citado envolve a rede americana Target, que em 2002 desenvolveu um modelo capaz de prever, com alta precisão, se uma cliente estava grávida. Utilizando dados de compras, como cremes sem perfume, suplementos minerais e sabão neutro, a empresa identificou padrões de consumo típicos da gestação. O modelo gerava uma pontuação de probabilidade com base em 25 produtos-chave e, a partir disso, campanhas de marketing foram direcionadas com base nessas previsões.



A história ganhou notoriedade quando a Target enviou cupons de produtos para bebês a uma jovem cuja gravidez ainda não havia sido revelada à família, demonstrando o poder preditivo do modelo. Esse caso ilustra como a classificação, quando bem aplicada, pode antecipar comportamentos com base em dados rotineiros.

O processo de classificação envolve duas fases principais: treinamento e teste. No treinamento, o algoritmo aprende com dados rotulados; na fase de teste, o modelo é avaliado com novos dados para verificar sua capacidade de generalização. O desempenho do modelo é medido por métricas como acurácia, precisão, recall e F1-score.


A classificação pode ser binária (duas classes), multiclasse (mais de duas categorias) ou multilabel (instâncias que pertencem simultaneamente a várias classes). Essa última é comum em contextos como recomendação de conteúdos, onde um mesmo item pode ser associado a múltiplos rótulos. Em síntese, a tarefa de classificação transforma dados históricos em modelos capazes de tomar decisões automatizadas, sendo amplamente utilizada em domínios como marketing, saúde, finanças e segurança.

ALGORITMOS DE CLASSIFICAÇÃO	DESCRIÇÃO
K-NN	Classifica um objeto com base na maioria dos votos da classe dos k vizinhos mais próximos.
ÁRVORES DE DECISÃO	Modelo preditivo que mapeia observações sobre itens a conclusões sobre o item alvo, usando árvores de decisões lógicas.
FLORESTAS ALEATÓRIAS	Método ensemble que constrói múltiplas árvores de decisão durante o treinamento para melhorar a qualidade da classificação.
CLASSIFICADOR NAIVE BAYES	Técnica de classificação baseada no teorema de Bayes com a suposição de independência entre os preditores.
SUPPORT VECTOR MACHINE (SVM)	Método de classificação que encontra o hiperplano que melhor separa diferentes classes de dados em um espaço de características.

O que é Classificação?

Atribuir categorias predefinidas a novos dados.

O modelo aprende com exemplos já rotulados para fazer previsões futuras.



Exemplo de Uso: Análise de Crédito



Um banco pode classificar um cliente como "adimplente" ou "inadimplente".

Estudo de Caso: A Previsão da Target

O Desafio: Identificar clientes grávidas para marketing direcionado.

A meta era enviar cupons de produtos para bebês antes da concorrência.



A Análise: Foram identificados 25 produtos-chave no histórico de compras.



O Resultado: O modelo atribuiu a uma cliente uma pontuação de 87% de probabilidade de estar grávida.



Regressão

INCIDÊNCIA EM PROVA: BAIXA

REGRESSÃO

Consiste em prever valores numéricos contínuos com base em variáveis de entrada. Ao contrário da classificação, que atribui categorias, a regressão estima quantidades, como preços, lucros ou temperaturas. Por exemplo, um modelo de regressão pode prever o valor de um imóvel considerando fatores como localização, número de quartos e metragem. Essa técnica é amplamente usada em cenários onde se deseja identificar tendências, realizar projeções ou estimar resultados quantitativos com base em dados históricos.

A regressão é uma tarefa de mineração de dados relacionada à classificação, mas com foco diferente. Enquanto a classificação prevê categorias, a regressão estima valores numéricos contínuos. Um exemplo prático é o caso da Target, que, além de prever se uma cliente estava grávida, também buscava estimar a fase da gestação para enviar cupons no momento adequado. Isso caracteriza um problema típico de regressão.

O objetivo da regressão é modelar a relação entre variáveis independentes e uma variável dependente numérica, por meio de uma função matemática. O modelo aprende com dados históricos, atribuindo pesos diferentes a cada variável e ajustando uma curva (linear ou não) que representa a tendência geral. O resultado é uma equação que pode ser usada para gerar previsões quantitativas.

Segundo Navathe, a regressão é uma extensão da lógica da classificação. A estrutura do modelo é semelhante: usa-se um conjunto de atributos para prever um resultado. A diferença está no tipo de saída – enquanto a classificação atribui classes discretas, a regressão retorna valores contínuos.

A regressão linear é a forma mais simples e assume uma relação linear entre as variáveis. Existem variantes mais complexas, como a regressão polinomial, regressão por árvores de decisão e modelos baseados em redes neurais ou máquinas de vetor de suporte (SVR), úteis para padrões não lineares e bases com alta complexidade.


O processo é dividido em duas etapas: treinamento, com dados rotulados, e avaliação, onde se verificam a precisão e a capacidade de generalização do modelo por meio de métricas como erro médio absoluto (MAE), erro quadrático médio (MSE) ou R^2 . Também é possível utilizar múltiplas variáveis explicativas, no que se denomina regressão múltipla.

Um exemplo marcante de aplicação de regressão foi o Google Flu Trends. A iniciativa usava dados de buscas por sintomas (como "febre" e "tosse") para estimar, em tempo real, surtos de gripe nos Estados Unidos. O modelo chegou a antecipar picos regionais de casos em até 10 dias antes dos dados oficiais do CDC, com precisão inicial de 97%. Apesar de sua posterior perda de desempenho e descontinuação, o projeto demonstrou o potencial da regressão para prever valores contínuos com base em dados indiretos. Vejamos os principais algoritmos de regressão:

ALGORITMOS DE REGRESSÃO	DESCRIÇÃO
REGRESSÃO LINEAR	Modelo simples que assume uma relação linear entre variáveis independentes e a variável dependente. Produz uma equação do tipo $Y = aX + b$.
REGRESSÃO POLINOMIAL	Estende a regressão linear ao incluir potências dos atributos, permitindo capturar relações não lineares entre variáveis.
SUPPORT VECTOR REGRESSION (SVR)	Versão da SVM adaptada para prever valores contínuos, buscando um hiperplano que fique dentro de uma margem de tolerância dos dados.
REDES NEURAIS (REGRESSÃO)	Utiliza camadas de neurônios para modelar relações complexas e não lineares entre entrada e saída, ideal para grandes volumes de dados.




O Que é Regressão?



Aplicações e Algoritmos Comuns


Caso de Uso: Google Flu Trends

O Google previu surtos de gripe com até 10 dias de antecedência analisando buscas online.




Com o tempo, o modelo passou a superestimar os surtos e o projeto foi descontinuado — um lembrete de que correlação não é causalidade.

Tipos de Algoritmos




Regressão Linear

Modela uma relação linear simples entre variáveis ($Y = aX + b$).



Regressão Polinomial

Captura relações não lineares, permitindo modelar curvas nos dados.



Redes Neurais

Modela relações muito complexas, ideal para grandes volumes de dados.

Análise de Agrupamentos

INCIDÊNCIA EM PROVA: ALTA

ANÁLISE DE AGRUPAMENTOS

Consiste em agrupar objetos semelhantes entre si em conjuntos chamados clusters, de forma que os elementos dentro de um mesmo grupo sejam mais parecidos entre si do que com os de outros grupos. Diferentemente da classificação, ela é uma técnica não supervisionada, pois os dados não vêm previamente rotulados. O objetivo é descobrir padrões ou estruturas ocultas nos dados, como segmentar clientes com base em comportamentos de compra ou identificar áreas com características similares em uma cidade. A clusterização é amplamente utilizada em marketing, biologia, reconhecimento de padrões e análise exploratória de dados.

A análise de agrupamentos, também chamada de clustering, é uma técnica de mineração de dados que visa identificar grupos de registros semelhantes entre si, sem a necessidade de categorias pré-definidas. Por ser baseada em aprendizado não supervisionado, o algoritmo detecta automaticamente padrões e distribui os dados em clusters com alta similaridade interna e baixa similaridade entre grupos distintos.

Diferentemente da classificação, o agrupamento não trabalha com rótulos conhecidos. Seu objetivo é estruturar conjuntos de dados brutos, revelando estruturas ocultas com base em características comuns. Essa técnica é especialmente útil em cenários com grande volume de dados não rotulados, nos quais não é viável classificar os elementos manualmente.


Um exemplo prático é a categorização de produtos em plataformas de e-commerce, como o Mercado Livre. Com milhões de itens sendo anunciados, algoritmos de clustering são usados para agrupar produtos com base em atributos como descrição, marca e categoria, facilitando a navegação e a recomendação personalizada. Inicialmente, define-se o número estimado de grupos e, por meio de iterações, os itens são realocados até que se atinja uma configuração ideal de semelhança interna.

Além do clustering convencional, existe o agrupamento hierárquico, que organiza os dados em uma estrutura de árvore. Ele permite criar níveis de agrupamento — desde grupos amplos até subgrupos mais

específicos – e é eficaz em situações em que há múltiplos níveis de similaridade. Esse método foi utilizado, por exemplo, pela Cambridge Analytica para segmentar eleitores com base em perfis comportamentais e aplicar campanhas políticas altamente personalizadas.

Em síntese, a análise de agrupamentos é uma ferramenta essencial para a descoberta de padrões desconhecidos, contribuindo para segmentações automatizadas e para a organização eficiente de grandes volumes de dados sem necessidade de supervisão humana. Agora veremos algumas classificações de agrupamento, iniciando por agrupamentos determinísticos e agrupamentos estocásticos:

CLASSIFICAÇÃO	DESCRIÇÃO
DETERMINÍSTICO	Métodos determinísticos apresentam sempre o mesmo agrupamento quando executados com os mesmos dados e parâmetros.
ESTOCÁSTICO	Métodos estocásticos podem apresentar diferentes soluções dependendo dos parâmetros e/ou da condição inicial.






Os algoritmos de agrupamento também podem ser divididos em algoritmos hierárquicos ou algoritmos particionais:

CLASSIFICAÇÃO	DESCRIÇÃO
HIERÁRQUICO	Métodos hierárquicos criam uma decomposição hierárquica dos dados, podendo ser divididos em aglomerativos ou divisivos, baseados em como o processo de composição/decomposição é efetuado. Métodos aglomerativos começam com cada objeto pertencendo a um grupo e unem sucessivamente objetos. Métodos divisivos começam com todos os objetos fazendo parte do mesmo grupo e particionam sucessivamente os grupos em grupos menores.
PARTICIONAL	Dado um conjunto com n objetos, um método particional constrói k partições dos dados, sendo que cada partição representa um cluster ($k \leq n$). Dado o número k de partições, um método particional cria uma partição inicial e emprega um algoritmo de

realocação iterativa que tem por objetivo melhorar o particionamento movendo objetos entre grupos (Ex: K-Means e K-Medoids).

Por fim, os algoritmos particionais podem ser divididos em agrupamentos rígidos (Hard Clustering) ou agrupamentos difusos (Fuzzy Clustering³). Vejamos:

ALGORITMOS	DESCRIÇÃO
RÍGIDOS (HARD)	Em algoritmos particionais hard, cada elemento do conjunto de dados pertence exclusivamente a um único cluster. A partição é clara e definida, sem sobreposição entre os clusters. Esses algoritmos são adequados para situações em que a distinção entre os grupos é bem definida e cada ponto de dados pode ser atribuído inequivocamente a um cluster específico.
SUAVES/DIFUSOS (SOFT/FUZZY)	Em algoritmos particionais soft/fuzzy, cada ponto de dados pode pertencer a mais de um cluster, com um grau de associação representado por um valor de probabilidade ou pertinência. Esse tipo de particionamento é útil quando a fronteira entre os clusters não é clara e os dados podem ser melhor representados por uma associação difusa a múltiplos clusters.



ALGORITMOS DE AGRUPAMENTO	DESCRIÇÃO
K-MÉDIAS	Algoritmo que particiona os dados em k grupos com base na distância aos centros dos grupos, minimizando a variância dentro de cada cluster.
K-MEDOIDS	Similar ao k-médias, mas utiliza um ponto de dados real como o centro do cluster para aumentar a robustez a outliers.


³ Também chamado de Soft Clustering (ou Agrupamento Probabilístico).

FUZZY K-MÉDIAS	Variação do k-médias que permite que cada ponto pertença a vários clusters com diferentes graus de pertencimento.
ÁRVORE GERADORA MÍNIMA	Algoritmo que constrói uma árvore que conecta todos os pontos com o menor custo total, podendo ser usada para identificar agrupamentos naturais.
DBSCAN	Algoritmo que identifica clusters baseados em densidade, agrupando pontos que estão próximos uns dos outros com base em um raio e número mínimo de pontos.
SINGLE/COMPLETE LINKAGE	Métodos de agrupamento hierárquico que consideram a menor (<i>single</i>) ou maior (<i>complete</i>) distância entre pontos de dois clusters para fundi-los.

O COEFICIENTE DE SILHOUETTE: UMA MEDIDA DE QUALIDADE DE CLUSTERIZAÇÃO

Avalia quão bem um ponto se encaixa em seu cluster (coesão) em comparação com outros clusters (separação).

COESÃO (a):
Distância Média Intra-Cluster



Quão próximo o ponto está dos outros em seu próprio grupo. **Quanto menor, melhor.**


a

FÓRMULA DO SILHOUETTE (S)

$$S = \frac{b - a}{\max(a, b)}$$

Calculado para cada ponto.
O valor final é a média de todos os pontos.


SEPARAÇÃO (b):
Distância Média do Cluster Mais Próximo



Quão distante o ponto está dos pontos no grupo vizinho mais próximo. **Quanto maior, melhor.**


b

INTERPRETAÇÃO DO RESULTADO



O Coeficiente de Silhouette varia de -1 a +1. Valores mais próximos de +1 indicam uma clusterização de melhor qualidade.

O Que é Análise de Agrupamentos (clustering)?



Aprendizado Não Supervisionado.
O algoritmo descobre os grupos sozinho, sem rótulos ou categorias pré-definidas.




Objetivo: Descobrir Estruturas Ocultas.
Ideal para segmentar clientes, organizar produtos ou identificar perfis de comportamento.

Como Funciona na Prática?



Exemplo: Organização de E-commerce

Organiza automaticamente milhões de produtos (ex: Mercado Livre) analisando seus atributos.



Agrupamento Hierárquico:
Uma Estrutura em Árvore
Cria uma "árvore" de grupos, permitindo uni-los ou dividi-los em subgrupos.



Aplicação de Impacto: Análise de Perfis
A Cambridge Analytica usou a técnica para identificar perfis de eleitores e personalizar mensagens.



Regras de Associação

INCIDÊNCIA EM PROVA: ALTÍSSIMA

REGRAS DE ASSOCIAÇÃO

Consiste em identificar relações frequentes e interessantes entre itens ou atributos em grandes conjuntos de dados. Um exemplo clássico é a análise de mercado, em que se busca descobrir que produtos são comprados juntos com frequência – como a famosa relação entre fraldas e cerveja. Essa tarefa é baseada em medidas como suporte e confiança, que ajudam a avaliar a relevância e a força das associações encontradas. As regras de associação são úteis para recomendações de produtos, detecção de padrões de consumo e estratégias de marketing direcionadas.

A descoberta de regras de associação é uma técnica da mineração de dados voltada à identificação de padrões recorrentes em grandes volumes de dados transacionais. O exemplo mais clássico é o do carrinho de supermercado: ao analisar milhares de transações, é possível encontrar combinações de itens que costumam ser comprados juntos, como leite e açúcar, ou fraldas e cerveja.

Essas regras são expressas no formato $X \rightarrow Y$, onde X é o antecedente e Y o conseqüente. Ambos são conjuntos de itens disjuntos, ou seja, não compartilham elementos ($X \cap Y = \emptyset$). A presença de X em uma transação indica alta probabilidade de ocorrência de Y na mesma transação. Esse tipo de inferência permite automatizar recomendações, otimizar layout de lojas ou estruturar promoções conjuntas com base em comportamento real de consumo.

A técnica é amplamente aplicável em diversos contextos. Por exemplo, clientes que compram sapatos tendem a adquirir bolsas, músicos que compram guitarras frequentemente adicionam palhetas, e assim por diante. As regras de associação permitem descobrir essas correlações implícitas entre itens, aumentando a eficácia de ações comerciais e logísticas.

Além das associações diretas, existem extensões importantes: os padrões sequenciais e os padrões temporais. Os padrões sequenciais consideram a ordem dos eventos. Na área da saúde, por exemplo, é possível identificar que certos procedimentos médicos antecedem o surgimento de condições específicas com alta frequência, revelando sequências clínicas recorrentes.

Já os padrões temporais analisam séries de dados registradas em intervalos regulares, como preços diários de ações ou vendas semanais. O objetivo é detectar comportamentos similares ao longo do tempo, permitindo análises comparativas entre ativos ou produtos com dinâmicas de mercado correlacionadas. As regras de associação são essenciais para revelar correlações ocultas entre itens ou eventos, oferecendo suporte a decisões estratégicas com base em dados objetivos, e contribuindo para o entendimento de padrões de comportamento não evidentes à observação direta.

Além de identificar itens que ocorrem juntos, a mineração de dados também pode revelar itens que raramente aparecem simultaneamente. Para isso, utilizam-se as regras de associação negativas, que apontam relações de exclusão entre conjuntos de itens. Esse tipo de análise é particularmente útil quando combinada com hierarquias de conceitos.

Hierarquias de conceitos estruturam os itens em diferentes níveis de abstração – por exemplo, produto $\rightarrow$ categoria $\rightarrow$ departamento. Essa estrutura permite generalizar itens específicos, reduzindo a esparsidade dos dados e facilitando a identificação de padrões negativos que, de outra forma, passariam despercebidos.

Uma regra de associação negativa é representada na forma $X \rightarrow \neg Y$, indicando que, quando X ocorre, Y tende a não ocorrer. Por exemplo, pode-se identificar que clientes que compram itens da categoria



“alimentos orgânicos” tendem a não adquirir “produtos ultraprocessados” na mesma transação. Tais padrões evidenciam relações de exclusão ou incompatibilidade de consumo.

O uso de hierarquias introduz conhecimento semântico ao processo de mineração, ampliando o alcance das análises e permitindo a detecção de padrões mais abstratos e relevantes. Para avaliar a qualidade das regras de associação (positivas ou negativas), utilizam-se três principais métricas: suporte, confiança e elevação – que indicam, respectivamente, a frequência, a confiabilidade e o grau de dependência entre os conjuntos envolvidos na regra.

MEDIDAS DE INTERESSE	DESCRIÇÃO
SUORTE/ PREVALÊNCIA	Trata-se da <u>frequência</u> com que um conjunto de itens específicos ocorrem no banco de dados, isto é, o percentual de transações que contém todos os itens em um conjunto. Em termos matemáticos, a medida de suporte para uma regra $X \rightarrow Y$ é a frequência em que o conjunto de itens aparece nas transações do banco de dados. Um suporte alto nos leva a crer que os itens do conjunto X e Y costumam ser comprados juntos, pois ocorrem com alta frequência no banco (Ex: 70% das compras realizadas em um mercado contém arroz e refrigerante).
CONFIANÇA/ FORÇA	Trata-se da <u>probabilidade</u> de que exista uma relação entre itens. Em termos matemáticos, a medida de confiança para uma regra $X \rightarrow Y$ é a força com que essa regra funciona. Ela é calculada pela frequência dos itens Y serem comprados dado que os itens X foram comprados. Uma confiança alta nos leva a crer que exista uma alta probabilidade de que se X for comprado, Y também será (Ex: existe uma probabilidade de 70% de que clientes que comprem fraldas também comprem cerveja).
ELEVAÇÃO/ LIFT	Trata-se da <u>medida de força</u> da associação entre os conjuntos de itens, indicando o quanto a ocorrência do consequente é influenciada pela presença do antecedente, de forma independente da frequência absoluta dos itens. Ele é calculado como $Lift(X \rightarrow Y) = Confiança(X \rightarrow Y) \div Suporte(Y)$, sendo que: $Lift > 1$ indica que a ocorrência de X aumenta a probabilidade de ocorrência de Y; $Lift = 1$ indica independência estatística entre os conjuntos de itens; e $Lift < 1$ indica que a ocorrência de X reduz a probabilidade de ocorrência de Y.

Vamos ver um exemplo de cálculo de suporte e confiança porque esse conteúdo será importante para entender o funcionamento dos algoritmos de regras de associação. Vejamos a tabela a seguir:

- TRANSAÇÃO 1: 🍎 🍺 🍷 🥥
- TRANSAÇÃO 2: 🍎 🍺 🍷
- TRANSAÇÃO 3: 🍎 🍺
- TRANSAÇÃO 4: 🍎 🍏
- TRANSAÇÃO 5: 🍷 🍺 🍷 🥥
- TRANSAÇÃO 6: 🍷 🍺 🍷
- TRANSAÇÃO 7: 🍷 🍺
- TRANSAÇÃO 8: 🍷 🍏

REGRA DE ASSOCIAÇÃO: {MAÇÃ → CERVEJA}

Para realizar a medida de suporte, basta calcular a razão da sua frequência pela quantidade de transações. A maçã aparece em 4 das 8 transações e a cerveja aparece em 6 das 8 transações:

$$\text{Suporte} \{ \text{🍏} \} = \frac{4}{8} = 0,50$$




$$\text{Suporte} \{ \text{Cerveja} \} = \frac{6}{8} = 0,75$$

Para realizar a medida de confiança, basta calcular em quantas dessas quatro transações ocorreu cerveja como consequente. Como cerveja aparece em 3 das 4 transações, temos confiança de 75%.

$$\text{Confiança} \{ \text{Maçã} \rightarrow \text{Cerveja} \} = \frac{\text{Suporte} \{ \text{Maçã}, \text{Cerveja} \}}{\text{Suporte} \{ \text{Maçã} \}} = \frac{3}{4} = 0,75$$

Para realizar a medida de elevação, compara-se a confiança da regra com o suporte do consequente (Cerveja), verificando a correlação entre eles:


$$\text{Elevação} \{ \text{Maçã} \rightarrow \text{Cerveja} \} = \frac{\text{Confiança} \{ \text{Maçã}, \text{Cerveja} \}}{\text{Suporte} \{ \text{Cerveja} \}} = \frac{3/4}{6/8} = \frac{0,75}{0,75} = 1,00$$



ALGORITMOS DE ASSOCIAÇÃO	DESCRIÇÃO
APRIORI	Algoritmos que exploram relações de associação entre itens em grandes bancos de dados de transações, utilizando um enfoque iterativo baseado em limiares de suporte e confiança para encontrar conjuntos de itens frequentes.
FP-GROWTH	Melhoria do Apriori que utiliza uma estrutura de dados chamada FP-Tree para compactar o banco de dados de transações, reduzindo significativamente a necessidade de varreduras completas do banco de dados e melhorando a eficiência.



REGRAS DE ASSOCIAÇÃO: DESCOBRINDO PADRÕES OCULTOS EM DADOS



CRISP-DM

INCIDÊNCIA EM PROVA: ALTA

CRISP-DM

Metodologia amplamente adotada para conduzir projetos de mineração de dados de forma estruturada e eficiente. Ele é dividido em seis fases principais: entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem, avaliação e implantação. Cada fase orienta o time de dados desde a definição dos objetivos de negócio até a entrega de resultados práticos e aplicáveis, promovendo uma abordagem iterativa e flexível. O CRISP-DM é especialmente valorizado por sua neutralidade em relação a ferramentas e setores, sendo aplicável a uma grande variedade de contextos analíticos.

Na área de tecnologia da informação, há uma forte ênfase na organização por processos. Diversas metodologias amplamente utilizadas – como PMBOK (gerenciamento de projetos), BABOK (análise de negócios), ITIL (serviços de TI), CMMI (qualidade de software) e COBIT (governança) – são estruturadas com base em processos bem definidos e boas práticas.

Com essa lógica, também foi desenvolvido um modelo específico para orientar projetos de mineração de dados: o CRISP-DM (Cross Industry Standard Process for Data Mining). Trata-se de uma metodologia padronizada, criada a partir da experiência de especialistas do setor, com o objetivo de sistematizar e tornar mais eficiente a condução de projetos de mineração em diversos contextos organizacionais.

Segundo definição oficial, o CRISP-DM é um modelo de processo industrial, independente de ferramentas, voltado para tornar os projetos de mineração de dados mais rápidos, baratos, confiáveis e gerenciáveis. Aplicável tanto a grandes quanto a pequenos projetos, ele promove a reutilização de boas práticas, contribuindo para a padronização e controle das atividades envolvidas.


O modelo é de uso livre (não proprietário), o que permite sua adoção por qualquer organização sem necessidade de licenciamento. Estruturalmente, o CRISP-DM é composto por seis fases principais que



formam um ciclo de vida iterativo, ou seja, as etapas podem ser revisitadas conforme o andamento e os resultados do projeto exigirem ajustes. Assim, ele se estabelece como uma referência sólida para orientar projetos de mineração de dados de forma estruturada e eficiente.

As seis fases do CRISP-DM não precisam ser seguidas de forma rígida ou linear. Embora o modelo defina etapas bem estruturadas, seu principal diferencial está na flexibilidade. O processo é iterativo e cíclico, permitindo que o profissional retorne a fases anteriores conforme novas informações surgem ou ajustes se tornam necessários.


O diagrama oficial do CRISP-DM ilustra essa dinâmica com múltiplas setas entre as fases, representando os fluxos mais comuns entre as etapas durante a execução de um projeto. O círculo que envolve todo o processo reforça essa característica cíclica, indicando que a mineração de dados é uma atividade contínua, com revisões e aprimoramentos frequentes ao longo do ciclo de vida do projeto.



ETAPAS	OBJETIVO PRINCIPAL	DESCRIÇÃO
ENTENDIMENTO DO NEGÓCIO	Alinhar o projeto aos objetivos reais da organização	Definição do problema, metas, critérios de sucesso, restrições e expectativas. Escolha das tarefas de mineração mais adequadas ao objetivo do negócio.
ENTENDIMENTO DOS DADOS	Compreender a natureza e a qualidade dos dados disponíveis	Coleta inicial, exploração dos dados, análises descritivas, identificação de valores ausentes, outliers, inconsistências e avaliação da relevância das variáveis.
PREPARAÇÃO DOS DADOS	Construir o conjunto de dados final para modelagem	Limpeza, integração, transformação, seleção de atributos, engenharia de variáveis e organização dos dados. Etapa iterativa e mais demorada do projeto.



CONSTRUÇÃO DO MODELO	Criar modelos analíticos a partir dos dados preparados	Aplicação de algoritmos de mineração (classificação, regressão, clustering, associação), ajuste de parâmetros e divisão em conjuntos de treino e teste.
TESTE E AVALIAÇÃO	Verificar se o modelo atende aos objetivos do negócio	Avaliação com métricas técnicas e análise crítica dos resultados, validação com especialistas de negócio e decisão sobre ajustes ou aprovação do modelo.
IMPLANTAÇÃO (IMPLEMENTAÇÃO)	Gerar valor prático para a organização	Integração do modelo aos sistemas, entrega de relatórios ou dashboards, monitoramento contínuo, documentação, treinamento de usuários e manutenção do modelo.



QUESTÕES COMENTADAS

1. (CEBRASPE / MPE-CE - 2025) Julgue o seguinte item, relativo a técnicas de visualização de dados em business intelligence, a data lakes e a regras de associação em mineração de dados.

Em mineração de dados, as regras de associação podem ser utilizadas para identificar combinações recorrentes entre argumentos jurídicos e decisões judiciais, revelar padrões entre tipos de ação e desfechos processuais, e auxiliar na recomendação de precedentes com base em casos semelhantes.

Comentários:

As regras de associação em mineração de dados são eficazes para identificar padrões e relações entre dados, como argumentos jurídicos e decisões judiciais, permitindo a análise de precedentes e a previsão de desfechos processuais.

Gabarito: Correto

2. (CEBRASPE / EMBRAPA - 2025) A respeito do tratamento e análise de grandes volumes de dados, julgue o item que se segue.

A mineração de dados pode ser aplicada para a identificação de padrões de associação, como a regra "se X, então Y", frequentemente utilizada em análise de cestas de compras.

Comentários:

A mineração de dados realmente permite a identificação de padrões de associação, como a regra "se X, então Y", que é amplamente utilizada na análise de cestas de compras para entender comportamentos de compra e recomendações de produtos.

Gabarito: Correto

3. (CEBRASPE / EMBRAPA - 2025) Julgue o item seguinte, a respeito das estruturas de dados e de bancos de dados e da análise de dados.

Na análise de dados, algoritmos de aprendizado de máquina realizam todas as etapas do processo, eliminando a necessidade de qualquer intervenção humana na interpretação dos resultados.

Comentários:

Embora algoritmos de aprendizado de máquina possam automatizar muitas etapas da análise de dados, a interpretação dos resultados ainda requer intervenção humana para contextualização e tomada de decisões informadas.

Gabarito: Errado

4. (CEBRASPE / EMBRAPA - 2025) Julgue o item seguinte, a respeito das estruturas de dados e de bancos de dados e da análise de dados.

No processo de análise de dados, uma das etapas é a análise exploratória, que visa à identificação de padrões e possíveis tendências.

Comentários:

A análise exploratória de dados é uma etapa fundamental que permite aos analistas identificar padrões, tendências e anomalias nos dados, facilitando a compreensão e a formulação de hipóteses para análises posteriores.

Gabarito: Correto

5. (CEBRASPE / BDMG - 2025) Relativamente aos conceitos de CRISP-DM, MLOps e Python, julgue o seguinte item.

No CRISP-DM, a etapa de data understanding inclui a construção e a validação de modelos preditivos, garantindo que os resultados estejam alinhados aos objetivos do negócio.

Comentários:

A etapa de Data Understanding no CRISP-DM foca na coleta, exploração e compreensão dos dados, não na construção e validação de modelos preditivos, que ocorrem nas etapas posteriores do processo.

Gabarito: Errado

6. (CEBRASPE / ANM - 2025) Julgue o item a seguir, relativo ao modelo CRISP-DM (cross industry standard process for data mining).

Compreensão do negócio, compreensão dos dados, preparação dos dados, modelagem, avaliação e implantação são as fases do modelo CRISP-DM, e, nesse modelo, as fases devem ser seguidas de maneira estritamente sequencial, sem a possibilidade de iterações ou retrocessos.

Comentários:

O modelo CRISP-DM permite iterações e retrocessos entre suas fases, pois a compreensão do negócio e dos dados pode levar a ajustes na preparação e modelagem, garantindo um processo mais flexível e adaptável às necessidades do projeto.

Gabarito: Errado

7. (CEBRASPE / ANM - 2025) A respeito de overfitting e underfitting, de deep learning e de métodos de data mining, julgue o item que se segue.

A regressão é o método de data mining usado para prever valores contínuos como, por exemplo, previsão de vendas, preços de ações, identificação de transações fraudulentas, entre outros.

Comentários:

A regressão é uma técnica de data mining amplamente utilizada para prever valores contínuos, como vendas e preços, pois modela a relação entre variáveis independentes e dependentes, permitindo previsões precisas.

Gabarito: Correto

8. (CEBRASPE / ANM - 2025) A respeito de overfitting e underfitting, de deep learning e de métodos de data mining, julgue o item que se segue.

Para reconhecer padrões de ocorrência que se repetem em determinados conjuntos de dados, como, por exemplo, padrões de consumo, é usado o método de data mining denominado associação.

Comentários:

O método de associação em data mining é utilizado para identificar padrões frequentes e relações entre variáveis em grandes conjuntos de dados, como padrões de consumo, sendo fundamental para a análise de comportamento do consumidor.

Gabarito: Correto

9. (CEBRASPE / ANM - 2025) Julgue o item a seguir, relativo às tecnologias CSV e JSON, à Linguagem SQL e ao modelo CRISP-DM.

No modelo CRISP-DM, durante a fase de evaluation (avaliação), os resultados do modelo são comparados com os objetivos do negócio para determinar sua eficácia e adequação.

Comentários:

Na fase de avaliação do modelo CRISP-DM, é fundamental comparar os resultados obtidos com os objetivos do negócio. Essa análise garante que o modelo atenda às expectativas e requisitos definidos, assegurando sua eficácia e aplicabilidade.

Gabarito: Correto

10.(CEBRASPE / ANM - 2025) Julgue o item a seguir, relativo às tecnologias CSV e JSON, à Linguagem SQL e ao modelo CRISP-DM.

Durante a fase de data preparation (preparação dos dados) do modelo CRISP-DM, é necessário que todos os dados sejam normalizados e transformados em variáveis numéricas, independentemente de sua natureza original, para facilitar a análise posterior.

Comentários:

A normalização e transformação de dados em variáveis numéricas não é uma exigência universal na fase de preparação de dados do CRISP-DM. Dependendo da análise, dados categóricos podem ser mantidos ou transformados de outras formas, como codificação.

Gabarito: Errado

11.(CEBRASPE / TRF - 6ª REGIÃO - 2025) A respeito de data mart e data mining, julgue o item a seguir.

O uso de data mining permite, por exemplo, que uma empresa de varejo descubra padrões de compra ocultos em grandes volumes de dados, permitindo que a empresa crie promoções direcionadas ou ajuste o leiaute da loja para aumentar as vendas.

Comentários:

O data mining é uma técnica que analisa grandes volumes de dados para identificar padrões e tendências. No contexto de uma empresa de varejo, isso possibilita a criação de promoções personalizadas e a otimização do espaço da loja, aumentando a eficácia das vendas.

Gabarito: Correto

12.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Acerca de data mining e data mart, julgue o item subsequente.

A técnica de clustering (agrupamento), em data mining, é utilizada para classificar dados em categorias predefinidas, facilitando a análise de grandes volumes de dados.

Comentários:

A técnica de clustering não classifica dados em categorias predefinidas, mas sim agrupa dados semelhantes sem rótulos, permitindo a descoberta de padrões e insights em grandes volumes de dados.

Gabarito: Errado

13.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Em relação às fases do CRISP-DM, julgue o próximo item.

A fase 7 do CRISP-DM indica que o processo de construção do armazém de dados correspondente deve ser revisado em função das atualizações dos dados.

Comentários:

A fase 7 do CRISP-DM é a "Implementação", que se refere à aplicação dos modelos desenvolvidos e não à construção do armazém de dados. A revisão do armazém de dados ocorre em outras etapas, como na manutenção e atualização dos dados.

Gabarito: Errado

14.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Em relação às fases do CRISP-DM, julgue o próximo item.

Na fase de modelagem do CRISP-DM, além da divisão de dados em treinamento, testes e validação, são escolhidos os algoritmos que podem ser testados e utilizados de acordo com o tipo de exploração dos dados desejada.

Comentários:

Na fase de modelagem do CRISP-DM, realmente ocorre a seleção de algoritmos apropriados para o problema em questão, além da divisão dos dados em conjuntos de treinamento, teste e validação, visando otimizar a performance do modelo.

Gabarito: Correto

15.(CEBRASPE / STJ - 2024) Data mining é o processo de descobrir padrões e informações valiosas em grandes conjuntos de dados, a partir da utilização de técnicas estatísticas, de aprendizado de máquina e de inteligência artificial.

Comentários:

O enunciado descreve com precisão o conceito de data mining, que envolve a extração de padrões e informações relevantes de grandes volumes de dados utilizando técnicas de estatística, aprendizado de máquina e inteligência artificial.

Gabarito: Correto

16.(CEBRASPE / TC-DF - 2024) Julgue o item subsecutivo, referentes a mineração de dados.

A mineração de dados é o processo de descoberta de padrões e de outras informações valiosas de grandes conjuntos de dados.

Comentários:

A mineração de dados realmente envolve a extração de padrões e informações significativas a partir de grandes volumes de dados, utilizando técnicas estatísticas e algoritmos para identificar tendências e insights valiosos.

Gabarito: Correto

17.(CEBRASPE / TC-DF - 2024) Julgue o item subsecutivo, referentes a mineração de dados.

Na modelagem da metodologia CRISP-DM, métodos como validação cruzada e métricas de desempenho são empregados para se avaliar o quão bem os modelos se saem em dados não vistos.

Comentários:

A metodologia CRISP-DM não utiliza a validação cruzada como parte de sua estrutura. Ela se concentra em etapas como entendimento do negócio, preparação dos dados e modelagem, mas a validação cruzada é uma técnica específica de avaliação de modelos, não uma etapa da metodologia.

Gabarito: Errado

18.(CEBRASPE / CTI - 2024) Com base em obtenção, limpeza e pré-processamento de dados, julgue o próximo item.

No processo de análise, as atividades de limpeza, filtragem e estruturação dos dados estão concentradas na etapa de compreensão dos dados.

Comentários:

A etapa de compreensão dos dados envolve a exploração e visualização, enquanto a limpeza, filtragem e estruturação dos dados são atividades da etapa de preparação dos dados, que precede a análise propriamente dita.

Gabarito: Errado

19.(CEBRASPE / CODEVASF - 2024) Em relação a conceitos, fundamentos, características, técnicas e métodos de BI (business intelligence), definição e conceitos de DW (data warehouse) e data mining e arquitetura e aplicações de data warehouse com ETL, julgue o item subsequente.

Data mining consiste em um processo analítico projetado para explorar grandes quantidades de dados em busca de padrões consistentes e(ou) relacionamentos sistemáticos entre variáveis.

Comentários:

O data mining é, de fato, um processo analítico que busca descobrir padrões e relacionamentos em grandes volumes de dados. Essa técnica é fundamental para a extração de conhecimento e insights valiosos a partir de dados complexos.

Gabarito: Correto

20.(CEBRASPE / CODEVASF - 2024) Julgue o próximo item, relativo a conceitos e noções de modelo CRISP-DM, sistemas de suporte a decisão, gestão de conteúdo e aplicações de data warehouse com OLAP.

A preparação de dados, que consiste em analisar a qualidade dos dados de acordo com o problema, explorar os dados e formular as hipóteses, faz parte dos estágios do CRISP-DM.

Comentários:

A preparação de dados no modelo CRISP-DM envolve a transformação e limpeza dos dados, mas a análise da qualidade e a formulação de hipóteses são atividades que ocorrem em etapas posteriores, como a exploração de dados e a modelagem.

Gabarito: Errado

21.(CEBRASPE / CTI - 2024) Com base em obtenção, limpeza e pré-processamento de dados, julgue o próximo item.

As anomalias verificadas em um conjunto de dados devem ser descartadas de modo a se manter a harmonia do conjunto analisado.

Comentários:

A exclusão de anomalias nem sempre é a melhor abordagem, pois elas podem conter informações valiosas sobre padrões ou erros no processo de coleta. A análise deve considerar a natureza das anomalias e seu impacto na interpretação dos dados.

Gabarito: Errado

22.(CEBRASPE / TCE-PR - 2024) Caso se queira analisar a relação entre três variáveis climáticas de uma região no interior do Paraná para prever futuras situações de emergência, então se deve utilizar, para tal fim, a técnica de

- a) sequência de tempo.
- b) análise quantitativa.
- c) análise de regressão.
- d) análise qualitativa.
- e) correlação assíncrona.

Comentários:

(a) Errado. A sequência de tempo é utilizada para analisar dados ao longo do tempo, mas não é a técnica mais adequada para prever situações de emergência com múltiplas variáveis climáticas.

(b) Errado. A análise quantitativa envolve a coleta e análise de dados numéricos, mas não especifica a relação entre variáveis, que é essencial para prever emergências climáticas.

(c) Correto. A análise de regressão é a técnica apropriada para modelar e prever a relação entre múltiplas variáveis, permitindo entender como elas interagem e influenciam situações de emergência.

(d) Errado. A análise qualitativa foca em aspectos não numéricos e subjetivos, não sendo adequada para prever situações de emergência baseadas em dados climáticos quantitativos.

(e) Errado. A correlação assíncrona não é uma técnica reconhecida na análise de dados climáticos e não se aplica ao contexto de previsão de emergências.

Gabarito: Letra C

23.(CEBRASPE / CTI - 2024) Com base em obtenção, limpeza e pré-processamento de dados, julgue o próximo item.

O pré-processamento de dados deve ocorrer em bases de informações não estruturadas, com o objetivo de diminuir a quantidade de dados a serem processados.

Comentários:

O pré-processamento de dados é essencial para transformar informações não estruturadas em um formato mais útil, reduzindo a quantidade de dados irrelevantes e facilitando a análise posterior. Isso melhora a eficiência do processamento.

Gabarito: Correto

24.(CEBRASPE / SEPLAG-CE - 2024) No que se refere a Big Data e analytics, julgue o item a seguir.

Nas técnicas de classificação e clusterização de dados, as classes, ou categorias, devem existir previamente à sua aplicação.

Comentários:

Na classificação, as classes são definidas previamente, mas na clusterização, os dados são agrupados sem categorias pré-estabelecidas, permitindo a descoberta de padrões e estruturas nos dados.

Gabarito: Errado

25.(CEBRASPE / SEPLAG-CE - 2024) No que se refere a Big Data e analytics, julgue o item a seguir.

No CRISP-DM, os modelos de dados são definidos na etapa de preparação de dados, com a utilização de técnicas de machine learning.

Comentários:

No CRISP-DM, a definição dos modelos de dados ocorre na etapa de modelagem, não na preparação de dados. A preparação é focada na limpeza e transformação dos dados, enquanto a modelagem utiliza técnicas de machine learning para criar os modelos.

Gabarito: Errado

26.(CEBRASPE / ANTT - 2024) No que se refere a deep learning e mineração de dados, julgue o item subsequente.

A mineração de dados é comumente classificada por sua capacidade de realizar determinadas tarefas, entre as quais está a estimação, que, embora similar à classificação, é usada quando o registro é identificado por um valor numérico e não um categórico.

Comentários:

A afirmação descreve corretamente a mineração de dados, onde a estimativa é utilizada para prever valores numéricos, diferenciando-se da classificação, que lida com categorias. Essa distinção é fundamental na aplicação de técnicas de aprendizado de máquina.

Gabarito: Correto

27.(CEBRASPE / ANAC - 2024) No que se refere a modelagem dimensional, mineração de dados e big data, julgue o item subsequente.

No modelo CRISP-DM, a fase de preparação dos dados é caracterizada por atividades como análise da qualidade dos dados, exploração dos dados, geração dos primeiros insights e formulação de hipóteses.

Comentários:

A fase de preparação dos dados no modelo CRISP-DM envolve a limpeza, transformação e seleção dos dados, mas não inclui a geração de insights ou formulação de hipóteses, que ocorrem em fases posteriores.

Gabarito: Errado

28.(CEBRASPE / CTI - 2024) Julgue o item a seguir que tratam de extração e representação de conhecimento.

■

Em mineração de dados, interpretação e explanação consiste em filtrar o conjunto de dados por meio de mecanismo que varia de acordo com a técnica de mineração utilizada.

Comentários:

A interpretação e explanação em mineração de dados não se limitam a filtrar dados, mas envolvem a análise e a apresentação dos resultados obtidos, visando extrair conhecimento útil e compreensível a partir dos dados processados.

Gabarito: Errado

29.(CEBRASPE / CTI - 2024) Considerando processos de análise e mineração de dados, julgue o item subsequente.

Em data mining, um mesmo processo de análise de dados pode utilizar bancos de dados relacionais ou NoSQL, mas não simultaneamente.

Comentários:

Em data mining, é possível utilizar bancos de dados relacionais e NoSQL simultaneamente, dependendo das necessidades do projeto e das características dos dados, permitindo uma análise mais abrangente e eficaz.

Gabarito: Errado

30.(CEBRASPE / CTI - 2024) Considerando processos de análise e mineração de dados, julgue o item subsequente.

Em data mining, a técnica de associação é uma função que determina o coeficiente de afinidade entre certos eventos.

Comentários:

A técnica de associação em data mining, como o algoritmo Apriori, identifica padrões que mostram a relação entre eventos, calculando a afinidade entre eles, como em cestas de compras, onde produtos são frequentemente comprados juntos.

Gabarito: Correto

LISTA DE QUESTÕES

- 1. (CEBRASPE / MPE-CE - 2025) Julgue o seguinte item, relativo a técnicas de visualização de dados em business intelligence, a data lakes e a regras de associação em mineração de dados.**

Em mineração de dados, as regras de associação podem ser utilizadas para identificar combinações recorrentes entre argumentos jurídicos e decisões judiciais, revelar padrões entre tipos de ação e desfechos processuais, e auxiliar na recomendação de precedentes com base em casos semelhantes.

- 2. (CEBRASPE / EMBRAPA - 2025) A respeito do tratamento e análise de grandes volumes de dados, julgue o item que se segue.**

A mineração de dados pode ser aplicada para a identificação de padrões de associação, como a regra "se X, então Y", frequentemente utilizada em análise de cestas de compras.

- 3. (CEBRASPE / EMBRAPA - 2025) Julgue o item seguinte, a respeito das estruturas de dados e de bancos de dados e da análise de dados.**

Na análise de dados, algoritmos de aprendizado de máquina realizam todas as etapas do processo, eliminando a necessidade de qualquer intervenção humana na interpretação dos resultados.

- 4. (CEBRASPE / EMBRAPA - 2025) Julgue o item seguinte, a respeito das estruturas de dados e de bancos de dados e da análise de dados.**

No processo de análise de dados, uma das etapas é a análise exploratória, que visa à identificação de padrões e possíveis tendências.

- 5. (CEBRASPE / BDMG - 2025) Relativamente aos conceitos de CRISP-DM, MLOps e Python, julgue o seguinte item.**

No CRISP-DM, a etapa de data understanding inclui a construção e a validação de modelos preditivos, garantindo que os resultados estejam alinhados aos objetivos do negócio.

- 6. (CEBRASPE / ANM - 2025) Julgue o item a seguir, relativo ao modelo CRISP-DM (cross industry standard process for data mining).**

Compreensão do negócio, compreensão dos dados, preparação dos dados, modelagem, avaliação e implantação são as fases do modelo CRISP-DM, e, nesse modelo, as fases devem ser seguidas de maneira estritamente sequencial, sem a possibilidade de iterações ou retrocessos.

7. (CEBRASPE / ANM - 2025) A respeito de overfitting e underfitting, de deep learning e de métodos de data mining, julgue o item que se segue.

A regressão é o método de data mining usado para prever valores contínuos como, por exemplo, previsão de vendas, preços de ações, identificação de transações fraudulentas, entre outros.

8. (CEBRASPE / ANM - 2025) A respeito de overfitting e underfitting, de deep learning e de métodos de data mining, julgue o item que se segue.

Para reconhecer padrões de ocorrência que se repetem em determinados conjuntos de dados, como, por exemplo, padrões de consumo, é usado o método de data mining denominado associação.

9. (CEBRASPE / ANM - 2025) Julgue o item a seguir, relativo às tecnologias CSV e JSON, à Linguagem SQL e ao modelo CRISP-DM.

No modelo CRISP-DM, durante a fase de evaluation (avaliação), os resultados do modelo são comparados com os objetivos do negócio para determinar sua eficácia e adequação.

10.(CEBRASPE / ANM - 2025) Julgue o item a seguir, relativo às tecnologias CSV e JSON, à Linguagem SQL e ao modelo CRISP-DM.

Durante a fase de data preparation (preparação dos dados) do modelo CRISP-DM, é necessário que todos os dados sejam normalizados e transformados em variáveis numéricas, independentemente de sua natureza original, para facilitar a análise posterior.

11.(CEBRASPE / TRF - 6ª REGIÃO - 2025) A respeito de data mart e data mining, julgue o item a seguir.

O uso de data mining permite, por exemplo, que uma empresa de varejo descubra padrões de compra ocultos em grandes volumes de dados, permitindo que a empresa crie promoções direcionadas ou ajuste o leiaute da loja para aumentar as vendas.

12.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Acerca de data mining e data mart, julgue o item subsequente.

A técnica de clustering (agrupamento), em data mining, é utilizada para classificar dados em categorias predefinidas, facilitando a análise de grandes volumes de dados.

13.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Em relação às fases do CRISP-DM, julgue o próximo item.

A fase 7 do CRISP-DM indica que o processo de construção do armazém de dados correspondente deve ser revisado em função das atualizações dos dados.

14.(CEBRASPE / TRF - 6ª REGIÃO - 2025) Em relação às fases do CRISP-DM, julgue o próximo item.

Na fase de modelagem do CRISP-DM, além da divisão de dados em treinamento, testes e validação, são escolhidos os algoritmos que podem ser testados e utilizados de acordo com o tipo de exploração dos dados desejada.

15.(CEBRASPE / STJ - 2024) Data mining é o processo de descobrir padrões e informações valiosas em grandes conjuntos de dados, a partir da utilização de técnicas estatísticas, de aprendizado de máquina e de inteligência artificial.

16.(CEBRASPE / TC-DF - 2024) Julgue o item subsecutivo, referentes a mineração de dados.

A mineração de dados é o processo de descoberta de padrões e de outras informações valiosas de grandes conjuntos de dados.

17.(CEBRASPE / TC-DF - 2024) Julgue o item subsecutivo, referentes a mineração de dados.

Na modelagem da metodologia CRISP-DM, métodos como validação cruzada e métricas de desempenho são empregados para se avaliar o quão bem os modelos se saem em dados não vistos.

18.(CEBRASPE / CTI - 2024) Com base em obtenção, limpeza e pré-processamento de dados, julgue o próximo item.

No processo de análise, as atividades de limpeza, filtragem e estruturação dos dados estão concentradas na etapa de compreensão dos dados.

19.(CEBRASPE / CODEVASF - 2024) Em relação a conceitos, fundamentos, características, técnicas e métodos de BI (business intelligence), definição e conceitos de DW (data warehouse) e data mining e arquitetura e aplicações de data warehouse com ETL, julgue o item subsequente.

Data mining consiste em um processo analítico projetado para explorar grandes quantidades de dados em busca de padrões consistentes e(ou) relacionamentos sistemáticos entre variáveis.

20.(CEBRASPE / CODEVASF - 2024) Julgue o próximo item, relativo a conceitos e noções de modelo CRISP-DM, sistemas de suporte a decisão, gestão de conteúdo e aplicações de data warehouse com OLAP.

A preparação de dados, que consiste em analisar a qualidade dos dados de acordo com o problema, explorar os dados e formular as hipóteses, faz parte dos estágios do CRISP-DM.

21.(CEBRASPE / CTI - 2024) Com base em obtenção, limpeza e pré-processamento de dados, julgue o próximo item.

As anomalias verificadas em um conjunto de dados devem ser descartadas de modo a se manter a harmonia do conjunto analisado.

22.(CEBRASPE / TCE-PR - 2024) Caso se queira analisar a relação entre três variáveis climáticas de uma região no interior do Paraná para prever futuras situações de emergência, então se deve utilizar, para tal fim, a técnica de

- a) sequência de tempo.
- b) análise quantitativa.
- c) análise de regressão.
- d) análise qualitativa.
- e) correlação assíncrona.

23.(CEBRASPE / CTI - 2024) Com base em obtenção, limpeza e pré-processamento de dados, julgue o próximo item.

O pré-processamento de dados deve ocorrer em bases de informações não estruturadas, com o objetivo de diminuir a quantidade de dados a serem processados.

24.(CEBRASPE / SEPLAG-CE - 2024) No que se refere a Big Data e analytics, julgue o item a seguir.

Nas técnicas de classificação e clusterização de dados, as classes, ou categorias, devem existir previamente à sua aplicação.

25.(CEBRASPE / SEPLAG-CE - 2024) No que se refere a Big Data e analytics, julgue o item a seguir.

No CRISP-DM, os modelos de dados são definidos na etapa de preparação de dados, com a utilização de técnicas de machine learning.

26.(CEBRASPE / ANTT - 2024) No que se refere a deep learning e mineração de dados, julgue o item subsequente.

A mineração de dados é comumente classificada por sua capacidade de realizar determinadas tarefas, entre as quais está a estimação, que, embora similar à classificação, é usada quando o registro é identificado por um valor numérico e não um categórico.

27.(CEBRASPE / ANAC - 2024) No que se refere a modelagem dimensional, mineração de dados e big data, julgue o item subsequente.

No modelo CRISP-DM, a fase de preparação dos dados é caracterizada por atividades como análise da qualidade dos dados, exploração dos dados, geração dos primeiros insights e formulação de hipóteses.

28.(CEBRASPE / CTI - 2024) Julgue o item a seguir que tratam de extração e representação de conhecimento.

Em mineração de dados, interpretação e explanação consiste em filtrar o conjunto de dados por meio de mecanismo que varia de acordo com a técnica de mineração utilizada.

29.(CEBRASPE / CTI - 2024) Considerando processos de análise e mineração de dados, julgue o item subsequente.

Em data mining, um mesmo processo de análise de dados pode utilizar bancos de dados relacionais ou NoSQL, mas não simultaneamente.

30.(CEBRASPE / CTI - 2024) Considerando processos de análise e mineração de dados, julgue o item subsequente.

Em data mining, a técnica de associação é uma função que determina o coeficiente de afinidade entre certos eventos.

GABARITO

1. CORRETO
2. CORRETO
3. ERRADO
4. CORRETO
5. ERRADO
6. ERRADO
7. CORRETO
8. CORRETO
9. CORRETO
10. ERRADO
11. CORRETO
12. ERRADO
13. ERRADO
14. CORRETO
15. CORRETO
16. CORRETO
17. ERRADO
18. ERRADO
19. CORRETO
20. ERRADO
21. ERRADO
22. LETRA C
23. CORRETO
24. ERRADO
25. ERRADO
26. CORRETO
27. ERRADO
28. ERRADO
29. ERRADO
30. CORRETO

ESSA LEI TODO MUNDO CONHECE: PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.



1 Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.



2 Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).



3 Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).



4 Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).



5 Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).



6 Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).



7 Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.



8 O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.