

## **Aula 16 - Prof. Diego Carvalho e Renato da Costa**

*SEFAZ-AL (Auditor Fiscal da  
Administração Tributária Estadual -  
AFTE) Inteligência Artificial e Ciência de  
Dados - 2026 (Pós-Edital)*  
**Autor:  
Diego Carvalho, Emannuelle  
Gouveia Rolim, Equipe Informática  
e TI, Renato da Costa**

11 de Setembro de 2026

## Índice

|                                                    |    |
|----------------------------------------------------|----|
| 1) Big Data - Teoria .....                         | 3  |
| 2) Big Data - Questões Comentadas - CEBRASPE ..... | 18 |
| 3) Big Data - Lista de Questões - CEBRASPE .....   | 31 |



## APRESENTAÇÃO


Prezados,

Para quem estuda em pré- edital e tem tempo, o ideal é realizar um estudo completo e incremental. Inicie pelas premissas fundamentais de Big Data, conhecidas como os 5 Vs, que possuem incidência altíssima nas provas, seguido pelos conceitos básicos e a dataficação, cuja cobrança também é alta. Na sequência, consolide a parte de armazenamento (as diferenças entre Data Lakes e Data Warehouses) e as análises do Analytics. Por fim, mesmo com incidência baixa, passe pelas arquiteturas e os tipos de dados.

Se você está no pós- edital e com o tempo escasso, foque obrigatoriamente nos tópicos de alta e altíssima relevância. Estude as premissas dos 5 Vs (volume, velocidade, variedade, veracidade e valor) e os conceitos essenciais de Big Data e dataficação. Dedique um tempo também para diferenciar Data Warehouse de Data Lake e dominar os quatro tipos de análise em Analytics. Por outro lado, pode descartar sem medo as etapas do pipeline de dados e os papéis de equipe, que têm incidência baixíssima.

Em termos de esforço e facilidade, a teoria inicial de Big Data, os tipos de dados e as premissas dos 5 Vs são assuntos fáceis, porém exigem bastante decoreba dos conceitos e de definições de bancas. A parte de armazenamento e os tipos de análises do Analytics têm complexidade mediana; demandam entender a lógica de funcionamento e as diferenças sutis entre os termos, como análise preditiva versus prescritiva. Já as arquiteturas Lambda e Kappa exigem mais raciocínio, sendo os tópicos mais complexos.

Prof. Diego Carvalho



BIG DATA: A arte de complicar o óbvio.



# BIG DATA

## Conceitos Básicos

INCIDÊNCIA EM PROVA: ALTA

### BIG DATA

Trata-se de um termo que se refere ao grande volume de dados – estruturados, semiestruturados e não estruturados – que são gerados continuamente em alta velocidade por diversas fontes, como redes sociais, dispositivos móveis, sensores, sistemas transacionais, entre outros. Esses dados são tão volumosos e complexos que as ferramentas tradicionais de processamento e análise não são capazes de lidar eficientemente com eles. O seu objetivo principal é transformar essa massa de dados em informação útil para tomada de decisão.

Você sabe o que é um cookie? Na internet, cookies são pequenos arquivos que ficam armazenados no seu navegador e guardam um monte de informações: desde preferências e histórico de navegação até login automático. Tudo isso para quê? Para que os sites “lembrem” de você, melhorem sua experiência e, claro, mostrem anúncios mais certos.

Quer ver como isso funciona na prática? Sabe aquele vídeo do YouTube que mal começou e já veio aquele anúncio chato interrompendo tudo? Ou então, quando você está no Instagram e aparece exatamente aquela propaganda sobre algo que você estava pesquisando dias atrás? Pois é, isso tem tudo a ver com cookies. Mas não só com eles – também entra na conta o tipo de perfil que você segue, os sites que você acessa, sua idade, sexo, localização... uma verdadeira radiografia digital sua.



Agora, deixa eu contar uma história que aconteceu comigo. Pink Floyd é – evidentemente – a melhor banda de todos os tempos. Eu escuto direto, sigo páginas da banda, leio sobre os integrantes... enfim, consumo tudo. Aí, um belo dia, estou lá de bobeira no Instagram e dou de cara com um anúncio de uma camiseta que dizia: “Nunca subestime um fã de Pink Floyd que tenha nascido em outubro.” Galera, juro que na hora eu pensei: “Não é possível... que coincidência é essa?”. Não só porque Pink Floyd é a minha banda favorita, mas também porque... adivinha em que mês eu nasci? Outubro! Na minha inocência, achei que o universo estava me mandando um presente. Mas aí a ficha caiu: não tinha nada de místico ou mágico naquilo. O Instagram simplesmente juntou o que ele já sabia sobre mim, isto é, que eu gosto da banda e que nasci em outubro. Pronto, ele criou o anúncio absolutamente perfeito para mim!

Em outras palavras, esse é o tal “poder” dos cookies e do rastreamento de dados. Eles permitem que a internet praticamente adivinhe quem você é, o que você gosta, o que está pensando em comprar – e às vezes até antes de você mesmo perceber. E não é exagero: quase tudo o que você faz online deixa um rastro. Clicou num anúncio? Tem registro. Ignorou o anúncio? Também tem. Assistiu um vídeo no YouTube – tipo aquelas aulas do Estratégia Concursos? Pois é, registrado!

Agora, pensa comigo: temos atualmente mais de 8 bilhões de pessoas no mundo. Imagina o tanto de dado que é gerado a cada segundo só por essas pessoas estarem simplesmente existindo, interagindo, usando um app, acessando um site, comprando uma coisa ou outra. É tanto dado, mas tanto dado, que a gente teve que inventar um nome para isso: Big Data.





O que é Big Data, afinal? É essa quantidade absurdamente imensa de informações geradas todos os dias, vindas de tudo quanto é lugar: redes sociais, sensores, celulares, bancos, empresas, aplicativos... tudo. Agora olha que curioso: parece recente, mas esse termo foi utilizado pela primeira vez nos anos 90, pelo pesquisador John Mashey, para falar justamente sobre dados tão grandes e tão complexos que os sistemas antigos não conseguiam mais dar conta de processar tudo.

Hoje em dia, a gente conta com tecnologias específicas só para lidar com isso – e, olha, elas fazem muito mais do que organizar bagunça. Elas ajudam empresas e gestores a tomar decisões melhores, mais rápidas e bem embasadas. Porque, no final das contas, dado bem usado é poder! Bem, não existe uma definição singular de Big Data, mas vejamos algumas:

#### **POR OXFORD ENGLISH DICTIONARY**

Big Data é um dado de grande tamanho, tipicamente ao nível que sua manipulação e gerenciamento apresenta desafios significativos a logística.

#### **POR DUMBILL E EDD**

Big Data é o dado que excede a capacidade de processamento convencional dos sistemas de bancos de dados.

#### **POR MAYER-SCHÖNBERGER E CUKIER'S**

Big Data é a habilidade da sociedade de aproveitar a informação por novas maneiras para produzir introspecção úteis ou bens e serviços de valor significativo.

#### **POR INTERNATIONAL DATA CORPORATION**

Big Data é uma nova geração de tecnologias e arquiteturas, projetadas economicamente para extrair valor de volumes muito grandes e vastos de dados, permitindo alta velocidade de captura, descoberta e análise.

Note que o conceito de Big Data é bem amplo! Basicamente, ele se refere a conjuntos de dados tão grandes – ou tão complexos – que os programas tradicionais simplesmente não dão conta. E não é só o tamanho que é problema... os desafios incluem de tudo um pouco: analisar os dados, capturá-los, organizá-los, pesquisar dentro deles, compartilhá-los, armazená-los, transferi-los, visualizá-los – e, claro, lidar com todas as questões de privacidade que vêm junto.

Além disso, o termo muitas vezes é usado também quando falamos em análise preditiva e outras técnicas avançadas que ajudam a extrair valor real desses dados todos. Sabe aquela ideia de prever tendências, comportamentos e riscos? Pois é, Big Data tem tudo a ver com isso! Agora, quer saber qual é a minha definição favorita? É essa aqui: Big Data é o processo de capturar, gerenciar e analisar um volume gigantesco de dados – que podem ser estruturados ou não – e que, justamente por isso, não conseguem ser tratados pelos bancos de dados relacionais tradicionais.

Na prática, estamos falando de informações vindas de vídeos digitais, imagens, sensores espalhados por aí, arquivos de log de sistemas... enfim, todo tipo de dado que não cabe direitinho em tabelinhas com colunas e linhas. São dados mais "caóticos", por assim dizer, mas com um potencial imenso de revelar padrões, insights e oportunidades – se a gente souber como usá-los. Por falar nisso, vamos definir o que são dados estruturados, semi-estruturados e não-estruturados...

Por fim, no contexto de Big Data, temos o conceito de Datafication (Dataficação). Trata-se basicamente do processo de transformar aspectos da realidade – atividades, comportamentos, eventos e interações – em dados quantificáveis, registráveis e analisáveis. Em outras palavras, é a conversão de fenômenos antes não estruturados ou não mensuráveis em dados digitais que podem ser coletados, armazenados e explorados analiticamente.



A dataficação vai além da simples digitalização. Enquanto digitalizar significa converter algo analógico em formato digital (como escanear um documento), dataficar significa extrair dados de ações e contextos cotidianos, muitas vezes de forma contínua e automatizada. Exemplos clássicos incluem o registro de cliques em sites, interações em redes sociais, dados de localização por GPS, sensores de IoT, logs de sistemas e métricas de uso de aplicativos.

Esse processo é um dos pilares do Big Data, pois amplia significativamente o volume, a variedade e a velocidade dos dados disponíveis. Ao dataficar processos e comportamentos, as organizações passam a ter uma base rica para análises descritivas, preditivas e prescritivas, possibilitando desde a personalização de serviços até a otimização de operações e a criação de modelos de machine learning.

### Saiba mais:

Big Data funciona como um oceano gigantesco de informações que só faz sentido quando temos navios, radares e mapas para explorá-lo.

O oceano representa o enorme volume e a variedade de dados gerados continuamente. As correntes marítimas simbolizam a velocidade com que os dados chegam, muitas vezes de forma contínua. Os navios cargueiros correspondem à ingestão e ao transporte dos dados, trazendo informações de diferentes origens. Os portos e armazéns representam os Data Lakes e repositórios, onde os dados ficam armazenados, mesmo em estado bruto. Os radares e sonares simbolizam o processamento e a análise, que permitem identificar padrões, riscos e oportunidades. Os mapas e rotas traçadas correspondem aos insights, relatórios e modelos analíticos, que transformam dados em conhecimento útil.

Big Data é um oceano de dados: grande, profundo e em constante movimento – só gera valor quando existem ferramentas capazes de navegar, analisar e extrair significado desse volume massivo de informações.

## Desvendando o Big Data: O Oceano de Informações do Século XXI

### O Que é Big Data?

#### Um Volume Massivo de Dados

Gerado continuamente por fontes como redes sociais, sensores e dispositivos móveis.




#### Grande Demais para Ferramentas Comuns

Tão volumoso e complexo que exige tecnologias e arquiteturas específicas para análise.

#### Dataficação: Tudo Vira Dado

O processo de transformar ações do cotidiano (cliques, curtidas, localização) em dados analisáveis.



### Como Funciona na Prática? O Anúncio Perfeito

#### A "Coincidência"

Um fã de Pink Floyd nascido em outubro recebe um anúncio de uma camiseta com essa exata descrição.



Fã de Pink Floyd



#### O Rastreamento por Trás da Mágica

A plataforma conectou o interesse na banda (seguidores, publicações) com dados pessoais (mês de nascimento).

### Qual o Objetivo Final?

#### Transformar Dados Brutos em Decisões Inteligentes

A meta é extrair informações úteis que orientem ações e estratégias.



#### Deixamos Rastros Digitais

Quase tudo que fazemos online é registrado, desde um clique até o tempo gasto em um vídeo.



#### Alcançar Vantagem Competitiva

Empresas usam a análise para aumentar a eficiência e obter resultados superiores aos concorrentes.



#### Um Oceano de Oportunidades

Assim como um oceano, Big Data só gera valor com as ferramentas certas para navegar e explorá-lo.

## Premissas

**INCIDÊNCIA EM PROVA: ALTÍSSIMA**

Podemos afirmar que a definição de Big Data pode ser quebrada em cinco dimensões, quais sejam: Volume, Velocidade, Variedade, Veracidade e Valor.

### Volume

Vamos começar falando do “V” mais conhecido do Big Data: Volume. É talvez o mais fácil de entender porque diz respeito, basicamente, à quantidade absurda de dados que a gente gera e consome todos os dias. E não é pouca coisa, não: estamos falando de petabytes, exabytes e até zettabytes! Isso mesmo, são trilhões de trilhões de informações circulando por aí – de redes sociais, celulares, sensores IoT, sites de compras, aplicativos de transporte, sistemas de empresas... enfim, de praticamente tudo.

Veja bem, essa quantidade gigantesca de dados não cabe mais nos bancos tradicionais, sabe aqueles que a gente usava lá no início da computação, com tabelinhas certinhas e organizadas? Eles até funcionam bem para dados estruturados, mas quando falamos de Big Data, a escala é outra. É aí que entram soluções como o Hadoop, o Amazon S3, os bancos NoSQL e os famosos Data Lakes, que são como grandes reservatórios de dados em formatos variados e muitas vezes ainda “crus”.

Agora, tem um detalhe importante: quanto mais dados, mais difícil e caro fica lidar com eles. Você precisa decidir se vai guardar tudo ou só o que realmente importa. Além disso, organizar, limpar, mover, buscar e transformar tudo isso em informação útil pode ser uma tarefa bem complexa. É por isso que o volume influencia diretamente na infraestrutura, no custo e nas estratégias que uma empresa adota para extrair valor desses dados.

Em outras palavras, só ter muito dado não resolve nada. É preciso saber o que fazer com ele. O V de Volume é a fundação do Big Data, mas sozinho não entrega resultado. Ele precisa caminhar junto com os outros “Vs” – que logo mais a gente vai ver – para que, no fim das contas, os dados ajudem a tomar decisões mais inteligentes, descobrir padrões e até antecipar comportamentos dos usuários.

### Velocidade

Vamos agora ao segundo “V” do Big Data: Velocidade. E quando a gente fala em velocidade aqui, não é só sobre rapidez – é sobre um ritmo frenético com que os dados são gerados, transmitidos, processados e analisados. Vivemos em um mundo onde tudo acontece em tempo real: redes sociais, sensores espalhados por aí, sistemas bancários, aplicativos de entrega... tudo produzindo dados o tempo todo, sem parar.

E veja, não é só uma questão de coletar rápido – o ponto principal é processar esses dados enquanto eles ainda estão fresquinhos, gerando valor ali na hora. Pense, por exemplo, em um sistema que detecta fraude em transações bancárias: ele não pode demorar cinco minutos para decidir se um pagamento é suspeito, né? Tem que ser na hora! A mesma lógica vale para recomendação de filmes na Netflix ou alertas em fábricas automatizadas. O dado chega, é processado, e a ação é tomada quase instantaneamente.

Mas... como lidar com esse fluxo contínuo? Aí entram tecnologias específicas, como Apache Kafka, Apache Flink, Apache Storm e outras que trabalham com o chamado stream processing – ou seja, elas analisam os dados enquanto eles estão chegando, diferente do velho processamento em batch, que espera acumular um monte de coisa para depois analisar.



Agora, não pense que é fácil. Trabalhar com velocidade alta exige estrutura parruda, além de estratégias inteligentes para manter a qualidade dos dados, evitar gargalos e responder aos picos de uso. É um desafio técnico, sim, mas também estratégico. Afinal, quem consegue agir mais rápido, geralmente leva vantagem no mercado, antecipa necessidades dos clientes e toma decisões mais certeiras. Em suma, a Velocidade é o que permite que as empresas não apenas saibam o que está acontecendo, mas que consigam agir enquanto a coisa ainda está acontecendo. E isso, convenhamos, faz toda a diferença.

## Variedade

Chegou a hora de falar sobre o “V” de Variedade! A variedade tem a ver com a diversidade absurda de tipos e fontes de dados que a gente lida hoje em dia. Lembra daquela época em que tudo ficava arrumadinho em tabelas, com coluninhas bem organizadas? Pois é, esse tempo já ficou para trás. Hoje, os dados vêm de todo canto – e em todo tipo de formato que você possa imaginar.

Tem texto de e-mail, áudio de WhatsApp, vídeos do TikTok, imagens de câmeras de segurança, PDFs, posts no Twitter, registros de sensores, arquivos XML, planilhas do Excel, cliques em sites, e por aí vai. Tudo isso é dado, só que espalhado, bagunçado e com formatos completamente diferentes. E aí vem a parte que deixa tudo mais desafiador: como lidar com essa salada de dados? Veja só:

Dados estruturados são os dados bonitinhos, que cabem direitinho em uma tabela de banco de dados (Ex: nome, idade, endereço, etc); dados semiestruturados são aqueles que têm um certo formato, mas são mais flexíveis, como arquivos XML ou JSON; por fim, dados não estruturados são aqueles dados rebeldes – vídeos, áudios, imagens, texto livre, com ruídos ou praticamente tudo que não cabe numa tabela tradicional.

Agora, pense no seguinte: uma empresa quer entender o que os clientes estão achando de um novo produto. Ela pode cruzar as vendas (dados estruturados) com os comentários nas redes sociais (dados não estruturados) e os cliques no site (dados semiestruturados). Juntando tudo isso, ela consegue uma visão muito mais completa e estratégica do comportamento do consumidor.

Por outro lado, lidar com tanta variedade exige ferramentas robustas. Os bancos de dados tradicionais, sozinhos, não dão conta do recado. É aí que entram soluções como NoSQL, Hadoop, Spark, Data Lakes e tantas outras tecnologias que ajudam a organizar esse caos criativo de informações. No fim das contas, a Variedade é o que permite que o Big Data capte não só números, mas também emoções, contextos e comportamentos. É isso que transforma dado em visão estratégica.

## Veracidade

Bora falar de mais um “V” importantíssimo do Big Data: o V de Veracidade. Esse aqui é o que separa o joio do trigo – porque não adianta nada ter montanhas de dados se a gente não pode confiar neles, certo? Veja bem, no mundo do Big Data, os dados vêm de tudo quanto é canto: redes sociais, sensores, sites, aplicativos. E nem sempre essas fontes são controladas ou confiáveis. Aí entra o desafio: como saber se o que a gente tem na mão é verdadeiro, atualizado e útil? Spoiler: não é simples!

Muitas vezes, os dados estão incompletos, bagunçados, repetidos ou até errados mesmo. Se você usa esse tipo de dado para tomar uma decisão, pode acabar fazendo uma escolha catastrófica. Imagine uma empresa que confia em um relatório cheio de informações erradas para lançar um produto? Isso é capaz de gerar um prejuízo absurdo.

É por isso que a veracidade exige atenção redobrada com a qualidade da informação. Isso significa aplicar técnicas de limpeza de dados, eliminar duplicidades, identificar inconsistências, verificar a origem





da informação e entender o contexto em que ela foi coletada. Sensores com defeito? Bots em redes sociais? Cadastros mal preenchidos? Tudo isso precisa ser filtrado ou corrigido.

Ferramentas de estatística e inteligência artificial (como aprendizado de máquina) ajudam nessa missão, encontrando padrões e alertando quando algo parece “fora da curva”; mas, no fim das contas, o segredo está em tratar os dados com responsabilidade, com curadoria e regras claras. Então, anota aí: não é só quantidade, nem velocidade, nem variedade. Sem veracidade, Big Data vira Big Problema. Informação errada pode ser mais perigosa do que nenhuma informação – e ninguém quer isso, né?

## Valor

Chegamos ao “V” que talvez seja o mais importante de todos: Valor. Cá entre nós, para que serve um caminhão de dados se você não consegue tirar nada de útil deles? É como ter uma biblioteca inteira e nunca abrir um livro. O verdadeiro poder do Big Data está justamente em gerar valor real – seja economizando dinheiro, melhorando a experiência do cliente, aumentando a eficiência de um processo ou tomando decisões mais certeiras. Sem isso, tudo vira só um monte de dados ocupando espaço e consumindo energia.

Vamos pensar em exemplos do dia a dia: quando um banco detecta uma transação estranha no seu cartão e bloqueia em tempo real, é o Big Data gerando valor. Quando a Netflix te sugere um filme que tem tudo a ver com o seu gosto, também. Ou quando uma loja ajusta o estoque porque sabe exatamente o que vai vender no fim de semana. Tudo isso é dado que virou ação inteligente.

Mas calma: extrair valor não é automático. Requer estratégia, boas perguntas, ferramentas certas e gente capacitada para interpretar o que os dados estão dizendo. É tipo garimpar: você tem que saber onde cavar e o que procurar – senão só encontra pedra. E olha só: nem todo dado vale ouro. Às vezes, o que realmente importa está em 10% do que você coleta. Por isso, o V de Valor também serve para lembrar a gente de priorizar – focar no que faz sentido, no que traz retorno, no que ajuda a tomar decisão.

Resumindo? Big Data sem valor é só gasto. O diferencial está em transformar dado cru em insight útil. E isso é o que separa quem só coleciona informação de quem realmente inova.

| PREMISSAS         | DESCRIÇÃO                                                              |
|-------------------|------------------------------------------------------------------------|
| <b>VOLUME</b>     | Quantidade massiva de dados gerados continuamente.                     |
| <b>VELOCIDADE</b> | Rapidez com que os dados são criados, processados e analisados.        |
| <b>VARIEDADE</b>  | Diferentes tipos e formatos de dados, estruturados ou não.             |
| <b>VERACIDADE</b> | Qualidade e confiabilidade das informações coletadas.                  |
| <b>VALOR</b>      | Utilidade e relevância dos dados para tomada de decisões estratégicas. |

### Saiba mais:

Uma boa forma de entender os 5 V's do Big Data é imaginar o trabalho de um órgão de controle que precisa fiscalizar toda a movimentação financeira de um país ao longo do tempo.

Volume pode ser comparado à quantidade de documentos fiscais e contábeis que chegam diariamente ao órgão auditor. São milhões de notas fiscais eletrônicas, declarações de imposto, folhas de pagamento, contratos, transferências bancárias e registros previdenciários. O desafio não é apenas guardar tudo isso, mas conseguir analisar um acervo gigantesco sem perder eficiência.



Velocidade diz respeito à rapidez com que essas informações são geradas e precisam ser analisadas. Transações ocorrem em tempo real, impostos são recolhidos continuamente e pagamentos são feitos a cada segundo. Se a auditoria analisar os dados apenas meses depois, o dano já pode ter ocorrido. Por isso, a fiscalização moderna precisa processar dados quase no mesmo ritmo em que eles surgem.


Variedade aparece na diversidade de fontes e formatos usados na auditoria. Há dados estruturados, como declarações fiscais e balancetes; dados semiestruturados, como arquivos XML de notas fiscais; e dados não estruturados, como e-mails, relatórios em PDF, mensagens ou imagens de documentos digitalizados. Todos precisam ser considerados para uma visão completa da situação fiscal.

Veracidade representa a confiabilidade das informações analisadas. Em auditoria, dados inconsistentes, incompletos ou manipulados podem levar a conclusões erradas. É preciso verificar a origem, cruzar bases diferentes, validar registros e identificar fraudes ou erros, garantindo que as análises se apoiem em informações corretas e confiáveis.

Por fim, Valor é o resultado prático da análise dos dados. Não adianta coletar milhões de registros se isso não gera benefícios reais, como a identificação de sonegação, desperdício de recursos públicos, fraudes em contratos ou melhoria da arrecadação. O verdadeiro valor do Big Data, na auditoria governamental, está em transformar dados brutos em ações concretas que aumentem a eficiência, a transparência e a justiça fiscal.

## Desvendando o Big Data: Os 5 Vs Essenciais

Big Data é definido por cinco dimensões principais, conhecidas como os "5 Vs". Cada "V" representa um desafio e uma oportunidade únicos, e juntos eles explicam por que tecnologias e estratégias especiais são necessárias para transformar grandes volumes de informação em decisões inteligentes.



Informação importante: inicialmente, considerava-se que o Big Data era baseado em apenas três V's (Volume, Velocidade Variedade). Com o tempo, surgiram também Veracidade e Valor - essa é a formação mais aceita atualmente. No entanto, alguns autores e especialistas passaram a propor outros "Vs" que aprofundam ou complementam os desafios e dimensões da análise de dados em larga escala (caem muito raramente em prova, mas vamos ver rapidamente).



| OUTRAS PREMISSAS       | DESCRIÇÃO                                                                                                                                                                                                                                                        |
|------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>VARIABILIDADE</b>   | Refere-se às mudanças imprevisíveis nos dados ao longo do tempo, incluindo variações na estrutura e oscilações na velocidade do fluxo, com picos e vales de chegada, exigindo técnicas adaptativas de análise e processamento.                                   |
| <b>VISUALIZAÇÃO</b>    | O grande volume de dados requer ferramentas gráficas para interpretação eficiente. Dashboards, gráficos e mapas interativos transformam dados complexos em insights acessíveis, ajudando na tomada de decisões estratégicas em diferentes setores.               |
| <b>VIABILIDADE</b>     | Analisa se um projeto de Big Data é sustentável em termos de custos, infraestrutura e retorno esperado. Um sistema viável precisa equilibrar armazenamento, processamento e análise para garantir eficiência operacional e valor para a organização.             |
| <b>VALIDADE</b>        | Diz respeito à qualidade e precisão dos dados coletados. Informações imprecisas ou desatualizadas podem comprometer análises e decisões, exigindo validação rigorosa, limpeza de dados e métodos de governança para garantir confiabilidade.                     |
| <b>VULNERABILIDADE</b> | Refere-se aos riscos de segurança, privacidade e manipulação dos dados. A proteção contra ataques, vazamentos e uso indevido exige criptografia, controle de acesso e conformidade com regulamentações como LGPD e GDPR.                                         |
| <b>VOLATILIDADE</b>    | Define a velocidade com que os dados se tornam obsoletos ou perdem relevância. Em cenários dinâmicos, informações podem mudar rapidamente, exigindo análise contínua para manter a atualidade dos modelos preditivos e decisões estratégicas.                    |
| <b>VISCOSIDADE</b>     | Refere-se à resistência dos dados ao fluxo ao longo da arquitetura de informação. Dados com alta viscosidade são difíceis de mover, integrar ou transformar entre sistemas, aumentando latência, complexidade operacional e impactando a agilidade das análises. |



## Armazenamento de Dados

INCIDÊNCIA EM PROVA: MÉDIA

Ao longo dos anos, a maneira como as organizações armazenam e analisam dados passou por mudanças profundas – e, convenhamos, bastante fascinantes. Essas transformações não surgiram por acaso: foram impulsionadas pela evolução tecnológica, pelo crescimento exponencial da quantidade de dados gerados e pela demanda crescente por análises mais rápidas, detalhadas e estratégicas.

No início dessa trajetória, o cenário era bem mais simples. Os dados eram guardados em arquivos planos, como CSVs, XMLs, arquivos de texto ou até formatos proprietários de sistemas antigos. Eram soluções baratas e fáceis de implementar, mas extremamente vulneráveis. Um simples erro manual podia comprometer todo o conjunto de dados. Não havia garantias reais de consistência, integridade ou escalabilidade – era tudo muito artesanal.

Com o aumento do volume de informações e, principalmente, das transações, tornou-se indispensável adotar soluções mais sólidas. É nesse contexto que surgem os Sistemas Gerenciadores de Bancos de Dados (SGBDs). Eles trouxeram avanços importantes, como controle de concorrência, integridade referencial, normalização e o uso de uma linguagem padrão que se tornou dominante: o SQL. Isso elevou significativamente a confiabilidade do armazenamento de dados.

Apesar desse avanço, os bancos relacionais tradicionais apresentavam limitações importantes. Eles foram projetados para lidar com operações do dia a dia, o chamado processamento transacional, e não para análises históricas complexas, como grandes agregações ou comparações entre longos períodos. Em outras palavras, eram eficientes para registrar o presente, mas pouco adequados para compreender o passado de forma analítica.

Foi justamente para suprir essa lacuna que surgiu o conceito de Data Warehouse (DW). A proposta era criar um ambiente dedicado à análise, capaz de integrar dados vindos de múltiplas fontes, padronizá-los e organizá-los de forma consistente. O foco deixava de ser apenas o armazenamento e passava a ser a geração de informação de qualidade para apoio à decisão.

Com o amadurecimento desse modelo, percebeu-se que diferentes áreas da empresa tinham necessidades analíticas específicas. O setor de recursos humanos, por exemplo, analisava dados bem distintos daqueles usados pelo time comercial. Assim nasceram os Data Marts: subconjuntos temáticos do Data Warehouse, geralmente alinhados à abordagem de Kimball. Eles foram fundamentais para consolidar o chamado BI 1.0, marcado por relatórios estruturados, consultas SQL e dashboards confiáveis.

Entretanto, o cenário mudou novamente com a explosão dos dados não estruturados. Logs de aplicações, interações em redes sociais, dados de sensores, imagens, vídeos e áudios passaram a fazer parte do cotidiano das empresas. Nesse contexto, os Data Warehouses tradicionais começaram a mostrar rigidez excessiva. Surge então o conceito de Data Lake, cuja proposta é armazenar grandes volumes de dados em seu formato bruto, sem exigir modelagem prévia – o famoso schema-on-read. Essa flexibilidade trouxe grandes oportunidades, mas também riscos: sem governança adequada, o Data Lake pode rapidamente se transformar em um “pântano de dados”, difícil de entender e pouco confiável.

Para equilibrar a organização do Data Warehouse com a flexibilidade do Data Lake, surgiu o conceito de Data Lakehouse. Essa abordagem busca unificar o melhor dos dois mundos, combinando controle transacional, catálogos, versionamento e governança com a liberdade necessária para trabalhar com dados brutos, ciência de dados e machine learning. Trata-se de um passo importante rumo a ambientes analíticos mais maduros e integrados.





A fase mais recente dessa evolução vai além da tecnologia e foca na forma como os dados são organizados dentro das empresas. É o caso do Data Mesh, uma abordagem descentralizada que atribui aos próprios domínios de negócio – como finanças, marketing ou logística – a responsabilidade pelos seus dados. Cada domínio passa a tratar seus conjuntos de dados como produtos, conhecidos como data products, que devem ser confiáveis, acessíveis e interoperáveis, seguindo padrões comuns.

O Data Mesh não substitui arquiteturas anteriores, como Data Warehouses ou Data Lakes. Em vez disso, ele redefine a maneira como esses componentes são organizados e consumidos, priorizando escalabilidade, autonomia e alinhamento com o negócio.

A evolução dos repositórios de dados reflete uma busca contínua por equilíbrio. Partimos de arquivos simples, avançamos para bancos relacionais, evoluímos para Data Warehouses focados em análise, Data Marts especializados, Data Lakes flexíveis, Lakehouses integrados e, mais recentemente, o Data Mesh, que reorganiza tudo sob uma nova lógica. Essas abordagens não se anulam; elas coexistem, formando ecossistemas híbridos que se adaptam ao contexto e ao nível de maturidade de cada organização.

| PERÍODO   | REPOSITÓRIO/<br>ARQUITETURA | CARACTERÍSTICAS                                                                                                                                                                                                              | OBJETIVO<br>PRINCIPAL                                       |
|-----------|-----------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------|
| 1960-1980 | Arquivos Planos             | Dados armazenados em arquivos simples, sem padronização, metadados ou governança. A integração entre sistemas era difícil, pois cada aplicação mantinha formatos próprios, gerando redundância e inconsistências frequentes. | Registro operacional, armazenamento básico.                 |
| 1970-1990 | SGBD Relacional             | Introdução do modelo relacional com SQL, garantindo integridade via propriedades ACID. Bancos como Oracle, DB2 e Informix permitiram padronização, consultas estruturadas e gestão consistente de dados corporativos.        | Processamento transacional (OLTP) e consultas estruturadas. |
| 1990-2005 | Data Warehouse              | Repositório corporativo com dados integrados, limpos e historizados, alimentado via ETL. Oferece estrutura consolidada e estável para análises estratégicas e relatórios confiáveis de longo prazo.                          | BI corporativo, consistência e análises estratégicas.       |
| 1995-2005 | Data Marts                  | Subconjuntos temáticos extraídos do DW, geralmente modelados de forma dimensional para acelerar análises. Permitem entregas rápidas e foco nas necessidades específicas de cada área de negócio.                             | Análises departamentais, desempenho analítico.              |
| 2000-2010 | ODS                         | Repositório intermediário com dados integrados e atualizações frequentes, contendo pouca história. Serve como camada operacional com visão quase em tempo real para alimentar sistemas e apoiar decisões do dia a dia.       | Visão integrada e quase em tempo real para operações.       |
| 2010-2018 | Data Lake                   | Armazena dados brutos estruturados, semiestruturados e não estruturados em larga escala. Baseado em Hadoop, HDFS e processamento distribuído, permite flexibilidade com schema-on-read para análises avançadas e ML.         | Flexibilidade, Big Data, ciência de dados e ML.             |
| 2018+     | Data Lakehouse              | Une governança e confiabilidade do DW com a flexibilidade do Data Lake. Inclui tabelas ACID, versionamento, catálogos e processamento unificado, permitindo BI e machine learning no mesmo ambiente.                         | BI + ML no mesmo repositório, unificação de workloads.      |
| 2019+     | Data Mesh                   | Abordagem descentralizada onde domínios tratam dados como produtos, com responsabilidade local e interoperabilidade. Suporta escalabilidade                                                                                  | Escalabilidade organizacional e                             |



organizacional e colaboração por meio de padrões federados. autonomia dos domínios.

### Saiba mais:


A evolução do armazenamento de dados é como a evolução de uma cidade – de casas isoladas até bairros autônomos interligados.

Arquivos são como casas isoladas: cada pessoa guarda seus próprios documentos, sem padrão, sem integração e com difícil compartilhamento. Planilhas funcionam como prédios pequenos de escritórios: organizam melhor as informações, mas ainda são frágeis, limitadas e pouco escaláveis. SGBD Relacional representa o centro urbano planejado: ruas bem definidas, regras claras, integridade e organização estruturada dos dados.

Data Warehouse é o centro administrativo da cidade: reúne dados consolidados, históricos e confiáveis para tomada de decisão estratégica. Data Marts são secretarias especializadas: versões menores do Data Warehouse, focadas em áreas específicas como finanças, RH ou vendas. ODS (Operational Data Store) funciona como um posto de atendimento rápido: dados integrados e atualizados quase em tempo real para operações do dia a dia, sem histórico profundo.

Data Lake é o grande terreno aberto da cidade: armazena tudo – dados estruturados, semiestruturados e não estruturados – mesmo sem saber ainda como serão usados. Data Lakehouse é a modernização do terreno aberto: combina a flexibilidade do Data Lake com a organização e confiabilidade do Data Warehouse. Data Mesh representa uma cidade descentralizada e inteligente: cada bairro (domínio) é dono dos seus dados, com autonomia, padrões compartilhados e interoperabilidade.

## De Arquivos a Malhas de Dados: A Evolução do Armazenamento



## Big Data Analytics

INCIDÊNCIA EM PROVA: MÉDIA

### BIG DATA ANALYTICS

Processo de examinar grandes volumes de dados, estruturados e não estruturados, para identificar padrões, tendências, correlações e insights que apoiem a tomada de decisões estratégicas. Utilizando técnicas avançadas de estatística, aprendizado de máquina e mineração de dados, essa análise vai além das capacidades do Business Intelligence tradicional, permitindo prever comportamentos, detectar anomalias e automatizar ações com base em dados em tempo real. É uma abordagem essencial para empresas que buscam transformar dados massivos em vantagem competitiva e inovação contínua.

Big Data Analytics é o processo de explorar aquele oceano de dados – sim, os famosos dados massivos – com o objetivo de encontrar padrões escondidos, entender comportamentos, prever tendências e, no fim das contas, tomar decisões mais inteligentes. E veja, não estamos falando de uma simples análise de planilhas. Aqui, o buraco é mais embaixo...

Esse tipo de análise vai além das ferramentas tradicionais de BI (Business Intelligence). Em vez de olhar só para o que já aconteceu, o Big Data Analytics se apoia em técnicas como mineração de dados, algoritmos de aprendizado de máquina e processamento distribuído para dar conta dos 5 V's que caracterizam o Big Data: volume, variedade, velocidade, veracidade e valor.

A grande sacada é que ele consegue lidar com diferentes tipos de dados – dos estruturados (como tabelas e bancos relacionais), aos semiestruturados (como arquivos JSON ou XML), até os não estruturados (como vídeos, áudios, textos de redes sociais e logs de sistema). Ou seja, dá para analisar praticamente qualquer coisa que uma organização produza ou colete.

Para isso, entra em cena um arsenal tecnológico de respeito: Hadoop, Spark, Kafka, bancos NoSQL e, claro, as plataformas em nuvem como AWS, Azure e Google Cloud. Ferramentas como Python, R, redes neurais, análise preditiva, clustering e análise em tempo real completam o time. Tudo isso não só para armazenar, mas para transformar dados em conhecimento útil – quase em tempo real, se necessário.

E os benefícios? São muitos. Empresas conseguem operar com mais eficiência, personalizar produtos e serviços, antecipar tendências, detectar fraudes e melhorar a experiência do cliente. Um exemplo prático: redes de varejo analisam o comportamento de compra para oferecer promoções sob medida. Já bancos e fintechs usam o Big Data para identificar transações suspeitas em segundos.

Claro, nem tudo são flores. A qualidade dos dados, por exemplo: se os dados estiverem incompletos, duplicados ou simplesmente errados, o risco de chegar a conclusões equivocadas é alto. Sem falar na questão da governança e segurança – que é crítica, principalmente em setores como saúde e finanças. E, para completar, tudo isso exige uma equipe qualificada: cientistas e engenheiros de dados, analistas de negócios, gente capaz de transformar dados complexos em ações concretas.

Pode afirmar, portanto, que o Big Data Analytics é uma ferramenta poderosa para transformar dados brutos em inteligência de verdade. E em tempos de economia digital, em que a informação vale ouro, essa capacidade analítica não é mais um diferencial – é uma questão de sobrevivência competitiva. Quem domina essa arte sai na frente, reage rápido às mudanças do mercado e toma decisões baseadas em evidências, e não em achismos.

### Tipos de Análise



| TIPO DE ANÁLISE            | DESCRIÇÃO                                                                                                                                                                                                                                                                                                                                                                                                                                          |
|----------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>ANÁLISE DESCRITIVA</b>  | Em vez de se focar no futuro, busca fazer uma fotografia do presente, para que decisões de cunho imediato possam ser tomadas com segurança. Ela trabalha com histórico de dados, cruzando informações com o objetivo de gerar um panorama claro e preciso dos temas relevantes para a empresa no presente momento. Exemplo: por meio do cruzamento de dados, conclui-se que determinada pessoa atualmente é identificada como má pagadora.         |
| <b>ANÁLISE DIAGNÓSTICA</b> | O foco está na relação de causas e consequências percebidas ao longo do tempo, dentro de um determinado tema. Assim, a análise diagnóstica funciona baseada na coleta de dados relacionados a um determinado assunto, cruzando informações com o objetivo de entender quais fatores influenciaram o resultado atual. Exemplo: determinada pessoa nunca havia sido identificada como má pagadora – somente é agora porque ficou viúva recentemente. |
| <b>ANÁLISE PREDITIVA</b>   | Este tipo de análise é o mais indicado para quem precisa prever algum tipo de comportamento ou resultado. Esta técnica busca analisar dados relevantes ao longo do tempo, buscando padrões comportamentais e suas variações de acordo com cada contexto, a fim de prever como será o comportamento de seu público ou mercado no futuro, dadas as condições atuais. Exemplo: quanto estará o valor do dólar no ano que vem?                         |
| <b>ANÁLISE PRESCRITIVA</b> | Segue um modelo similar à Análise Preditiva, no entanto com objetivos ligeiramente diferentes. Em vez de tentar prever um determinado acontecimento, esta análise busca prever as consequências deste acontecimento. Exemplo: dado um aumento do valor do dólar no ano que vem, como isso poderá afetar as importações de matéria prima, consequentemente, o faturamento das vendas de determinada empresa.                                        |

Em análises de dados, especialmente no contexto de Big Data Analytics, é comum que provas explorem a distinção sutil – porém fundamental – entre análise preditiva e análise prescritiva. Embora ambas utilizem modelos estatísticos e técnicas de machine learning, elas respondem a perguntas diferentes e produzem resultados com naturezas distintas.

A análise preditiva tem como objetivo antecipar o que provavelmente vai acontecer. Ela identifica padrões em dados históricos para estimar eventos futuros, como a chance de um cliente cancelar um serviço, a previsão de demanda ou a probabilidade de inadimplência. Seu resultado é uma previsão ou probabilidade, mas não indica, por si só, qual decisão deve ser tomada. Saber que algo vai ocorrer não implica automaticamente saber o que fazer a respeito.

Já a análise prescritiva vai um passo além. A partir das previsões geradas – muitas vezes pela própria análise preditiva – ela recomenda ações concretas para atingir um objetivo específico ou minimizar riscos. Para isso, combina previsões com regras de negócio, simulações, otimização e critérios de decisão. Seu foco não é apenas prever o futuro, mas orientar a tomada de decisão.

A analogia ajuda a fixar a diferença: a análise preditiva diz que vai chover; a análise prescritiva diz para levar o guarda-chuva. A primeira antecipa o fato; a segunda transforma essa antecipação em uma recomendação prática de ação.


Em termos de prova, a chave está em observar o verbo dominante: se a análise estima, prevê ou antecipa, trata-se de preditiva; se ela indica, recomenda, sugere ou otimiza uma decisão, estamos diante de uma análise prescritiva. Essa distinção é recorrente em questões objetivas e discursivas, justamente por exigir atenção ao propósito final da análise.

Uma dúvida comum é sobre a diferença entre Business Intelligence, Big Data Analytics e Data Mining! Alguns autores consideram um é a evolução do anterior, abrangendo mais dados e ferramentas matemáticas/estatísticas; outros afirmam que – na verdade – é tudo a mesma coisa e que possuem nomes diferentes apenas por uma questão de marketing: vende mais dizer que uma ferramenta de software é uma solução de Big Data Analytics do que uma solução de Data Mining. Vejamos...





| CARACTERÍSTICAS               | BUSINESS INTELLIGENCE                                     | BIG DATA ANALYTICS                                                 | DATA MINING                                                        |
|-------------------------------|-----------------------------------------------------------|--------------------------------------------------------------------|--------------------------------------------------------------------|
| <b>OBJETIVO PRINCIPAL</b>     | Apoiar decisões com base em dados históricos consolidados | Explorar e analisar grandes volumes de dados diversos              | Descobrir padrões ocultos e relações em grandes conjuntos de dados |
| <b>TIPO DE DADO</b>           | Geralmente estruturado                                    | Estruturado, semiestruturado e não estruturado                     | Principalmente estruturado, mas pode incluir outros tipos          |
| <b>VOLUME DE DADOS</b>        | Moderado                                                  | Muito alto (Big Data)                                              | Médio a alto                                                       |
| <b>FOCO ANALÍTICO</b>         | Descritivo e diagnóstico (o que aconteceu?)               | Preditivo e prescritivo (o que pode acontecer e o que fazer?)      | Exploratório e preditivo (quais padrões estão escondidos?)         |
| <b>FERRAMENTAS COMUNS</b>     | Power BI, Tableau, QlikView, Excel                        | Hadoop, Spark, NoSQL, Python, R, plataformas em nuvem              | Weka, RapidMiner, Python, R, SAS                                   |
| <b>TECNOLOGIAS ENVOLVIDAS</b> | OLAP, dashboards, relatórios                              | Machine Learning, processamento distribuído, análise em tempo real | Algoritmos (árvore de decisão, redes neurais, k-means, etc)        |
| <b>USUÁRIO FINAL</b>          | Gestores e analistas de negócios                          | Cientistas de dados, engenheiros de dados, times de produto        | Cientistas de dados, analistas especializados                      |
| <b>TEMPO DE ANÁLISE</b>       | Dados históricos e atuais                                 | Dados em tempo real ou históricos massivos                         | Históricos ou em lote, foco em descoberta                          |
| <b>AUTOMAÇÃO DE INSIGHTS</b>  | Baixa                                                     | Alta (com IA e modelos preditivos)                                 | Alta (modelos automatizados para descoberta de padrões)            |
| <b>EXEMPLO DE APLICAÇÃO</b>   | Relatórios de vendas mensais                              | Previsão de rotatividade de clientes com base em comportamento     | Identificação de segmentos de clientes por comportamento comum     |



## QUESTÕES COMENTADAS

### 1. (CEBRASPE / Polícia Federal - 2025) Acerca de segurança da informação, bancos de dados e aprendizado de máquina, julgue o próximo item.

Em geral, projetos de Big Data caracterizam-se por cinco diferentes atributos: valor, variedade, velocidade, veracidade e volume.

#### Comentários:

Os cinco atributos de Big Data são fundamentais: valor refere-se à utilidade dos dados, variedade à diversidade de formatos, velocidade à rapidez de processamento, veracidade à confiabilidade dos dados e volume à quantidade de informações.

**Gabarito:** Correto

### 2. (CEBRASPE / EMBRAPA - 2025) Julgue o item a seguir, a respeito de inteligência artificial, Big Data e data warehouse.

Big Data e data warehouse são técnicas de armazenamento que dispensam a necessidade de descoberta de conhecimento e mineração de dados, e, por isso, a aprendizagem de máquina não se aplica ao contexto de Big Data.

#### Comentários:

Big Data e data warehouse são abordagens complementares que podem ser utilizadas em conjunto com técnicas de descoberta de conhecimento e mineração de dados. A aprendizagem de máquina é aplicável ao contexto de Big Data, permitindo extrair insights valiosos dos dados.

**Gabarito:** Errado

### 3. (CEBRASPE / EMBRAPA - 2025) Julgue o próximo item, a respeito de computação e de programação.

A análise de Big Data lida com dados estruturados, como tabelas e bancos de dados relacionais, mas não considera dados não estruturados, como textos, imagens e vídeos.

#### Comentários:

A análise de Big Data abrange tanto dados estruturados quanto não estruturados. Isso inclui textos, imagens e vídeos, que são essenciais para obter insights mais completos e significativos em diversas aplicações.

**Gabarito:** Errado

**4. (CEBRASPE / EMBRAPA - 2025) Julgue o item subsequente, a respeito de sensoriamento remoto e de sistemas de informação geográfica.**

O uso de plataformas de Big Data em agricultura dispensa algoritmos de aprendizado de máquina, pois a análise estatística tradicional é suficiente para gerar resultados úteis.

**Comentários:**

O uso de plataformas de Big Data na agricultura não dispensa algoritmos de aprendizado de máquina, pois esses algoritmos são essenciais para processar grandes volumes de dados e extrair padrões complexos, superando as limitações da análise estatística tradicional.

**Gabarito:** Errado

**5. (CEBRASPE / Polícia Federal - 2025) Julgue o item subsequente, relativos à teoria da informação e a banco de dados.**

A mineração de dados é uma técnica em que se utilizam exclusivamente algoritmos de aprendizado supervisionado para a identificação de padrões em grandes volumes de dados; no contexto de Big Data, a premissa principal é a utilização de bancos de dados relacionais tradicionais, que são suficientes para o enfrentamento dos desafios de volume, variedade e velocidade característicos desse ambiente.

**Comentários:**

A mineração de dados utiliza tanto algoritmos de aprendizado supervisionado quanto não supervisionado. Além disso, bancos de dados relacionais tradicionais muitas vezes não são suficientes para lidar com os desafios de Big Data, que requerem soluções mais robustas e escaláveis.

**Gabarito:** Errado

**6. (CEBRASPE / TRF - 6ª REGIÃO - 2025) No que se refere à ciência de dados, julgue o item seguinte.**

Em big data, representações visuais, como gráficos e dashboards, permitem que padrões sejam rapidamente identificados.

**Comentários:**

Representações visuais em big data, como gráficos e dashboards, facilitam a identificação de padrões e tendências, permitindo uma análise mais rápida e eficaz dos dados, essencial para a tomada de decisões.

**Gabarito:** Correto

**7. (CEBRASPE / TRF - 6ª REGIÃO - 2025) A respeito de Big Data, julgue o item a seguir.**

Na etapa de ingestão de um pipeline de dados de Big Data, os dados de diversas fontes são coletados e transportados para um armazenamento centralizado.

**Comentários:**

A ingestão de dados em um pipeline de Big Data envolve a coleta de informações de múltiplas fontes, que são então transportadas para um repositório centralizado, permitindo a análise e processamento posterior.

**Gabarito:** Correto

**8. (CEBRASPE / PC-DF - 2025) A respeito de inteligência artificial, de tipos de análise de dados e de Big Data, julgue o item que se segue.**

A veracidade em Big Data reflete o desafio de se assegurar a qualidade e precisão de dados frequentemente confusos, ruidosos e propensos a erros que comprometem sua confiabilidade.

**Comentários:**

A veracidade em Big Data é um dos 5 Vs (Volume, Velocidade, Variedade, Veracidade e Valor) e refere-se à qualidade e precisão dos dados. Dados ruidosos e confusos podem comprometer análises, tornando a veracidade um desafio crucial para a confiabilidade das informações.

**Gabarito:** Correto

**9. (CEBRASPE / TSE - 2024) Julgue o item a seguir, a respeito de técnicas de ingestão de dados, análise de dados e Big Data.**

No armazenamento de dados em Big Data, valor é o critério que observa a integração de informações coletadas em diferentes fontes, com vistas a enriquecer as análises.

**Comentários:**



O critério que observa a integração de informações coletadas em diferentes fontes é a "variedade", não o "valor". A variedade refere-se à diversidade de fontes e formatos de dados, essencial para análises em Big Data.

**Gabarito:** Errado

**10.(CEBRASPE / Prefeitura de Mossoró - 2024) Acerca de Big Data, julgue o próximo item.**

A arquitetura Lambda difere da arquitetura Kappa devido à existência da camada batch, que permite acesso ao histórico dos dados processados.

**Comentários:**

Na Lambda há camada batch, que reprocessa grandes volumes e mantém visão histórica; na Kappa, o foco é o streaming, sem batch separado, o que reduz o acesso/reprocessamento do histórico.

**Gabarito:** Correto

**11.(CEBRASPE / TSE - 2024) Julgue o item a seguir, a respeito de técnicas de ingestão de dados, análise de dados e Big Data.**

Na ingestão de dados, a arquitetura lambda utiliza o processamento em lote para fornecer visualizações das informações e utiliza a atualização em tempo real para ajudar os gestores a visualizarem dados críticos e urgentes.

**Comentários:**

Na arquitetura lambda, a camada batch processa grandes volumes em lote para análises/visualizações consolidadas, enquanto a camada speed atualiza em tempo real, permitindo acompanhar eventos críticos e urgentes com baixa latência.

**Gabarito:** Correto

**12.(CEBRASPE / STJ - 2024) O termo Big Data se refere apenas ao grande volume de dados que uma organização coleta, enquanto analytics é o processo de analisar esses dados para obter insights.**

**Comentários:**

O termo Big Data não se limita apenas ao volume de dados, mas também abrange a variedade, velocidade e veracidade desses dados. Analytics, por sua vez, é o processo de extração de insights, mas ambos conceitos são interdependentes.

**Gabarito:** Errado

**13.(CEBRASPE / STJ - 2024) Em Big Data, uma das propriedades ACID é a atomicidade, que garante que todas as alterações sejam efetivadas no banco de dados, sem atualização parcial da transação.**

**Comentários:**

A atomicidade é uma das propriedades ACID que assegura que uma transação seja tratada como uma unidade indivisível, garantindo que todas as operações sejam completadas com sucesso ou nenhuma delas seja aplicada, evitando atualizações parciais.

**Gabarito:** Correto

**14.(CEBRASPE / TC-DF - 2024) Julgue o item subsequente, que versa sobre Big Data e visualização e análise exploratória de dados.**

Big Data são dados não estruturados, em escala de exabytes, criados por sites de mídia social, transações financeiras e pela própria Internet, sendo muito vastos para serem estruturados em bancos de dados relacionais tradicionais.

**Comentários:**

Big Data refere-se a conjuntos de dados extremamente grandes e complexos que não podem ser facilmente gerenciados por bancos de dados relacionais tradicionais. Esses dados são frequentemente não estruturados e gerados por diversas fontes, como redes sociais e transações online.

**Gabarito:** Correto

**15.(CEBRASPE / CTI - 2024) Considerando processos de análise e mineração de dados, julgue o item subsequente.**

No contexto de mineração de dados, o atributo da veracidade está associado ao grau de confiabilidade dos dados utilizados na solução.

**Comentários:**

O atributo de veracidade na mineração de dados refere-se à confiabilidade e precisão dos dados. Dados verídicos são essenciais para garantir que as análises e decisões baseadas neles sejam válidas e eficazes.

**Gabarito:** Correto

**16.(CEBRASPE / TC-DF - 2024) Julgue o item subsequente, que versa sobre Big Data e visualização e análise exploratória de dados.**

Em Big Data, a análise preditiva visa recomendar ações específicas para a identificação de situações em que os resultados da análise podem ser usados para melhorar a eficiência, a eficácia e a produtividade das empresas.

**Comentários:**

A análise preditiva em Big Data não se limita a recomendar ações específicas, mas sim a prever resultados futuros com base em dados históricos. O foco é mais na previsão do que na recomendação direta de ações.

**Gabarito:** Errado

**17.(CEBRASPE / TCE-AC - 2024) A respeito de Big Data, julgue o próximo item.**

Um dos três Vs de Big Data possui a propriedade ACID de atomicidade, que garante que eventos de uma transação não interfiram em outras transações.

**Comentários:**

O conceito de atomicidade, parte das propriedades ACID, assegura que uma transação é indivisível e que suas operações são concluídas com sucesso ou não são realizadas, evitando interferências entre transações. Qual é a relação disso com as premissas do Big Data? Nenhuma! Viagem da banca e ela simplesmente ignorou todos os recursos e manteve esse gabarito absurdo!

**Gabarito:** Correto

**18.(CEBRASPE / ANATEL - 2024) Acerca do fluxo de Big Data, julgue o item que se segue.**

Streaming processing é uma tecnologia de Big Data exclusiva para atender processamentos de serviços de streaming de áudio e vídeo.

**Comentários:**

Streaming processing é uma tecnologia de Big Data que permite o processamento de dados em tempo real, não se limitando apenas a serviços de streaming de áudio e vídeo. Ela é aplicada em diversas áreas, como monitoramento de redes e análise de dados em tempo real.

**Gabarito:** Errado

### 19.(CEBRASPE / ANATEL - 2024) A respeito de Big Data, julgue o próximo item.

Em um data lake, os dados são depositados em estado bruto, sem terem passado por qualquer análise e mesmo sem terem uma governança.

#### Comentários:

Em um data lake, os dados são armazenados em seu formato original, sem processamento ou análise prévia, permitindo a flexibilidade de uso posterior. A ausência de governança inicial é uma característica típica desse tipo de armazenamento.

**Gabarito:** Correto

### 20.(CEBRASPE / ANATEL - 2024) A respeito de Big Data, julgue o próximo item.

Projetos de Big Data, quando necessário, crescem horizontalmente, com a inclusão de novos nodos, e verticalmente, com o acréscimo de mais memória.

#### Comentários:

Projetos de Big Data geralmente crescem horizontalmente, adicionando novos nodos, mas o crescimento vertical, que envolve aumentar a capacidade de um único nó, não é uma prática comum em Big Data, que prioriza a escalabilidade horizontal. Para mim, essa questão deveria ser anulada!

**Gabarito:** Errado

### 21.(CEBRASPE / SEBRAE-NACIONAL - 2024) Assinale a opção em que é indicado o termo afeto a Big Data que se refere ao fato de fluxos de dados serem imprevisíveis, com frequentes mudanças e alterações substanciais, aliado ao aumento da velocidade.

- a) bare metal
- b) map reduce
- c) variabilidade
- d) escalabilidade

#### Comentários:

(a) Errado. Bare metal se refere a servidores físicos sem virtualização, não relacionado à imprevisibilidade dos dados.

(b) Errado. Map Reduce é um modelo de programação para processamento de grandes volumes de dados, não aborda a variabilidade dos fluxos de dados.



- (c) Correto. A variabilidade em Big Data refere-se à natureza imprevisível dos fluxos de dados, que estão sujeitos a mudanças rápidas e significativas, refletindo a dinâmica dos dados em tempo real;
- (d) Errado. Escalabilidade diz respeito à capacidade de um sistema de aumentar sua capacidade de processamento, não à imprevisibilidade dos dados.

**Gabarito:** Letra C

**22.(CEBRASPE / SEBRAE-NACIONAL - 2024) A disciplina, em Big Data, que inclui o gerenciamento do ciclo de vida completo dos dados, abrangendo coleta, limpeza, organização, armazenamento, análise e governança de dados, é denominada data**

- a) visualization.
- b) mining.
- c) warehouse.
- d) analytics.

**Comentários:**

- (a) Errado. A visualização de dados refere-se à representação gráfica de informações, não abrange o ciclo completo de gerenciamento de dados.
- (b) Errado. Data mining é o processo de descobrir padrões em grandes conjuntos de dados, mas não cobre todo o ciclo de vida dos dados.
- (c) Errado. Um data warehouse é um sistema de armazenamento de dados, mas não inclui as etapas de coleta, limpeza e governança.
- (d) Correto. Data analytics envolve o gerenciamento completo do ciclo de vida dos dados, incluindo coleta, limpeza, organização, armazenamento, análise e governança.

**Gabarito:** Letra D

**23.(CEBRASPE / SEBRAE-NACIONAL - 2024) Em Big Data, coleções ou grupos de dados relacionados em que haja possibilidade de compartilhamento com outros grupos, atributos ou propriedades são denominados**

- a) data mining.
- b) data analytics.
- c) data set.
- d) data analysis.

### Comentários:

- (a) Errado. Data mining refere-se ao processo de descobrir padrões em grandes conjuntos de dados, não à coleção ou grupo de dados em si;
- (b) Errado. Data analytics envolve a análise de dados para obter insights, mas não se refere especificamente a coleções de dados;
- (c) Correto. Data set é o termo que designa coleções de dados relacionados que podem ser compartilhados e analisados, sendo a alternativa correta;
- (d) Errado. Data analysis é o processo de examinar dados para tirar conclusões, e não se refere a um grupo ou coleção de dados.

**Gabarito:** Letra C

### 24.(CEBRASPE / SEBRAE-NACIONAL - 2024) O aspecto diretamente afeto aos "Vs" de Big Data que trata especificamente de ruído nos dados que não podem ser convertidos em informações é

- a) o valor.
- b) a veracidade.
- c) o viés.
- d) a verossimilhança.

### Comentários:

- (a) Errado. O valor refere-se à utilidade dos dados, não ao ruído que impede a conversão em informações. Portanto, não é o aspecto correto relacionado ao problema mencionado.
- (b) Correto. A veracidade diz respeito à qualidade e precisão dos dados, incluindo o ruído que pode distorcer informações, sendo essencial para garantir a confiabilidade das análises em Big Data.
- (c) Errado. O viés refere-se a distorções nos dados que podem afetar a interpretação, mas não se relaciona diretamente ao ruído que impede a conversão em informações.
- (d) Errado. A verossimilhança está relacionada à plausibilidade dos dados, mas não aborda especificamente o ruído que dificulta a transformação de dados em informações úteis.

**Gabarito:** Letra B

**25.(CEBRASPE / SEBRAE-NACIONAL - 2024) O aspecto diretamente afeto aos "Vs" de Big Data que trata especificamente dos diferentes tipos de dados, ou seja, se são estruturados ou semiestruturados, é a**

- a) volatilidade.
- b) variedade.
- c) variância.
- d) variação.

**Comentários:**

(a) Errado. Volatilidade refere-se à rapidez com que os dados são gerados e descartados, não aos tipos de dados em si.

(b) Correto. Variedade é o "V" de Big Data que se refere à diversidade dos dados, incluindo dados estruturados, semiestruturados e não estruturados, abordando sua classificação.

(c) Errado. Variância é um termo estatístico que mede a dispersão dos dados, não se relacionando diretamente com a classificação dos tipos de dados em Big Data.

(d) Errado. Variação é um conceito que se refere a mudanças ou diferenças, mas não aborda a classificação dos dados em Big Data, que é o foco da questão.

▪

**Gabarito:** Letra B

**26.(CEBRASPE / SEBRAE-NACIONAL - 2024) Especificamente em relação a Big Data, o termo velocidade está relacionado**

- a) à celeridade de adaptação da base de dados em relação ao seu crescimento horizontal e à quantidade de "campos/colunas/tipos" de dados novos a serem inseridos na base de dados, ou, ainda, à rapidez na adequação do armazenamento de dados a serem estruturados ou não estruturados.
- b) à coleta rápida de dados, uma vez que os dados podem chegar em velocidades rápidas e enormes conjuntos de dados podem acumular-se em períodos curtos.
- c) à velocidade necessária de acesso à memória suficiente para processar as correlações entre os dados e responder às necessidades do usuário.
- d) ao processamento rápido no cálculo da qualidade dos dados que são inseridos na base de dados central.

**Comentários:**

- (a) Errado. A celeridade de adaptação da base de dados se relaciona mais à escalabilidade e flexibilidade do sistema, não especificamente à velocidade, que é um conceito mais ligado à rapidez na coleta e processamento de dados.
- (b) Correto. O termo velocidade em Big Data refere-se à rapidez com que os dados são coletados e processados, permitindo que grandes volumes de informações sejam acumulados em intervalos curtos, essencial para a análise em tempo real.
- (c) Errado. Embora o acesso à memória e o processamento sejam importantes, a definição de velocidade em Big Data foca mais na rapidez da coleta e no fluxo de dados, não apenas no acesso à memória.
- (d) Errado. O processamento rápido da qualidade dos dados é relevante, mas não é o foco do termo velocidade em Big Data, que se refere mais à rapidez na coleta e no fluxo de dados do que à qualidade dos dados inseridos.

**Gabarito:** Letra B

**27.(CEBRASPE / SEBRAE-NACIONAL - 2024) Assinale a opção em que é apresentado o termo de Big Data que se refere a uma massiva quantidade de informações que é uma característica crítica na determinação de seu valor.**

- a) verificação
- b) validação
- c) variância
- d) volume

#### **Comentários:**

- (a) Errado. Verificação refere-se ao processo de checar a precisão e a integridade dos dados, não à quantidade de informações.
- (b) Errado. Validação é o processo de garantir que os dados atendem a critérios específicos, não está relacionado diretamente ao volume de dados.
- (c) Errado. Variância é uma medida estatística que descreve a dispersão dos dados, não se relaciona com a quantidade massiva de informações.
- (d) Correto. Volume é um dos 3 Vs do Big Data, referindo-se à grande quantidade de dados gerados e armazenados, essencial para determinar o valor das informações.

**Gabarito:** Letra D

**28.(CEBRASPE / TCE-PR - 2024) Uma equipe estadual de TI teve acesso a um data lake sobre dados de estradas do estado do Paraná e vai cruzar informações com o objetivo de otimizar o fluxo de veículos. Para isso, o time de Big Data optou por inicialmente descartar as variáveis correlacionadas redundantes. Nessa situação, a técnica que o time de Big Data deve adotar é a(o)**

- a) associação preliminar.
- b) análise de predição.
- c) descarte de resíduos.
- d) combinação funcional.
- e) redução de dimensionalidade.

**Comentários:**

(a) Errado. Associação preliminar refere-se à identificação de relações entre variáveis, mas não necessariamente ao descarte de variáveis redundantes.

(b) Errado. Análise de predição envolve modelagem para prever resultados, não se concentra no descarte de variáveis redundantes.

(c) Errado. Descarte de resíduos não é uma técnica reconhecida em Big Data para lidar com variáveis redundantes, mas sim um termo mais geral.

(d) Errado. Combinação funcional se refere à criação de novas variáveis a partir de outras, não ao descarte de variáveis redundantes.

(e) Correto. Redução de dimensionalidade é a técnica utilizada para eliminar variáveis redundantes, mantendo a informação essencial, o que se alinha com o objetivo do time de Big Data.

**Gabarito:** Letra E

**29.(CEBRASPE / SECONT ES - 2022) Acerca de arquiteturas e soluções de Big Data, julgue o item seguinte.**

Kappa, uma arquitetura de software usada para processar dados, fornece acesso a métodos de processamento em lote e processamento de fluxo com uma abordagem em quatro camadas.

**Comentários:**

A arquitetura Kappa prioriza o processamento por fluxo (streaming) e tende a unificar o pipeline, não se caracterizando por oferecer, em “quatro camadas”, acesso a processamento em lote e em fluxo como descrito no item.



**Gabarito:** Errado

## LISTA DE QUESTÕES

**1. (CEBRASPE / Polícia Federal - 2025) Acerca de segurança da informação, bancos de dados e aprendizado de máquina, julgue o próximo item.**

Em geral, projetos de Big Data caracterizam-se por cinco diferentes atributos: valor, variedade, velocidade, veracidade e volume.

**2. (CEBRASPE / EMBRAPA - 2025) Julgue o item a seguir, a respeito de inteligência artificial, Big Data e data warehouse.**

Big Data e data warehouse são técnicas de armazenamento que dispensam a necessidade de descoberta de conhecimento e mineração de dados, e, por isso, a aprendizagem de máquina não se aplica ao contexto de Big Data.

**3. (CEBRASPE / EMBRAPA - 2025) Julgue o próximo item, a respeito de computação e de programação.**

A análise de Big Data lida com dados estruturados, como tabelas e bancos de dados relacionais, mas não considera dados não estruturados, como textos, imagens e vídeos.

**4. (CEBRASPE / EMBRAPA - 2025) Julgue o item subsequente, a respeito de sensoriamento remoto e de sistemas de informação geográfica.**

O uso de plataformas de Big Data em agricultura dispensa algoritmos de aprendizado de máquina, pois a análise estatística tradicional é suficiente para gerar resultados úteis.

**5. (CEBRASPE / Polícia Federal - 2025) Julgue o item subsequente, relativos à teoria da informação e a banco de dados.**

A mineração de dados é uma técnica em que se utilizam exclusivamente algoritmos de aprendizado supervisionado para a identificação de padrões em grandes volumes de dados; no contexto de Big Data, a premissa principal é a utilização de bancos de dados relacionais tradicionais, que são suficientes para o enfrentamento dos desafios de volume, variedade e velocidade característicos desse ambiente.

**6. (CEBRASPE / TRF - 6ª REGIÃO - 2025) No que se refere à ciência de dados, julgue o item seguinte.**

Em big data, representações visuais, como gráficos e dashboards, permitem que padrões sejam rapidamente identificados.

**7. (CEBRASPE / TRF - 6ª REGIÃO - 2025) A respeito de Big Data, julgue o item a seguir.**

Na etapa de ingestão de um pipeline de dados de Big Data, os dados de diversas fontes são coletados e transportados para um armazenamento centralizado.

**8. (CEBRASPE / PC-DF - 2025) A respeito de inteligência artificial, de tipos de análise de dados e de Big Data, julgue o item que se segue.**

A veracidade em Big Data reflete o desafio de se assegurar a qualidade e precisão de dados frequentemente confusos, ruidosos e propensos a erros que comprometem sua confiabilidade.

**9. (CEBRASPE / TSE - 2024) Julgue o item a seguir, a respeito de técnicas de ingestão de dados, análise de dados e Big Data.**

No armazenamento de dados em Big Data, valor é o critério que observa a integração de informações coletadas em diferentes fontes, com vistas a enriquecer as análises.

**10.(CEBRASPE / Prefeitura de Mossoró - 2024) Acerca de Big Data, julgue o próximo item.**

A arquitetura Lambda difere da arquitetura Kappa devido à existência da camada batch, que permite acesso ao histórico dos dados processados.

**11.(CEBRASPE / TSE - 2024) Julgue o item a seguir, a respeito de técnicas de ingestão de dados, análise de dados e Big Data.**

Na ingestão de dados, a arquitetura lambda utiliza o processamento em lote para fornecer visualizações das informações e utiliza a atualização em tempo real para ajudar os gestores a visualizarem dados críticos e urgentes.

**12.(CEBRASPE / STJ - 2024) O termo Big Data se refere apenas ao grande volume de dados que uma organização coleta, enquanto analytics é o processo de analisar esses dados para obter insights.**

**13.(CEBRASPE / STJ - 2024) Em Big Data, uma das propriedades ACID é a atomicidade, que garante que todas as alterações sejam efetivadas no banco de dados, sem atualização parcial da transação.**

**14.(CEBRASPE / TC-DF - 2024) Julgue o item subsequente, que versa sobre Big Data e visualização e análise exploratória de dados.**

Big Data são dados não estruturados, em escala de exabytes, criados por sites de mídia social, transações financeiras e pela própria Internet, sendo muito vastos para serem estruturados em bancos de dados relacionais tradicionais.

**15.(CEBRASPE / CTI - 2024) Considerando processos de análise e mineração de dados, julgue o item subsequente.**

No contexto de mineração de dados, o atributo da veracidade está associado ao grau de confiabilidade dos dados utilizados na solução.

**16.(CEBRASPE / TC-DF - 2024) Julgue o item subsequente, que versa sobre Big Data e visualização e análise exploratória de dados.**

Em Big Data, a análise preditiva visa recomendar ações específicas para a identificação de situações em que os resultados da análise podem ser usados para melhorar a eficiência, a eficácia e a produtividade das empresas.

**17.(CEBRASPE / TCE-AC - 2024) A respeito de Big Data, julgue o próximo item.**

Um dos três Vs de Big Data possui a propriedade ACID de atomicidade, que garante que eventos de uma transação não interfiram em outras transações.

**18.(CEBRASPE / ANATEL - 2024) Acerca do fluxo de Big Data, julgue o item que se segue.**

Streaming processing é uma tecnologia de Big Data exclusiva para atender processamentos de serviços de streaming de áudio e vídeo.

**19.(CEBRASPE / ANATEL - 2024) A respeito de Big Data, julgue o próximo item.**

Em um data lake, os dados são depositados em estado bruto, sem terem passado por qualquer análise e mesmo sem terem uma governança.

**20.(CEBRASPE / ANATEL - 2024) A respeito de Big Data, julgue o próximo item.**

Projetos de Big Data, quando necessário, crescem horizontalmente, com a inclusão de novos nodos, e verticalmente, com o acréscimo de mais memória.

**21.(CEBRASPE / SEBRAE-NACIONAL - 2024) Assinale a opção em que é indicado o termo afeto a Big Data que se refere ao fato de fluxos de dados serem imprevisíveis, com frequentes mudanças e alterações substanciais, aliado ao aumento da velocidade.**

- a) bare metal
- b) map reduce
- c) variabilidade
- d) escalabilidade

**22.(CEBRASPE / SEBRAE-NACIONAL - 2024) A disciplina, em Big Data, que inclui o gerenciamento do ciclo de vida completo dos dados, abrangendo coleta, limpeza, organização, armazenamento, análise e governança de dados, é denominada data**

- a) visualization.
- b) mining.
- c) warehouse.
- d) analytics.

**23.(CEBRASPE / SEBRAE-NACIONAL - 2024) Em Big Data, coleções ou grupos de dados relacionados em que haja possibilidade de compartilhamento com outros grupos, atributos ou propriedades são denominados**

- a) data mining.
- b) data analytics.
- c) data set.
- d) data analysis.

**24.(CEBRASPE / SEBRAE-NACIONAL - 2024) O aspecto diretamente afeto aos "Vs" de Big Data que trata especificamente de ruído nos dados que não podem ser convertidos em informações é**

- a) o valor.
- b) a veracidade.
- c) o viés.
- d) a verossimilhança.

**25.(CEBRASPE / SEBRAE-NACIONAL - 2024) O aspecto diretamente afeto aos "Vs" de Big Data que trata especificamente dos diferentes tipos de dados, ou seja, se são estruturados ou semiestruturados, é a**

- a) volatilidade.
- b) variedade.
- c) variância.
- d) variação.

**26.(CEBRASPE / SEBRAE-NACIONAL - 2024) Especificamente em relação a Big Data, o termo velocidade está relacionado**

- a) à celeridade de adaptação da base de dados em relação ao seu crescimento horizontal e à quantidade de "campos/colunas/tipos" de dados novos a serem inseridos na base de dados, ou, ainda, à rapidez na adequação do armazenamento de dados a serem estruturados ou não estruturados.



- b) à coleta rápida de dados, uma vez que os dados podem chegar em velocidades rápidas e enormes conjuntos de dados podem acumular-se em períodos curtos.
- c) à velocidade necessária de acesso à memória suficiente para processar as correlações entre os dados e responder às necessidades do usuário.
- d) ao processamento rápido no cálculo da qualidade dos dados que são inseridos na base de dados central.

**27.(CEBRASPE / SEBRAE-NACIONAL - 2024) Assinale a opção em que é apresentado o termo de Big Data que se refere a uma massiva quantidade de informações que é uma característica crítica na determinação de seu valor.**

- a) verificação
- b) validação
- c) variância
- d) volume

**28.(CEBRASPE / TCE-PR - 2024) Uma equipe estadual de TI teve acesso a um data lake sobre dados de estradas do estado do Paraná e vai cruzar informações com o objetivo de otimizar o fluxo de veículos. Para isso, o time de Big Data optou por inicialmente descartar as variáveis correlacionadas redundantes. Nessa situação, a técnica que o time de Big Data deve adotar é a(o)**

- a) associação preliminar.
- b) análise de predição.
- c) descarte de resíduos.
- d) combinação funcional.
- e) redução de dimensionalidade.

**29.(CEBRASPE / SECONT ES - 2022) Acerca de arquiteturas e soluções de Big Data, julgue o item seguinte.**

Kappa, uma arquitetura de software usada para processar dados, fornece acesso a métodos de processamento em lote e processamento de fluxo com uma abordagem em quatro camadas.

## GABARITO

1. CORRETO
2. ERRADO
3. ERRADO
4. ERRADO
5. ERRADO
6. CORRETO
7. CORRETO
8. CORRETO
9. ERRADO
10. CORRETO
11. CORRETO
12. ERRADO
13. CORRETO
14. CORRETO
15. CORRETO
16. ERRADO
17. CORRETO
18. ERRADO
19. CORRETO
20. ERRADO
21. LETRA C
22. LETRA D
23. LETRA C
24. LETRA B
25. LETRA B
26. LETRA B
27. LETRA D
28. LETRA E
29. ERRADO

# ESSA LEI TODO MUNDO CONHECE: PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.



1 Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.



2 Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).



3 Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).



4 Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).



5 Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).



6 Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).



7 Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.



8 O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.